CLASIFICACIÓN DE TIPOS DE TUMORES MALIGNOS DE CÁNCER DE MAMA MEDIANTE TÉCNICAS DE TRANSFER LEARNING Y EXPLICABILIDAD

CLASSIFICATION OF MALIGNANT BREAST CANCER TUMOR TYPES USING TRANSFER LEARNING AND EXPLICABILITY TECHNIQUES

Alumno: Felipe Galarza

Email: 9001649@alumnos.ufv.es

Grado en Business Analytics

Curso académico 2025-2026

Resumen

El cáncer de mama es una de las enfermedades con mayor impacto en la población femenina a nivel mundial y para disminuir su riesgo es fundamental detectarlo de forma temprana. En este contexto, este proyecto tiene como objetivo desarrollar un sistema de apoyo al diagnóstico basado en el análisis de imágenes del dataset BreakHis mediante técnicas aprendizaje profundo y explicabilidad. Para ello, se emplean distintas arquitecturas de redes neuronales convolucionales (CNN), como Inception, ResNet y DenseNet, aplicando aprendizaje por transferencia para adaptar modelos pre entrenados al problema planteado. Además, se incorporan técnicas de *data augmentation* con el fin de generar nuevas imágenes artificialmente para añadir variabilidad al dataset y mejorar la capacidad de generalización, especialmente ante la limitada disponibilidad de datos y los problemas de desbalanceo. De esta manera, se compara el rendimiento de las arquitecturas mediante métricas de clasificación y se introduce un enfoque de explicabilidad utilizando Grad-CAM++, con el objetivo de añadir interpretabilidad a las decisiones del modelo y analizar su fiabilidad en un ámbito médico. Los resultados muestran el potencial de estos modelos como herramientas de apoyo al diagnóstico, aunque su rendimiento podría mejorar con más datos y recursos computacionales.

Palabras clave: Cáncer de Mama, Data Augmetation, Redes Neuronales Convolucionales (CNN), Transfer Learning, Explicabilidad, Grad-CAM++

Abstract

Breast cancer is one of the diseases with the greatest impact on women worldwide, and early detection is crucial to reducing the risk. In this context, this project aims to develop a diagnostic support system based on image analysis of the BreakHis dataset using deep learning and explainability techniques. To achieve this, different convolutional neural network (CNN) architectures, such as Inception, ResNet, and DenseNet, are employed, applying transfer learning to adapt pre-trained models to the problem posed. Furthermore, data augmentation techniques are incorporated to artificially generate new images, adding variability to the dataset and improving its generalizability, especially given the limited data availability and imbalance issues. The performance of the architectures is then compared using classification metrics, and an explainability approach is introduced using Grad-CAM++ to add interpretability to the model's decisions and analyze its reliability in a medical setting. The results demonstrate the potential of these models as diagnostic support tools, although their performance could be improved with more data and computational resources.

Key words: Breast Cancer, Data Agmentation, Convolutional Neural Networks (CNN), Transfer Learning, Explainability, Grad-CAM++

ÍNDICE

1. INTRODUCCIÓN 1
1.1. Descripción del Problema 1
1.2. Motivación 2
1.3. Estado del arte 4
2. OBJETIVOS 7
2.1. Objetivo General 7
2.2. Objetivos Específicos 7
3. INGENIERÍA DEL DATO 8
3.1. Herramientas utilizadas 8
3.1. Origen de los Datos 9
3.2. Extracción y almacenamiento de los datos 11
3.3. Análisis Descriptivo 11
3.4. Preprocesamiento de los datos 15
3.4.1. División de los datos 16
3.4.2. Data Augmentation 19
3.4.3. Generadores 26
3.5. Conclusión 28
4. ANÁLISIS DEL DATO 29
4.1. Estrategia de análisis 29
4.2. Marco teórico 30
4.3. Desarrollo de la estrategia de análisis 38
4.3.1. Configuración de los pesos 38
4.3.2. Tamaño de la imagen de entrada (input) 39
4.3.3. Número de capas de las arquitecturas 39
4.3.4. Param Grid 40
4.3.5. Entrenamiento de los modelos 43
4.3.6. Análisis del mejor modelo 46
4.3.7. Grad-CAM++ 46
4.4. Métricas de evaluación 47
4.4.1. InceptionV3 48
4.4.2. ResNet101V2 54
4.4.3. DenseNet121 61
4.4.4. Comparativa global 66
4.5. Visualización e interpretación de los resultados 67

4.5.1. InceptionV3 + Grad-CAM++ 67
4.5.2. ResNet101V2 + Grad-CAM++ 70
4.5.3. DenseNet121 + Grad-CAM++ 73
4.6. Conclusión 76
BIBLIOGRAFÍA 78
Anexo 1. Descarga del dataset BreakHis 85
Anexo 2. Comprobación de las clases de las imágenes 86
Anexo 3. Distribución de las dimensiones 87
Anexo 4. Ejemplos de imágenes con dimensiones distinTas 88
Anexo 5. Distribución del modo y N.º de canales 89
Anexo 6. Transformaciones de data augmentation 90
Anexo 7. Comparación de diferentes valores de batch size 91
Anexo 8. Fórmulas 92

ÍNDICE DE FIGURAS

Ilustración 1. Distribución inicial de las imágenes por clase 12
Ilustración 2. Número de imágenes corruptas por clase 15
Ilustración 3. Distribución de imágenes por clase en Train antes del augmentation 16
Ilustración 4. Distribución de imágenes por clase en Validation antes del augmentation .. 17
Ilustración 5. Distribución de imágenes en Test antes del augmentation 18
Ilustración 6. Distribución de las imágenes en Train después del augmentation 25
Ilustración 7. Accuracy y Loss durante el entrenamiento del mejor InceptionV3 50
Ilustración 8. Matriz de confusión del mejor InceptionV3 52
Ilustración 9. Curva ROC-AUC del mejor InceptionV3 53
Ilustración 10. Accuracy y Loss durante el entrenamiento del mejor ResNet101V2 56
Ilustración 11. Matriz de confusión del mejor ResNet10V2 58
Ilustración 12. Accuracy y Loss durante el entrenamiento del mejor ResNet101V2 59
Ilustración 13. Accuracy y Loss durante el entrenamiento del mejor DenseNet121 62
Ilustración 14. Matriz de confusión del mejor DenseNet121 64
Ilustración 15. Curva ROC-AUC del mejor DenseNet121 65
Ilustración 16. Resultados del mejor InceptionV3 68
Ilustración 17. Resultados del mejor InceptionV3 con Grad-CAM++ 69

Ilustración 18. Resultados del mejor ResNet101V2 71
Ilustración 19. Resultados del mejor ResNet101V2 con Grad-CAM++ 72
Ilustración 20. Resultados del mejor DenseNet121 74
Ilustración 21. Resultados del mejor DenseNet121 con Grad-CAM++ 75
Ilustración 22. Captura de la sección de descarga del dataset BreakHis 85
Ilustración 23. Comprobación de las clases de las imágenes 86
Ilustración 24. Distribución del ancho de las imágenes 87
Ilustración 25. Distribución de la altura de las imágenes 87
Ilustración 26. Imagen de 700x460 88
Ilustración 27. Imagen de 700x456 88
Ilustración 28. Distribución del modo de las imágenes 89
Ilustración 29. Distribución de los canales de las imágenes 89
Ilustración 30. Transformaciones de data augmentation 90
Ilustración 31. Comparación de diferentes valores de batch size (1) 91
Ilustración 32. Comparación de diferentes valores de batch size (2) 91

ÍNDICE DE TABLAS

Tabla 1. Distribución de las imágenes en BreakHis 9
Tabla 2. Dimensión, modo y nº de canales de las imágenes 13
Tabla 3. Conteo de dimensiones 13
Tabla 4. Conteo de canales 14
Tabla 5. Parámetros de data augmentation 25
Tabla 6. Parámetros de los generadores para cada set 28
Tabla 7. Pesos automáticos de las clases 39
Tabla 8. Características de las arquitecturas pre entrenadas 40
Tabla 9. Param Grid 43
Tabla 10. Mejores parámetros en InceptionV3 48
Tabla 11. Métricas de mejor InceptionV3 49
Tabla 12. Classification report del mejor InceptionV3 51
Tabla 13. Fidelidad media por clase de Grad-CAM++ en mejor InceptionV3 54

Tabla 14. Mejores parámetros en ResNet101V2 55
Tabla 15. Métricas de mejor ResNet101V2 55
Tabla 16. Classification report del mejor ResNet101V2 57
Tabla 17. Fidelidad media por clase de Grad-CAM++ en mejor ResNet101V2 60
Tabla 18. Mejores parámetros en DenseNet121 61
Tabla 19. Métricas de mejor DenseNet121 61
Tabla 20. Classification report del mejor DenseNet121 63
Tabla 21. Fidelidad media por clase de Grad-CAM++ en mejor DenseNet121 66

ÍNDICE DE FÓRMULAS

Ecuación 1. Fórmula de accuracy 92
Ecuación 2. Fórmula de precisión 92
Ecuación 3. Fórmula de recall 92
Ecuación 4. Fórmula de F1-score 92
Ecuación 5. Fórmula de macro average 92
Ecuación 6. Fórmula de weighted average 92
Ecuación 7. Fórmula de weighted average 93
Ecuación 8. Tasa de falsos positivos 93
Ecuación 9. Fórmula AUC 93
Ecuación 10. Fórmula de categorical crossentropy 93
Ecuación 11. Fórmula de softmax 93
Ecuación 12. Fórmula de ReLU 93
Ecuación 13. Fórmula de la función 'gradcam_plus_plus' 93
Ecuación 14. Fórmula del peso de los canales de la función 'gradcam_plus_plus' 94

1. INTRODUCCIÓN

1.1. Descripción del Problema

El diagnóstico definitivo del cáncer de mama requiere el análisis de muestras de tejido obtenidas mediante biopsia. Este proceso consiste en la inspección visual de imágenes microscópicas del tejido por parte de un patólogo especializado, quien debe identificar y clasificar el subtipo tumoral en función de las características morfológicas de las células y la arquitectura del tejido. Sin embargo, este proceso presenta limitaciones fundamentales que condicionan su aplicabilidad (Mitko Veta, 2014).

Por un lado, el análisis médico es un proceso altamente especializado, lento y depende de la experiencia del profesional. Se ha señalado que existe una variabilidad intra-observador considerable entre patólogos, lo cual introduce inconsistencias en el diagnóstico (Chetan L. Srinidhi, 2021). Esta idea se refuerza indicando que el análisis de imágenes médicas es una tarea altamente exigente incluso para patólogos experimentados, dando lugar a discrepancias diagnósticas que pueden comprometer el tratamiento del paciente (Jonathan de Matos, 2021).

Por otro lado, la creciente demanda de análisis médicos contrasta con la disponibilidad limitada de especialistas. En ese contexto, los sitemas de Inteligencia Artificial basados en Deep Learning han demostrado una capacidad notable para clasificar imágenes médicas con un rendimiento comparable al de los especialistas. Sin embargo, estos sistemas presentan un problema crítico para su adopción, y es que actúan como cajas negras que generan una predicción sin explicar en qué características de la imagen se han basado. Además, se ha demostrado que la aplicabilidad clínica de estos modelos se ve seriamente limitada precisamente por esta falta de transparencia en el proceso de decisión, ya que ni los analistas de datos ni los médicos son capaces de comprender cómo el modelo llega a su resultado (Miriam Hägele, 2020).

Para abordar este problema, se han desarrollado técnicas de explicabilidad aplicables a redes neuronales convolucionales entre las que se destaca Grad-CAM++. El objetivo de estas técnicas es generar mapas de calor sobre la imagen indicando qué regiones han influido más en la decisión del modelo. Esto permite transformar el sistema de un modelo opaco o de caja negra en una herramienta que ofrece resultados interpretables para que el médico pueda analizar y entender en qué zonas del tejido se ha fijado el modelo para realizar su

diagnóstico. Esto facilita la validación clínica del diagnóstico (Aditya Chattopadhyay, 2018).

En este contexto, el presente proyecto aborda el problema de la clasificación automática e interpretable de los cuatro tipos de tumores malignos de mama presentes en el dataset BreaKHis mediante técnicas de Transfer Learning sobre arquitecturas de redes neuronales convolucionales (CNN) pre entrenadas, combinadas con el algoritmo de explicabilidad Grad-CAM++ para que el sistema tenga transparencia clínica completa.

1.2.Motivación

La motivación de este proyecto surge de la gran cantidad de mujeres que sufren cáncer de mama cada año, llegando la mayoría a morir debido a un diagnóstico tardío. Esto supone una gran preocupación ya que, en muchos de los casos, si se detectase a tiempo, la paciente sería capaz de sobrevivir.

Aunque muchas personas mueran a causa de este cáncer, los avances y las investigaciones que ha habido a lo largo de los años están continuamente ayudando a que la tasa de mortalidad disminuya, ya que permiten que cada vez se diagnostique más rápido (Mayo Clinic, 2025). Esto se debe a que se trata de un cáncer que, en estados avanzados, sobre todo cuando se ha desarrollado metástasis (las células cancerosas viajan a otras zonas del cuerpo a través de la sangre o el sistema linfático y generan un nuevo tumor, haciendo que este se multiplique (NIH, s.f.)) es muy difícil o imposible de curar, por lo que diagnosticarlo lo más pronto posible es lo mejor, ya que un diagnóstico temprano haría que entre un 70% y un 80% de las personas se pueda curar (Nadia Harbeck, 2019).

Existen varios tipos de cáncer de mama que pueden empezar desde cualquier zona de la mama, pero el más común es el carcinoma ductal, que surge en los tubos (conductos) que llevan la leche desde la mama hasta el pezón (Puay Hoon Tan, 2020). El carcinoma lobular es el segundo más común y surge en las partes de las mamas que producen la leche, es decir, los lóbulos. Los otros dos tipos de tumores malignos, menos comunes, son el carcinoma papilar y el mucinoso (Fabio A. Spanhol, 2016).

Además, el tratamiento dependerá del estado en el que se encuentre el cáncer. Este puede presentarse en 5 estados o estadios. Los estadios 0, I, II o III son los más iniciales y su tratamiento se basa en erradicar el cáncer e impedir que reaparezca, mientras que, si se encuentra en un estadio IV, se basa en intentar disminuir los síntomas y alargar el tiempo de

vida, ya que en este estado se considera prácticamente incurable. Incluso si superan el cáncer, los pacientes deberán seguir tomando medicamentos y haciéndose pruebas para vigilar su reaparición. Para conocer el estadio en el que se encuentra también es importante estar pendiente de los síntomas, ya que en las fases iniciales no se suele sufrir ninguno, pero según va creciendo el tumor pueden aparecer bultos, líquidos o cambios notables en la mama o en el pezón; y cuando el tumor se encuentra en un estado muy avanzado se pueden sufrir dolores, dificultad respiratoria, hinchazón y pérdida de peso (Biblioteca Nacional de Medicina, 2025).

Por esto, como ya se ha mencionado antes, es importante que se puedan realizar diagnósticos tempranos para poder identificar los tumores en los estadios iniciales y así poder erradicarlo. Pero, a pesar de los avances en las técnicas de diagnóstico, la interpretación de los resultados sigue siendo un proceso complejo y depende principalmente de la experiencia del médico

En los últimos años, se han desarrollado sistemas de Inteligencia Artificial que han demostrado tener una gran capacidad para realizar diagnósticos. Sin embargo, el problema de estos sistemas es que no explican ni el cómo ni el por qué han llegado a esa conclusión o resultado (Miriam Hägele, 2020). Esto da lugar a que se siga dependiendo del médico para realizar el diagnóstico. Y, aunque se haya demostrado que cuando los sistemas de IA trabajan de forma autónoma son capaces de mantener un rendimiento similar al de un médico, es importante destacar que cuando los médicos han utilizado estas herramientas como apoyo, los resultados en los diagnósticos mejoraron (Marina Álvarez-Benito, 2025). Por ello, el origen de este proyecto surge de la necesidad de crear un método fiable e interpretable que permita al médico apoyarse en el sistema sin perder el control del diagnóstico, reduciéndole el proyecto y permitiéndole centrarse en planificar el tratamiento.

Sin embargo, la aplicación de Deep Learning en imágenes médicas presenta un obstáculo adicional que es la escasez de datos etiquetados. Obtener imágenes médicas clínicas requiere procedimientos invasivos, costes elevados y restricciones éticas, lo que hace que los datasets médicos sean significativamente más pequeños que los utilizados en otras aplicaciones de visión por computador (Geert Litjens, 2017). Esta limitación convierte al Transfer Learning en la solución técnica más adecuada para este tipo de proyectos en lugar de entrenar un modelo desde cero sobre un dataset reducido. Para ello, se parte de arquitecturas ya pre-entrenadas sobre millones de imágenes en ImageNet, que han aprendido a detectar patrones visuales generales como bordes, texturas y formas, y se adaptan al

dominio médico mediante fine-tuning (Nima Tajbakhsh, 2017). Esto permite obtener modelos robustos incluso con los datos disponibles, aprovechando el conocimiento previo acumulado por arquitecturas consolidadas como ResNet, DenseNet o InceptionV3 (Jason Yosinski, 2014).

La intención inicial del proyecto, centrada en comparar el rendimiento de distintas arquitecturas CNN en la clasificación de tumores malignos, evolucionó al detectar que la precisión del modelo por sí sola no es suficiente para que un sistema sea útil en un contexto clínico real. Un modelo que clasifica correctamente pero no explica su decisión seguiría siendo una caja negra inaceptable para el médico. Por ello, se incorporó Grad-CAM++ como componente central del proyecto, no como un añadido opcional, sino como el mecanismo que permite cerrar la brecha entre el rendimiento técnico del modelo y su aplicabilidad clínica real, generando mapas de calor que señalan visualmente en qué regiones del tejido se ha basado el modelo para realizar cada clasificación (Aditya Chattopadhyay, 2018).

1.3.Estado del arte

En los últimos años, la aplicación de técnicas aprendizaje automático y profundo en el ámbito médico ha adquirido una gran importancia, especialmente en el diagnóstico del diagnóstico del cáncer de mama, donde, como se ha mencionado anteriormente, la detección temprana resulta clave para mejorar la supervivencia de los pacientes.

Los avances en este ámbito se han encontrado mediante el uso de modelos de aprendizaje automático aplicados a datasets estructurados, donde algoritmos como máquinas de soporte de vectores (SVM), random forest y redes neuronales demostraron una alta capacidad para clasificar tumores malignos y benignos (Collazo, 2020). Además, se evidenció que el uso de redes neuronales es útil como apoyo al diagnóstico médico por su precisión (J.A. Gómez Ruiz, 2000). Sin embargo, se encontró una gran limitación, ya que estos enfoques dependían de variables extraídas previamente y no eran capaces ofrecer el apoyo al diagnóstico utilizando directamente las imágenes médicas (Chávez, 2023). Esta limitación supone un punto de partida para este proyecto, ya que indica la necesidad de utilizar modelos capaces de trabajar directamente con imágenes, como las redes neuronales convolucionales (CNN).

Los siguientes avances se apoyaron en el aprendizaje profundo, ya que se enfocaron en el análisis directo de imágenes médicas mediante CNN, lo que permitió capturar patrones

complejos y relaciones espaciales imposibles de modelar con técnicas más tradicionales (Hugo Chanampe, 2019). De esta manera, en el ámbito del cáncer de mama, también se han aplicado arquitecturas de CNN para el análisis de imágenes mamarias, como ecografías, logrando mejoras significativas en la precisión del diagnóstico (Vásquez, 2025). Pero, a pesar de las mejoras en el diagnóstico, se ha observado que el rendimiento de estos modelos depende principalmente del tamaño y calidad de los datos disponibles y de las estrategias empleadas en el entrenamiento (Ocariz, 2025). En este sentido, se valida el uso de CNN en el ámbito médico y se presenta un principio para uno de los problemas a los que se enfrenta este tipo de proyectos, como lo es la necesidad de optimizar el rendimiento de los modelos con datasets limitados y especializados.

Siguiendo esta línea, se ha demostrado que el uso de técnicas de transfer learning en arquitecturas pre entrenadas de CNN permite mejorar su rendimiento en tareas de clasificación de imágenes médicas, especialmente cuanto se cuenta con datos limitados (Criollo, 2024). Para ello, además se han comparado arquitecturas como VGG, ResNet e Inception, observando mejoras en su capacidad de generalización tras aplicar fine tuning. Destacando Inception al mostrar un buen rendimiento combinando filtros de distintos tamaños dentro de la misma capa, permitiendo capturar información a múltiples escalas (Reshma Ahmed Swarna, 2024). También se ha visto que, de forma complementaria, el uso de técnicas de preprocesado de imágenes como transformaciones de data augmentation, ha sido comúnmente aplicado para incrementar artificialmente la variabilidad del conjunto de entrenamiento, reduciendo el sobreajuste y mejorando la eficacia de los modelos (Vásquez, 2025). Este aspecto resulta relevante para este proyecto, ya que apoya el uso de las dos técnicas en las que se basa, transfer learning y data augmentation.

Además, se han hecho comparaciones de distintas arquitecturas de CNN, para encontrar las que ofrezcan el mejor equilibrio entre precisión, sensibilidad y eficiencia. Arquitecturas de modelos como ResNet han demostrado un alto rendimiento gracias a su capacidad para mitigar problemas como el desvanecimiento del gradiente (Balamurali, 2022). Por otro lado, en modelos como DenseNet, se ha destacado su arquitectura con conexiones densas entre capas, lo que favorece la reutilización de características y mejora la eficiencia en el aprendizaje (Gao Huang, 2018). Esto apoya lo comentado anteriormente y resalta la necesidad de comparar distintas arquitecturas con diferentes configuraciones como uno de los objetivos de este proyecto.

Como limitación a estos avances, se encuentra la falta de interpretabilidad de los modelos en medicina, lo que limita su uso en este ámbito. En el contexto de las CNNs, los modelos suelen comportarse como cajas negras, dificultando la comprensión del proceso de clasificación para los médicos, lo que supone un obstáculo, ya que en este ámbito no solo es necesario obtener predicciones precisas, sino también comprender cómo se han conseguido para poder interpretar el diagnóstico (Ali Erdem Ozcelik, 2025). Esta necesidad apoya otro de los objetivos de esto proyecto, que es el de poder interpretar los resultados de los modelos entrenados.

Para solucionar esto, surgieron técnicas de Inteligencia Artificial Explicable (XAI), cuyo objetivo es proporcionar interpretaciones comprensibles sobre el comportamiento de los modelos. Entre estas técnicas destacan SHAP y LIME, comúnmente utilizados para explicar modelos de aprendizaje automático con datos estructurados mediante la contribución de cada característica en la predicción (Azzedine El mrabet, 2025). En cambio, para el contexto del análisis de imágenes, se desarrollaron técnicas diseñadas para modelos convolucionales, como Grad-CAM, que permite generar mapas de activación resaltando las regiones de la imagen que más influyen en la predicción del modelo facilitando su interpretación visual, lo que es fundamental para el ámbito médico (Simón, 2023). Siguiendo esta línea, se creó Grad-CAM++ como mejora de Grad-CAM, ya que optimiza la localización de las características relevantes y proporcionan explicaciones más precisas, especialmente cuando existen múltiples regiones de interés dentro de la imagen (Ameen, 2026). El desarrollo de estas técnicas supone un gran avance a la hora aportar herramientas útiles para este proyecto, ya que sirven como soporte para el objetivo de mejorar la interpretación de los resultados de los modelos, sobre todo con Grad-CAM++ al ser la versión mejorada y más útil para el contexto de las imágenes.

También se ha demostrado la utilidad de aplicar estas técnicas en el ámbito médico, ya que no solo mejoran la transparencia de los modelos, sino que aportan una mayor interpretabilidad para que los médicos puedan validar las predicciones de los diagnósticos (Ali Erdem Ozcelik, 2025). En este contexto, la evaluación de la explicabilidad de estas técnicas requiere analizar su fidelidad, entendida como el grado en que las regiones destacadas por el modelo se corresponden con áreas clínicamente relevantes y consistentes con el diagnóstico (Azzedine El mrabet, 2025). De esta forma, en este proyecto se destaca la importancia de evaluar la fidelidad de Grad-CAM++, ya que va a ser la técnica utilizada.

En conclusión, en el ámbito de las redes neuronales y la medicina ha habido muchos avances en las predicciones de los diagnósticos tanto con datos estructurados como con imágenes. En el contexto de estas últimas se ha comprobado la eficiencia del uso de arquitecturas de CNN combinándolas con técnicas de transfer learning y técnicas de explicabilidad para mejora la interpretación de los resultados con la evaluación de la fidelidad. Esto sugiere una base que este proyecto usará como soporte para tratar de conseguir los objetivos aportando una solución al problema planteado mediante la comparación de distintas configuraciones en arquitecturas, como ResNet, DenseNet e Inception, y la aplicación de Grad-CAM++.

2. OBJETIVOS

2.1.Objetivo General

El objetivo principal de este proyecto se basa en analizar si la aplicabilidad de técnicas de transfer learning y de explicabilidad a distintas arquitecturas de redes neuronales convolucionales para la clasificación de tipos de tumores malignos mediante imágenes microscópicas puede ser eficaz para encontrar la configuración que permita aportar una herramienta para el diagnóstico de cáncer de mama de una manera fácil, precisa y explicativa.

Para ello se personalizarán las arquitecturas de CNN pre entrenadas DenseNet121, ResNet101V2 y InceptionV3 mediante distintas configuraciones, para comparar, mediante métricas de evaluación, su eficacia a la hora de clasificar los distintos tipos de tumores malignos. Además, se analizará la fidelidad con la que el algoritmo de explicabilidad Grad-CAM++ es capaz de indicar la razón de los resultados de los modelos.

2.2.Objetivos Específicos

Para lograr el objetivo general del proyecto hará falta elaborar una pauta en forma de objetivos específicos. Esta consistirá en:

- Analizar la necesidad de aplicar técnicas de preprocesamiento de datos como data augmentation.
- Encontrar la arquitectura y configuración que mejor clasifique los tipos de tumores malignos mediante distintas métricas de evaluación.
- Analizar la fidelidad de Grad-CAM++ para identificar las regiones relevantes en la clasificación de las imágenes.

Para dar respuesta a estos objetivos, y por tanto resolver el objetivo general, se llevará a cabo una metodología basada en la preparación de los datos, desarrollo de los modelos y análisis de los resultados.

3. INGENIERÍA DEL DATO

3.1. Herramientas utilizadas

El proyecto se ha desarrollado en Google Colab, ya que cuenta con más recursos computacionales que el ordenador local. Estos recursos son necesarios, ya que se va a trabajar con imágenes, que son mucho más pesadas que datos numéricos, y arquitecturas redes neuronales pre entrenadas, que requieren de altas capacidades de RAM y GPU para procesar dichas imágenes.

Además, permite trabajar con notebooks en lenguaje Python, que es el que se pretende utilizar debido a la gran cantidad de librerías que posee para trabajar con datos y en concreto, para este caso, con imágenes, redes neuronales y algoritmos de explicabilidad como Tensorflow y Keras, además de Sklearn para las métricas de evaluación de los modelos, Numpy, Matplotlib y Sns para la manipulación y visualización de los datos, y otras librerías útiles para el desarrollo del proyecto.

Por otro lado, Google Colab también permite conectarse con Google Drive facilitando el uso de datasets de imágenes, que suelen ocupar mucho espacio y requieren mucho tiempo de descarga. Sin embargo, al estar almacenados en la nube de Google Drive, la conexión con Google Colab permite acceder a ellos sin tener que descargarlos reduciendo el uso de memoria y de tiempo. Además, aunque Google Colab trabaja por sesiones y al final de cada una borra todo el entorno incluyendo variables y archivos, esta funcionalidad evita

que se tenga que descargar el dataset al principio de cada sesión, lo que es útil para el proyecto, ya que permite trabajar con imágenes y redes neuronales de forma eficiente.

3.1.Origen de los Datos

Los datos con los que se cuenta para este proyecto se han descargado de la web del repositorio público de la Universidad Federal de Paraná (ver cómo en Anexo 1) y provienen de la base de datos Breast Cancer Histopathological Image Classification (BreakHis), construida mediante una colaboración entre dicha universidad y el Laboratorio de I+D – Anatomía Patológica y Citopatología de Paraná, ambos de Brasil. Esta base de datos cuenta con 7909 imágenes microscópicas (con una dimensión de 700x460 píxeles en RGB de 3 canales, profundidad de 8 bits por canal y formato PNG), recogidas de 82 pacientes de cáncer de mama, con diferentes factores de magnificación (40X, 100X, 200X y 400X), siguiendo la siguiente distribución:

Tabla 1. Distribución de las imágenes en BreakHis

Magnification	Benign	Malignant	Total
40X	652	1370	1995
100X	644	1437	2081
200X	623	1390	2013
400X	588	1232	1820
Total of Images	2480	5429	7909

Fuente: (Fabio A. Spanhol, 2016)

Estas imágenes se obtuvieron mediante el método SOB (Biopsia Quirúrgica Abierta), también conocido como mastectomía parcial o biopsia por escisión, mediante el cual se extrae una muestra de tejido de mayor tamaño que por biopsia con aguja.

Los tumores, benignos y malignos, se clasifican en distintos tipos y subtipos según su apariencia en el microscopio y cada uno de estos tipos ofrece un pronóstico diferente y tiene unas implicaciones terapéuticas diferentes:

- **Benignos**:

- **Adenosis (A):** Afección benigna del seno en la que los lobulillos del seno están agrandados y hay más glándulas de lo normal (Society, 2022).
- **Fibroadenoma (F):** Tumores de los senos comunes compuestos por tejido granular y tejido estromal (conectivo). Tienen forma ovalada o redonda y se pueden sentir como una canica o balín dentro del seno (Society, 2022).
- **Tumor filodes (PT):** Tumores poco comunes que comienzan en el tejido conectivo y no en los conductos ni en las glándulas (Society, 2022).
- **Adenoma Tubular (TA):** Tumores poco comunes similares a los fibroadenomas en aspecto y tacto, pero diferentes ante el microscopio (Santora, 2025).

- **Malignos:**
  - **Carcinoma ductal (DC):** Cancer de seno más común, que empieza en el revestimiento de los conductos galactóforos (tubos que llevan la leche desde los lobulillos hasta el pezón). Puede ser in situ (CDIS), donde las células anómalas se encuentran en el revestimiento de los conductos, o invasivo, donde las células anómalas se expanden fuera de los conductos a otras partes del cuerpo (NIH, s.f.)
  - **Carcinoma lobulillar (LC):** Cáncer similar al ductal pero que empieza en los lobulillos (o glándulas lácteas), en lugar de en los conductos. También puede ser in situ (CLIS) o invasivo (NIH, s.f.).
  - **Carcinoma mucinoso (MC):** Cáncer que comienza en células que revisten ciertos órganos internos y que se caracterizan por la producción de mucina (componente principal del moco) (NIH, s.f.).
  - **Carcinoma papilar (PC):** Cáncer poco común que se origina en los conductos mamarios y se caracteriza por la presencia de crecimientos o proyecciones digitiformes. También puede ser in situ o invasivo, además de encapsulado, contenido en una cápsula fibrosa dificultando la diseminación, o sólido, presentado como masas sólidas (Institute, s.f.).

En el dataset, cada archivo de imagen almacena información sobre la imagen indicando el método de biopsia, la clase de tumor, el tipo, identificación del paciente, factor

de magnificación y número de la imagen; por ejemplo, de esta manera: **SOB_B_TA-14-4659-40-001.png** (Fabio A. Spanhol, 2016).

De esta manera se obtienen los datos originales que se analizarán y procesarán para su uso en los modelos.

3.2.Extracción y almacenamiento de los datos

Como se ha explicado anteriormente, el objetivo de este proyecto se basa en identificar los distintos tipos de tumores malignos. Por ello, solo se han mantenido estos tumores del dataset. Además, como la estructura del dataset original se divide en **clase de tumor > tipo de tumor > factor de magnificación**, y se quiere simplificar teniendo únicamente los tipos, pero manteniendo la variabilidad, se han mezclado los factores de magnificación por los tipos dejando la siguiente estructura: **Malignos > Tipos de tumor.**

Para esto, como el dataset original se encuentra en formato tar.gz de 4GB, lo cual es muy pesado para Google Colab, primero se subió a Google Drive, aprovechando la conexión entre ambos programas. Una vez en drive, se extrajo el contenido guardando las imágenes con la estructura de carpetas original en Google Colab, evitando así duplicar el uso de memoria (si se hubiera subido directamente a Google Colab habría ocupado la memoria del tar.gz original y de la carpeta con las imágenes extraídas). Una vez se tienen las imágenes originales, se creó otra carpeta de 'Malignos', con la estructura simplificada, donde se almacenaron las imágenes correspondientes a cada tipo y se guardaron en sus respectivas carpetas mezclando los distintos factores de magnificación.

Para asegurarse de que las imágenes se han guardado de manera correcta en el dataset final, se ha comprobado que los nombres de los archivos de las imágenes coincidan con la carpeta de su tipo. Y se ha observado (ver Anexo 2) que las imágenes DC corresponden a la carpeta ductal_carcinoma, las imágenes LC corresponden a la carpeta lobular_carcinoma, las imágenes MC corresponden a la carpeta mucinous_carcinoma y las imágenes PC corresponden a la carpeta papillary_carcinoma. Por lo que el dataset se habría creado con la estructura correcta para poder analizarlo.

3.3.Análisis Descriptivo

Una vez se obtuvieron las imágenes con las que se quiere trabajar, se analizaron mediante un análisis descriptivo para conocer si existían imágenes corruptas, el número final de observaciones, su distribución en las clases, sus dimensiones y canales.

Distribución de las clases y número de observaciones

Se observó que en el dataset final se cuentan con 5429 imágenes distribuidas en 3.451 para carcinoma ductal (con etiqueta ductal_carcinoma), 626 para carcinoma lobular (con etiqueta lobular_carcinoma), 792 para carcinoma mucinoso (con etiqueta mucinous_carcinoma) y 560 para carcinoma papilar (con etiqueta papillary_carcinoma)

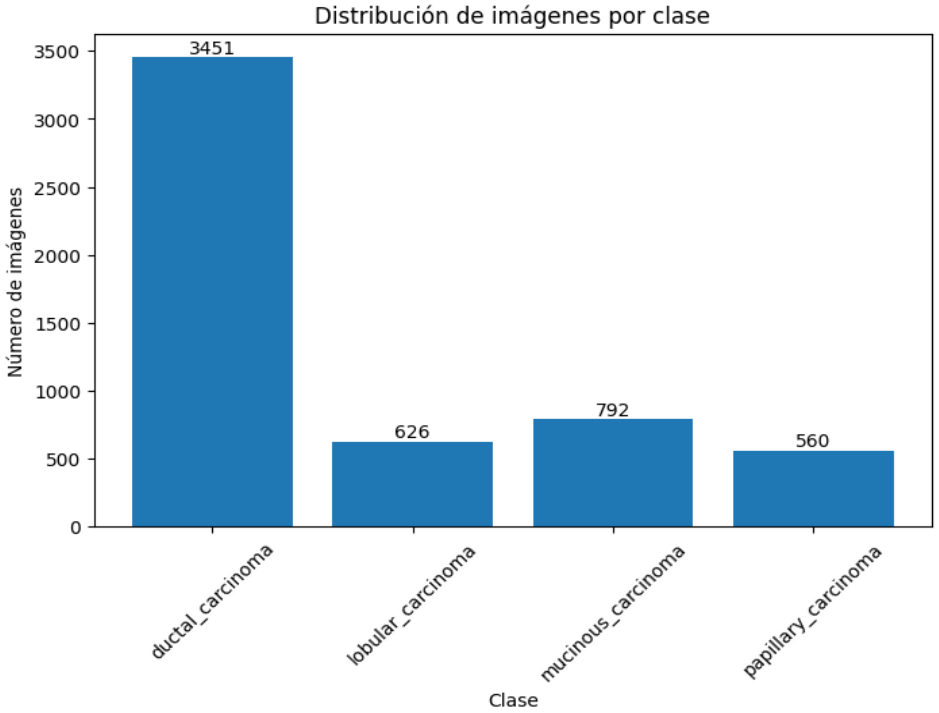

Ilustración 1. Distribución inicial de las imágenes por clase
(Fuente: Elaboración propia con Python)

Como se puede ver en el gráfico, había una gran diferencia entre al carcinoma ductal y el resto de los tipos, algo normal al ser el tipo de cáncer de mama más común. Esto daría lugar a un desbalanceo claro entre la clase ductal_carcinoma y el resto de las clases, más equilibradas entre ellas. Este desbalanceo se trataría más adelante mediante técnicas de data augmentation.

Análisis de las dimensiones y canales

Posteriormente, se han presentaron las observaciones en forma de dataframe para comprobar las dimensiones, el modo y el número de canales de las imágenes:

Tabla 2. Dimensión, modo y nº de canales de las imágenes

Index	Class	Filename	Width	Height	Mode	Channels
0	ductal_carcinoma	SOB_M_DC-14-2985-100-001.png	700	460	RGB	3
3451	lobular_carcinoma	SOB_M_LC-14-16196-100-010.png	700	460	RGB	3
4093	mucinous_carcinoma	SOB_M_MC-14-19979C-400-011.png	700	460	RGB	3
5424	papillary_carcinoma	SOB_M_PC-14-15687B-40-007.png	700	460	RGB	3

Fuente: Elaboración propia con Python

Como se ve, se confirmó que en general las imágenes presentaban unas dimensiones de 700x460 en modo RGB con 3 canales.

Además, se va a comprobó que todas las imágenes presentaran las mismas dimensiones, mediante el conteo y la distribución (ver Anexo 3) de estas.

Tabla 3. Conteo de dimensiones

width	height	count
700	456	74
700	460	5.355

Fuente: Elaboración propia con Python

Finalmente se observó que la mayoría de las imágenes presentaba una dimensión de 700x460, mientras que 74 tenían una dimensión de 700x456. Pero, al comprobar ejemplos

de imágenes con ambas dimensiones (ver Anexo 4), se observó que la diferencia en la dimensión era mínima y, que además al tratarse de un pequeño número de imágenes no tendría un gran efecto en los modelos. También, el efecto de esta diferencia de tamaño sería nula, ya que más adelante se aplicaría un redimensionamiento a todas las imágenes porque los modelos pre entrenados requieren un tamaño de entrada de imagen específico.

También se comprobó que todas imágenes presenten el mismo número de canales y modo, mediante el conteo y la distribución (ver Anexo 5) de estos.

Tabla 4. Conteo de canales

Mode	Channels	Count
RGB	3	5.429

Fuente: Elaboración propia con Python

Se observó que todas las imágenes son iguales en modo, y por tanto en canales, siendo estos RGB y 3, respectivamente.

Identificación de imágenes corruptas

Finalmente, se comprobó si existen imágenes corruptas dentro del dataset:

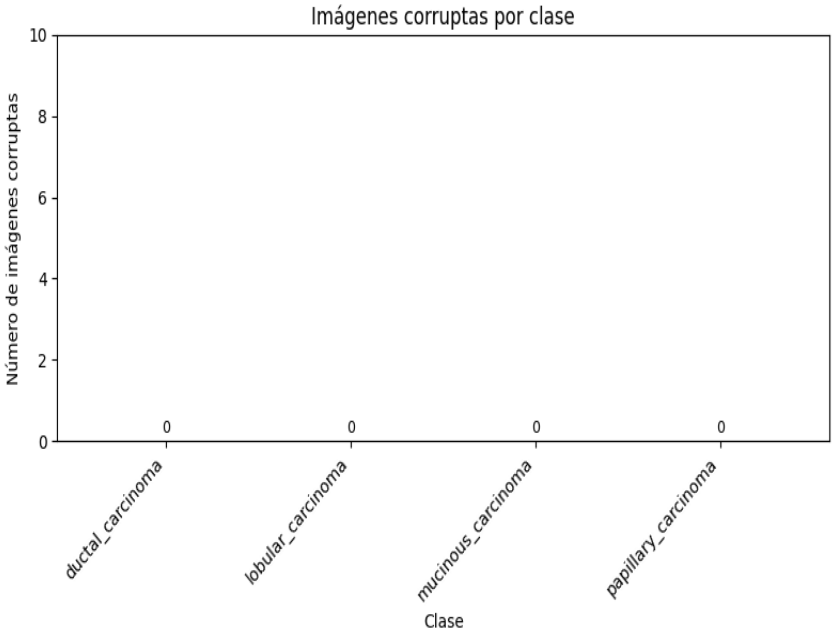

Ilustración 2. Número de imágenes corruptas por clase
(Fuente: Elaboración propia con Python)

Se observó que no existían imágenes corruptas, por lo que todas eran válidas para usarlas en el análisis.

3.4.Preprocesamiento de los datos

Una vez hecho el análisis y la comprobación de la validez de las imágenes del dataset, se preprocesaron para prepararlas para los modelos.

En este proceso de preprocesado se dividieron las imágenes en train, validation y test, para después aplicar las técnicas de data augmentation, arreglando el problema de desbalanceo de clases, y se crearon los generadores, donde se definió el tamaño del batch para cada epoch durante el entrenamiento de los modelos (el número de imágenes que se cargará) y se normalizaron y redimensionaron las imágenes a las medidas requeridas por estos.

3.4.1. División de los datos

Primero se hizo la división los datos para poder entrenar y validar los modelos correctamente. Para ello las imágenes se dividieron en 3 sets:

Train

Este set es el mayoritario con un 70% de los datos, ya que son los que el modelo utiliza para aprender a clasificarlos, con la siguiente distribución:

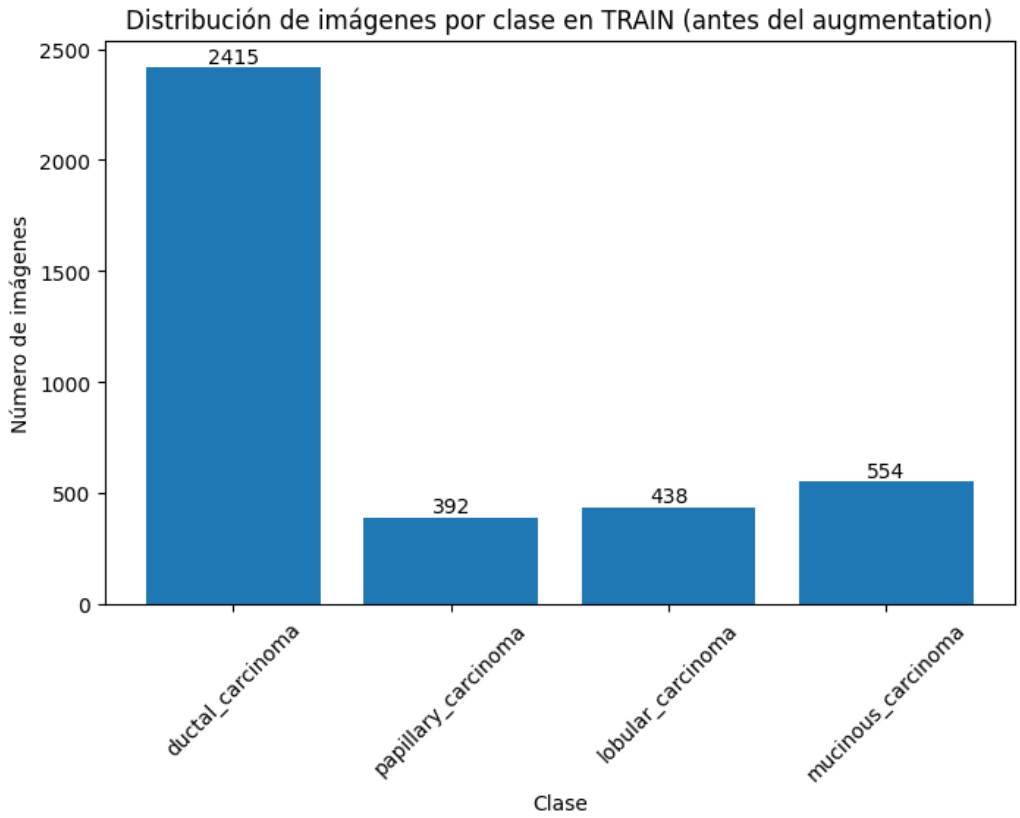

Ilustración 3. Distribución de imágenes por clase en Train antes del augmentation
(Fuente: Elaboración propia con Python)

Validation

Este set cuenta con el 15% de los datos, que son los que el modelo utiliza durante el entrenamiento para validar su aprendizaje en curso, con la siguiente distribución:

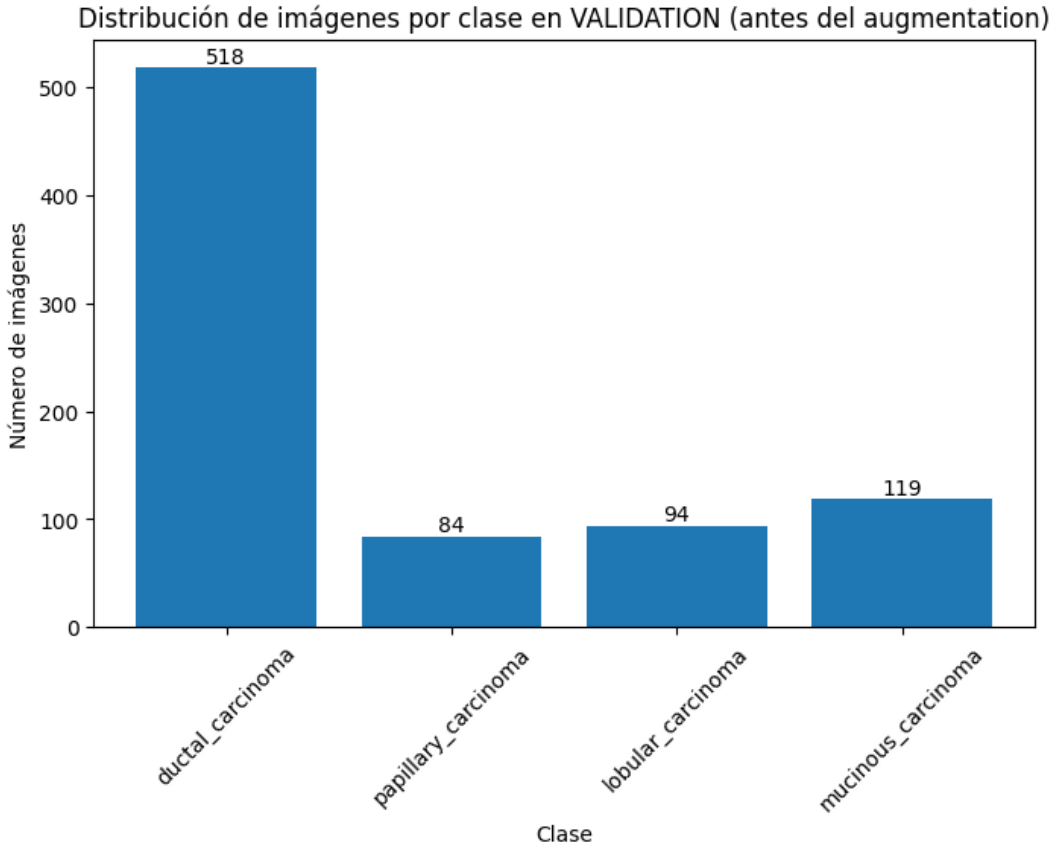

Ilustración 4. Distribución de imágenes por clase en Validation antes del augmentation (Fuente: Elaboración propia con Python)

Test

Este set también cuenta con un 15% de los datos y son imágenes que no se utilizan durante el entrenamiento, sino que se utilizan como datos nuevos en el modelo ya entrenado para evaluar su capacidad de generalización en la clasificación de las clases y, por tanto, su aplicación en casos nuevos. Al ser del mismo tamaño que el set de validación, sigue la misma distribución:

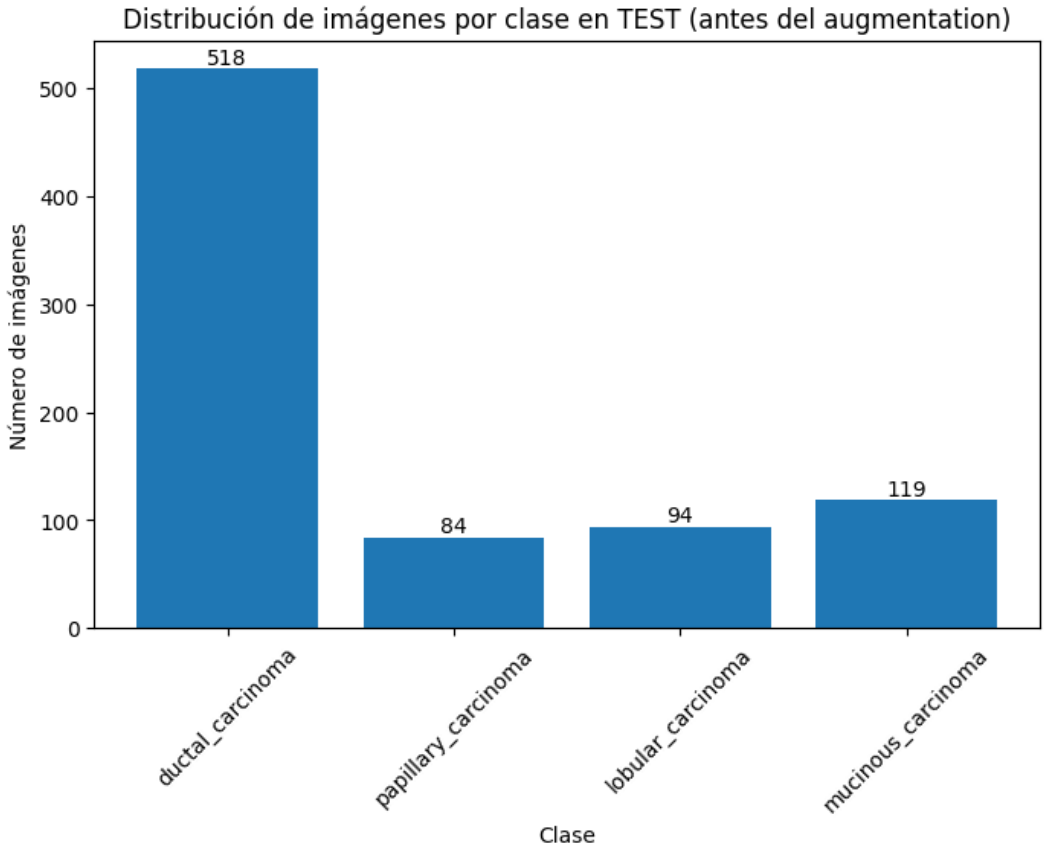

Ilustración 5. Distribución de imágenes en Test antes del augmentation
(Fuente: Elaboración propia con Python)

Para la división de estos sets se ha seguido una metodología que ha permitido mantener los porcentajes descritos con simplicidad. Primero se han divido el total de las imágenes en 70% para train y 30% a un set temporal, que luego se dividió en validation y test con 15% para cada set. Además, se siguió esta metodología, ya que la clase train_test_split de la librería sklearn solo permite dividir el dataset en dos partes por lo que fue necesario hacer dos divisiones.

Este paso es fundamental hacerlo antes de aplicar data augmentation, ya que esta técnica se aplica con el objetivo de regularizar el modelo mediante su aprendizaje, por lo que solo se utiliza en el set de train. En cambio, si se aplicase a los sets de validation y test, alteraría la distribución de la evaluación (Ian Goodfellow, 2016). Esto ocurre, ya que se aportaría una variabilidad innecesaria en esta parte, haciendo que las métricas reflejen el rendimiento del modelo entrenado sobre imágenes modificadas en lugar reales, produciendo una estimación optimista que no es representativa ni real (Connor Shorten, 2019).

3.4.2. Data Augmentation

Data augmentation es una técnica de regularización que consiste en generar nuevas muestras de entrenamiento aplicando transformaciones controladas sobre los datos originales, ampliando de forma artificial el tamaño y la diversidad del dataset sin tener que recopilar nuevos datos reales. Además, lo identifican como una de las técnicas más efectivas para combatir el overfitting en modelos de Deep learning con datasets de tamaño pequeño y mediano. En el caso de datasets de imágenes, las transformaciones aplicadas como las rotaciones, los desplazamientos, los cambios de escala, los flips y las variaciones de brillo generan imágenes que son distintas a nivel de píxel pero que preservan la etiqueta de la clase, ya que el contenido semántico y diagnóstico de la imagen no se altera (Connor Shorten, 2019).

La utilidad de esta técnica es que actúa como un regularizador implícito, ya que como el modelo recibe versiones ligeramente diferentes de cada imagen en cada época de entrenamiento, este no puede limitarse a memorizarlas, lo que le obliga a identificar las características visuales que realmente definen cada clase, como la morfología celular o la arquitectura del tejido. De esta forma, se reduce error de generalización al aumentar el espacio de ejemplos que el modelo ve durante el entrenamiento, lo que da lugar a un modelo más robusto frente a imágenes nuevas (Ian Goodfellow, 2016).

Además, presenta una solución para estudios en el ámbito médico, ya que uno de los principales obstáculos en el desarrollo de modelos de Deep Learning es la escasez de datos etiquetados. Esto ocurre porque la adquisición de imágenes médicas reales implica procedimientos clínicos invasivos, costes elevados y restricciones tanto éticas como de privacidad de los datos. Sin embargo, al aplicar esta técnica se evita la necesidad de adquirir nuevas imágenes mitigando este problema (Geert Litjens, 2017).

Por otro lado, en el dataset de este proyecto, como se ha visto anteriormente existe un desbalanceo notable en las clases, lo que, incluso ya en el dataset original de BreakHis, supone una gran limitación (Fabio A. Spanhol, 2016). Por ello se ha decidido aplicar la técnica de data augmentation, la cual ha demostrado ser útil para solucionar esta limitación en el dataset original mejorando las métricas de evaluación en todas las arquitecturas utilizadas (Agnieszka Mikołajczyk-Bareła, 2018).

Al haber un desequilibrio de alrededor de 2000 imágenes entre la clase ductal_carcinoma y el resto de las clases, puede haber un sesgo en el aprendizaje del modelo hacia las clases mayoritarias, lo cual reduce la capacidad de clasificar correctamente las clases minoritarias.

Por ello se ha decidido generar nuevas imágenes en las clases minoritarias hasta alcanzar un número total de 2000 imágenes como máximo en cada clase, ya que la clase mayoritaria, ductal_carcinoma, tiene aproximadamente 2400 imágenes en el set de train. De esta manera se garantiza que el modelo recibe una cantidad similar de imágenes de cada una de las cuatro clases durante el entrenamiento, eliminando así el sesgo que se puede producir por el desbalanceo.

Aunque la clase mayoritaria presenta cerca de 2400 imágenes, se ha decidido poner el límite de 2000 en el resto de las clases, ya que, si se trataran de igualar todas exactamente al mismo número de imágenes, las imágenes generadas podrían dominar las originales, provocando que el modelo aprenda más sobre datos sintéticos que sobre datos reales (Connor Shorten, 2019). Además, las nuevas imágenes suponen un aumente de aproximadamente el 85% en las clases minoritarias, lo cual es un ratio elevado, pero justo y necesario por el desequilibrio extremo que se presenta. Así, el desbalanceo disminuye drásticamente presentando una diferencia bastante menor entre la clase mayoritaria y las minoritarias, la cual se terminará de ajustar mediante el uso de pesos en los modelos.

Para aplicar esta técnica, se siguió una metodología común en este tipo de proyectos (Jason Wang, 2017). Primero se estableció que por cada clase que no alcanzaba el límite de 2000 imágenes se seleccione de forma aleatoria una imagen original del conjunto de entrenamiento de esa clase, a la que se le aplicarían las transformaciones configuradas de forma independiente y aleatoria, resultando una imagen que se guarda como una muestra nueva en la misma carpeta de la clase. Este proceso se repetiría hasta alcanzar

aproximadamente 2000 imágenes por clase. De esta manera, las imágenes originales se conservan intactas y las generadas se añaden como muestras adicionales.

Este enfoque corresponde a la augmentation offline, ya que las transformaciones se aplican a los datos antes del entrenamiento, lo que permite tener un control explícito sobre el tamaño final del dataset. Esto supone una ventaja frente a la augmentation online, en la cual las transformaciones definidas se aplican en tiempo real durante el entrenamiento, limitando el control del número de datos con los que el modelo está aprendiendo (Joseph Lemley, 2017).

Dentro de data augmentation existe una gran variedad de técnicas (ver en Anexo 6), que incluyen transformaciones geométricas, manipulaciones del espacio de color, mezcla de imágenes, borrado aleatorio, generación sintética mediante redes generativas adversiales (GANs), etcétera (Bedmar, 2023).

Debido a la gran variedad de transformaciones que existen, la selección de estas tiene que ser adecuada dado el contexto en se está trabajando. Esta decisión es importante, ya que no todas las transformaciones son igual de válidas para todas las tareas y su aplicación inapropiada puede reducir el rendimiento del modelo (Suorong Yang, 2023).

En el caso de las imágenes médicas, como las del dataset de este proyecto, las transformaciones válidas son únicamente aquellas que preservan el contenido de la imagen, es decir, que no alteran la morfología celular, la arquitectura del tejido ni la información cromática relevante para el diagnóstico. Teniendo esto en cuenta, se descartaron transformaciones como el borrado aleatorio o el recorte agresivo ya que eliminarían estructuras médicas relevantes. Además, las transformaciones de color extremas, las cuales alterarían la información de tinción H&E (método para visualizar mejor las diferentes partes de la célula al microscopio mediante tintes de hematoxilina y eosina (NIH, s.f.)), son también descartadas. Por ello, las transformaciones seleccionadas son la rotación moderada, desplazamiento, zoom, flip horizontal, variación de brillo suaves, desplazamiento de canales ligero y relleno de píxeles; las cuales son las más utilizadas para la clasificación de imágenes médicas porque introducen variabilidad suficiente para mejorar la generalización del modelo, sin comprometer la información de diagnóstico (David Tellez, 2019).

Rotation range

Esta transformación consiste en la rotacion de la imagen hacia la izquierda o hacia la derecha entre 1º y 359º. Este tipo de transformación está determinado por el grado de rotación del parámetro, ya que las rotaciones suaves se consideran útiles en tareas de detección de dígitos como MNIST (Modified National Institute of Standards and Technology) (Connor Shorten, 2019). En cambio, respecto a las imágenes médicas, no existen reglas relacionadas con la orientación, ya que un tejido puede aparecer en cualquier ángulo dependiendo de cómo se haya cortado la muestra. En este contexto, se ha demostrado que las rotaciones moderadas entre 10º y 30º mejoran la generalización en la clasificación de tejidos, mientras que rotaciones mayores pueden distorsionar las estructuras morfológicas relevantes para el diagnóstico, afectando de manera negativa a los resultados del modelo (David Tellez, 2019). Además, este tipo de transformación es una de las más naturales y efectivas en imágenes médicas, ya que son rotacionalmente invariantes (Sushovan Chaudhury, 2021).

Por esto, para el dataset de este proyecto, se ha decidido aplicar una rotación de 15º, dentro del rango previamente indicado, ya que aporta variabilidad sin distorsionar las partes importantes de las imágenes.

Width shift range y Hight shift range

Este tipo de transformación consiste en el desplazamiento de la imagen, vertical u horizontalmente, en el porcentaje del ancho especificado en el parámetro. Es especialmente útil para evitar el sesgo posicional de los datos, es decir, que el modelo aprenda a clasificar basándose en la posición de las estructuras en la imagen en lugar de en sus características morfológicas. Además, se recomiendan desplazamientos conservadores de entre el ±5% y el ±10% en imágenes médicas para preservar la integridad del diagnóstico, ya que porcentajes superiores podrían desplazar las estructuras relevantes fuera del encuadre (Connor Shorten, 2019). Por ello se ha decidido aplicar desplazamientos, tanto verticales como horizontales, de un ±8%, dentro del rango recomendado.

Zoom range

Este tipo de transformación consiste en aplicar un porcentaje de magnificación o zoom a las imágenes. Se ha concluido que zooms entre ±5% y ±10% son los más adecuados para imágenes médicas, ya que simulan pequeñas variaciones en la distancia focal del microscopio, que se producen de forma natural entre tomas del mismo tejido. En cambio, valores mayores alterarían la escala de las estructuras celulares y pueden confundir al modelo (Agnieszka Mikołajczyk-Bareła, 2018). Además, se ha comprobado que para la clasificación del dataset BreakHis, el zoom es una de las transformaciones principales de data augmentation, confirmando la efectividad en este ámbito (Musa Adamu Wakili, 2022).

Aunque las imágenes originales del dataset presenten aumentos por microscopio del 40%, 100%, 200% y 400%, y se haya decidido mantenerlos indistintamente, también se ha aplicado la transformación de zoom con un ±8%. Esto se ha hecho porque el porcentaje aplicado en el data augmentation es mucho menor que los aumentos de origen, por lo que no se estaría solapando ningún aumento. Además, como se ha explicado anteriormente, este valor se encuentra dentro del rango recomendado para este tipo de imágenes y se trata de una transformación útil y eficaz en este dataset.

Horizontal flip

Este tipo de transformación consiste en crear imágenes con 'efecto espejo' volteando las imágenes originales sobre su eje central de manera que se inviertan sus píxeles de izquierda a derecha. Se trata de una de las transformaciones más efectivas y sencillas de implementar, pero que dependen del contexto en el que se trabaje. Por ejemplo, si se trabaja con reconocimiento de texto, el flip destruye la etiqueta. A diferencia del ámbito médico, ya que los tejidos representados en imágenes médicas no tienen lateralidad preferente porque las estructuras celulares son morfológicamente simétricas y pueden aparecer con igual probabilidad en cualquier orientación horizontal. Esto supone que sea una transformación útil en este contexto, ya que preserva la clase (Connor Shorten, 2019). Se ha comprobado su utilidad en este ámbito, aplicándola en la clasificación de lesiones con CNN argumentando que la simetría bilateral de los tejidos biológicos justifica siempre su uso (Andre Esteva, 2017). De esta manera, se identifica como la transformación de data augmentation más aplicada en imágenes médicas (Geert Litjens, 2017).

Brightness range

Esta transformación es una de las más sencillas y prácticas de implementar. Consiste en aplicar operaciones matriciales simples sobre los valores RGB para aumentar o disminuir la luminosidad de la imagen (Connor Shorten, 2019). Además, se demostró que la manipulación del brillo y color es especialmente importante en las imágenes médicas debido a la variabilidad del proceso de tinción, y que valores superiores al 15%-20% podrían alterar la cromaticidad de forma poco realista, por lo que el rango conservador de alrededor del 10%, elegido para este proyecto, es el más habitual, ya que simula las diferencias en la intensidad de la tinción entre diferentes preparaciones médicas, que pueden variar entre laboratorios, lotes de reactivos y técnicos (David Tellez, 2019).

Channel shift range

Esta transformación consiste en el esplazamiento de los canales RGB aplicando una variación aleatoria sobre cada uno de estos de forma independiente. A diferencia de brightness range, que afecta a la luminosidad global de forma uniforme, el channel shift actúa canal a canal generando variaciones sutiles de tono que reproducen la variabilidad cromática real. Sin embargo, este tipo de transformación se describe como complementaria al brightness range, ya que cubren un tipo de variabilidad fotométrica diferente (Connor Shorten, 2019). Por esta razón, en el caso de este proyecto se aplica una variación de 10 unidades en los canales, el mismo valor que el aplicado en brightness range, ya que la variabilidad de color entre imágenes médicas no se limita al brillo, sino que también afecta a la distribución cromática entre canales (David Tellez, 2019).

Fill mode

Esta transformación es complementaria a rotaciones y desplazamientos, ya que al aplicar estas los píxeles que quedan fuera del encuadre original dejan huecos en los bordes de la imagen. Fill mode se utiliza para rellenar estos huecos y el modo en el que lo hace viene determinado por el parámetro que se defina. Con el valor 'nearest', cada píxel vacío se rellena copiando el valor del más cercano de la imagen original, lo que produce que el resultado sea visualmente coherente y menos artificial para imágenes de tejido celular, como lo es este caso. Además, se trata del modo de relleno más habitual a la hora de aplicar data

augmentation a imágenes médicas, ya que evita introducir colores o patrones artificiales que no existen en el tejido real (Connor Shorten, 2019).

Así, la aplicación de data augmentation se queda con estas transformaciones y valores respectivos:

Tabla 5. Parámetros de data augmentation

Transformación	Valor
Rotation range	15
Width shift range	0.08
Height shift range	0.08
Zoom range	0.08
Horizontal flip	True
Brightness range	(0.9, 1.1)
Channel shift range	10
Fill mode	nearest

Fuente: Elaboración propia con Python

Tras aplicar todas las transformaciones con los parámetros descritos, se ha solucionado el problema inicial de desbalanceo en el set de train reduciendo la diferencia con la clase mayoritaria drásticamente.

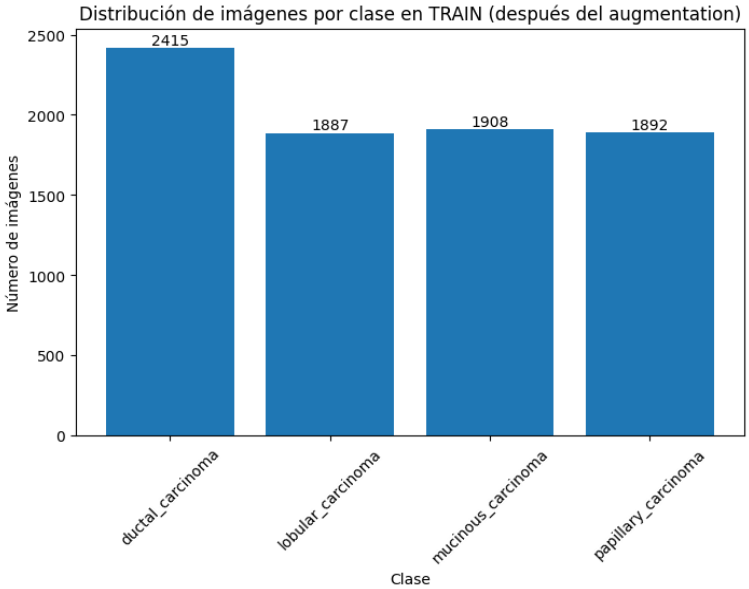

Ilustración 6. Distribución de las imágenes en Train después del augmentation (Fuente: Elaboración propia con Python)

Se observa que aún existe una diferencia mínima entre las clases, aunque se encuentran mucho más equilibradas que antes. Al ser una diferencia pequeña se solucinará mediante el ajuste de pesos en la ejecución de los modelos. Pero, de esta manera, los datos ya se encuentran almacenados en las carpetas correspondientes a su clase de forma balanceada.

3.4.3. Generadores

Los generadores de datos son una solución al problema de cargar grandes volúmenes de imágenes en memoria de forma simultánea. En lugar de cargar todo el dataset de una vez, el generador lee y procesa las imágenes por lotes durante el entrenamiento, lo que reduce bastante el consumo de la memoria RAM (HT, 2019). De esta manera, presentan la forma estándar de cargar datos a un modelo de Keras cuando el dataset es demasiado grande para cargarse en memoria de golpe (Chollet, 2021).

Pero es necesario definir unos parámetros cada set que estandaricen la carga de los datos. Por lo que, para este proyecto, se han definido 3 generadores, uno para cada set de datos (train, validation y test) aplicando, en cada uno, parámetros para el rescaldo de los píxeles y dimensiones, el número de imágenes que se cargan, el modo de las etiquetas y la mezcla de los datos.

Rescale

Las imágenes, al ser RGB con entrada de 8 bits por canal, se almacenan con valores de píxel en rango [0, 255], por lo que antes de introducirlas en la red es necesario normalizarlas al rango [0, 1] dividiendo cada valor de píxel por 255. Esto es importante, ya que se ha demostrado que la normalización de los datos de entrada es fundamental para la convergencia del entrenamiento, ya que evita que los gradientes sean dominados por las diferencias de escala entre características (Ian Goodfellow, 2016). Además, las redes neuronales convergen más rápido y de forma estable cuando los valores de entrada están en rangos pequeños y centrados. Por ello, para este proyecto, esta normalización se aplica a los tres generadores con el objetivo de garantizar que todos los datos se escalan de la misma forma.

Target size

Como ya se ha comentado anteriormente, las imágenes del dataset BreakHis tienen una dimensión general de 700x460, pero las arquitecturas pre entrenadas en Imagenet como ResNet o DenseNet esperan imágenes de tamaño fijo. Se trata de un tamaño estándar de entrada de 2024x224 píxeles establecido, originalmente, en VGG (Karen Simonyan, 2015) y adoptado, posteriormente, en ResNet (Kaiming He, 2015), DenseNet y EfficientNet (Mingxing Tan, 2020). Por esta razón, este redimensionamiento es un requerimiento fundamental para este proyecto.

Batch size

El batch size determina el número de imágenes que se procesan en cada paso de cada epoch durante el entrenamiento. Se ha demostrado que valores entre 16 y 64 (ver Anexo 7) ofrecen el mejor equilibrio entre velocidad de entrenamiento y capacidad de generalización en los modelos CNN (Ibrahem Kandel, 2020). Además, los tamaños de batch entre 2 y 64 (ver Anexo 7) generalizan mejor que los tamaños grandes, ya que el ruido introducido por lotes pequeños actúa como un regularizador implicito (Luschi, 2018).

Por estas razones se ha aplicado un batch size de 32, ya que representa un equilibrio entre la estabilidad del gradiente y la capacidad de generalización y por eso es uno de los valores más usados en la clasificación de imágenes.

Class mode

Mediante este parámetro se indica al generador el tipo de las clases a clasificar, que en este proyecto son categóricas, por lo que las etiquetas de cada una se codifican como vertores one-hot. Esto es que cada clase se representa como un vector de longitud igual al número total de clases, donde solo la posición correspondiente a la clase correcta vale 1 y el resto valen 0 (Keras, s.f.). Este parámetro es fundamental, ya que la función de activación y la función de perdida de los modelos depende de las clases. Por ejemplo, para softmax y categorícal crossentropy como funciones de activación y perdida, respectivamente, corresponde un class mode categorical (Ian Goodfellow, 2016), que es justo el caso de este proyecto.

Shuffle

Tener shuffle activado permite que las imágenes se carguen de forma aleatoria sin seguir el orden de las etiquetas. Por ello, es importante que se active en los generadores de train y validation para evitar que el modelo se aprenda el orden de las imágenes. En cambio, en el generador de test debe estar desactivado, ya que es fundamental que las etiquetas reales coincidan de forma exacta con el orden de las predicciones para poder calcular métricas como la matriz de confusión o la curva ROC. En caso de que estuviera activado en test, las predicciones y las etiquetas quedarían desalineadas y las métricas, por tanto, serían incorrectas (J, 2018).

Así, los 3 generadores se quedan con estos parámetros y valores respectivos:

Tabla 6. Parámetros de los generadores para cada set

	Train	Validation	Test
Rescale	1./255	1./255	1./255
Target size	(224, 224)	(224, 224)	(224, 224)
Batch size	32	32	32
Class mode	Categorical	Categorical	Categorical
Shuffle	True	True	False

Fuente: Elaboración propia con Python

3.5. Conclusión

Tras aplicar todas estas técnicas, se ha aprendido información sobre los datos con los que se cuenta, lo que ha permitido preprocesarlos de la manera idónea para los modelos que se van a configurar. De esta forma, los datos con los que se va a trabajar finalmente quedan almacenados y etiquetados correctamente, además de estar divididos en los 3 sets correspondientes, estando balanceados en train, que van a utilizar los modelos durante el aprendizaje. De esta manera también quedan preparados los generadores que cargarán los datos en los formatos correctos durante dicho aprendizaje.

4. ANÁLISIS DEL DATO

4.1. Estrategia de análisis

En este proyecto, se plantea un problema de aprendizaje supervisado de clasificación multiclase. El objetivo es construir un sistema capaz de clasificar imágenes de tejido mamario en cuatro categorías correspondientes a los subtipos de tumores malignos presentes en el dataset BreaKHis, a partir de las características visuales aprendidas directamente de los datos, sin necesidad de extracción manual de características por parte de un experto.

Dado que los datos de entrada son imágenes RGB de alta resolución, la estructura del dato determina directamente la elección del enfoque técnico. Las redes neuronales convolucionales (CNNs) son la arquitectura de referencia para tareas de clasificación de imágenes, ya que su diseño está específicamente orientado a extraer jerarquías de características espaciales, desde bordes y texturas en las capas iniciales hasta estructuras morfológicas complejas en las capas profundas. Sin embargo, entrenar una CNN desde cero requeriría un volumen de datos etiquetados muy superior al disponible en datasets médicos como BreaKHis, por lo que utiliza la técnica de data augmentation para generar nuevas imágenes a partir de transformaciones aplicadas a las del dataset original. Por esto, también se adopta Transfer Learning como estrategia de movilización, partiendo de arquitecturas ya pre-entrenadas sobre millones de imágenes en ImageNet y adaptándolas al dominio médico mediante fine-tuning. Este enfoque permite aprovechar el conocimiento visual ya adquirido por los modelos y obtener clasificadores robustos aun con datos limitados.

Para resolver el problema se han seleccionado tres arquitecturas con filosofías de diseño distintas, DenseNet121, ResNet101V2 e InceptionV3, con el objetivo de comparar su comportamiento ante el mismo problema y determinar cuál ofrece el mejor equilibrio entre rendimiento y capacidad de generalización en este dominio específico. Para realizar esta comparativa, al tratarse de un problema de clasificación multiclase, se utilizarán las métricas relacionadas con este tipo de problemas como accuracy, precisión, recall, f1-score, la matriz de confusión y la curva AUC-ROC.

Además del rendimiento predictivo, el proyecto incorpora Grad-CAM++ como técnica de explicabilidad acompañada de la métrica de fiabilidad, lo que permite evaluar no solo si el modelo clasifica correctamente, sino también si las regiones del tejido en las que se basa su decisión son clínicamente coherentes, lo cual es un requisito imprescindible para que el sistema pueda ser útil como herramienta de apoyo al diagnóstico médico real.

4.2.Marco teórico

Redes neuronales convolucionales (CNN)

Las redes neuronales convolucionales son la arquitectura de referencia para tareas de clasificación de imágenes. Fueron introducidas por Le Cun (Yann LeCun, 1998) y su adopción masiva se produjo tras el trabajo 'ImageNet Classification with Deep Convolutional Neural Networks' de Alex Krizhevsky, Ilya Sutskever y Geoffrey E. Hinton (Alex Krizhevsky, 2012). En este trabajo se demostró que las CNNs podrían superar con gran margen a los métodos tradicionales de visión por computador en el desafío planteado por ImageNet (Olga Russakovsky, 2015). A diferencia de las redes completamente conectadas, las CNNs explotan la estructura espacial de las imágenes mediante tres operaciones fundamentales que son la convolución, que aplica filtros sobre la imagen para extraer mapas de características locales; el pooling, que reduce la dimensión espacial de esos mapas preservando la información más relevante; y la normalización por batch, que estabiliza el entrenamiento acelerando la convergencia.

Lo que hace a las CNNs especialmente adecuadas para imágenes médicas es su capacidad de aprender representaciones jerárquicas. Las capas iniciales aprenden características de bajo nivel como bordes o gradientes de color, mientras que las capas más profundas aprenden patrones de alto nivel como la arquitectura del tejido y la disposición de las células. Se ha demostrado que las CNNs han superado de forma consistente a todos los métodos de extracción manual de características en clasificación de imágenes histopatológicas de cáncer, por lo que se establecen como la técnica más dominante en el área (Chetan L. Srinidhi, 2021). También se ha demostrado en el paper original del dataset BreakHis que con una CNN sencilla basada en AlexNet se superaba a los mejores descriptores textuales manuales disponibles en ese momento, lo que estableció el punto de partida de la investigación sobre la clasificación de los tumores de mama malignos (Fabio A. Spanhol, 2016).

Transfer learning

El transfer learning es la estrategia que permite adaptar un modelo pre entrenado en un dominio de datos masivo a un dominio distinto con datos limitados aprovechando el conocimiento visual ya adquirido en lugar de aprender desde cero (Jason Yosinski, 2014).

En el contexto de este proyecto, los modelos seleccionados se han pre entrenado sobre ImageNet que es una base de datos de más de un millón de imágenes en 1.000 categorías, lo que permite haber aprendido jerarquías de características visuales que van desde bordes y texturas en las capas iniciales hasta estructuras morfológicas complejas en las capas más profundas (University, 2021). Estas representaciones de bajo nivel son transferibles al dominio médico, donde la detección de bordes celulares, texturas del tejido y patrones morfológicos son las características relevantes para la clasificación de tipos de carcinomas.

La aplicación de Transfer Learning en imágenes médicas está ampliamente respaldada. Se ha demostrado que el fine tuning de redes pre entrenadas supera de forma consistente al entrenamiento desde cero en imágenes médicas con datasets limitados o reducidos y que el número de capas descongeladas tiene un impacto directo en la capacidad de adaptación al nuevo dominio (Nima Tajbakhsh, 2017). En algunos específicos trabajos sobre el dataset BreaKHis (Musa Adamu Wakili, 2022; Chetan L. Srinidhi, 2021), se confirma esta tendencia concluyendo que el transfer learning es el enfoque dominante en clasificación de imágenes de cáncer de mama, siendo adoptado de forma prácticamente universal en los proyectos más recientes de este ámbito.

En este proyecto se aplica transfer learning mediante fine-tuning parcial, descongelando un número variable de capas del backbone, o columna vertebral del modelo, de la arquitectura sobre un conjunto fijo de capas personalizadas añadidas a la cabeza del modelo. Esta decisión se debe a que, como ya se ha mencionado previamente, las primeras capas de una CNN aprenden las características genéricas como los bordes, las texturas y los gradientes de color, las cuales son útiles en medicina, mientras que las capas más profundas aprenden las representaciones más específicas del dominio de ImageNet que necesitan ser reajustadas al dominio médico. El número óptimo de capas a descongelar se determina mediante el grid search empleado, lo cual permite que el propio proceso de entrenamiento identifique el equilibrio adecuado entre la transferencia y la adaptación para cada arquitectura.

InceptionV3

Inception V3 fue propuesta como evolución de la arquitectura GoogleLeNet (Christian Szegedy, 2014), incorporando módulos Inception que aplican convoluciones de múltiples tamaños de kernel en paralelo, 1x1, 3x3 y 5x5, sobre el mismo mapa de activación

para capturar de forma simultánea patrones a distintas escalas espaciales. Esta característica la hace especialmente adecuada para imágenes médicas, ya que la información diagnóstica relevante aparece a múltiples escalas, desde el nivel celular hasta el nivel de la arquitectura de tejidos. InceptionV3 requiere que las imágenes de entrada tengan un tamaño de 299x299 píxeles, lo cual es una resolución superior a al utilizado en otras arquitecturas como DenseNet y Resnet (Christian Szegedy V. V., 2015). Esto ayuda a preservar la información espacial de las imágenes originales del dataset antes del redimensionado ya que no hay que hacer tanta comprensión del tamaño.

La aplicación en el ámbito del cáncer de mama de esta arquitectura está sólidamente respaldada, ya que se ha demostrado que, adaptada mediante Transfer Learning, obtiene resultados competitivos en la clasificación de estas imágenes con múltiples magnificaciones (Meena Prakash Ramasamy, 2024). Además, se han entrenado InceptionV3 y Xception con augmentación en tiempo real sobre el dataset BreaKHis y se obtuvo un accuracy del 94% con InceptionV3, superando a la CNN base en un 9% (Rishi Rai, 2021). Estos buenos resultados muestran el gran rendimiento del modelo apoyando su uso en este proyecto.

ResNet101V2

ResNet introdujo las conexiones residuales como solución al problema de la degradación del gradiente en redes muy profundas (Kaiming He, 2015).

ResNet101V2 es una variante mejorada que aplica la normalización por batch antes de la convolución en lugar de después, lo que mejora la estabilidad del entrenamiento y la capacidad de generalización. Con 101 capas, ofrece una mayor capacidad de representación que ResNet50 manteniendo una complejidad computacional todavía aceptable (Karabulut, 2023).

La familia ResNet es una de las más usadas en clasificación de imágenes de cáncer de mama. Se demostró su eficacia en medicina, independientemente de la magnificación de las imágenes (Neslihan Bayramoglu, 2016). En este contexto, para el dataset BreaKHis con tipos de tumores malignos, se aplicó la arquitectura ResNet con configuraciones de Transfer Learning multietapa combinadas con otros optimizadores, obteniendo resultados competitivos frente a otras arquitecturas (Gelan Ayana, 2022). Su inclusión en este proyecto se debe a que las conexiones residuales garantizan que la información original de las capas tempranas, las cuales son relevantes para la detección de estructuras celulares finas, no

desaparezca en las capas más profundas ya que en imágenes médicas aportan información relevante debido a la importancia de los detalles morfológicos de cara al correcto diagnóstico.

DenseNet121

DenseNet121 fue propuesta en el paper como una arquitectura basada en conexiones densas, es decir, donde cada capa recibe como entrada los mapas de activación de todas las capas anteriores del bloque y transmite los suyos a todas las posteriores. Esto se traduce en dos ventajas clave para el problema que se aborda en este proyecto. Por un lado, la reutilización de características a lo largo de toda la red reduce de forma drástica el número de parámetros respecto a arquitecturas que tienen una profundidad similar, mitigando así el riesgo de overfitting en datasets de tamaño reducido. Por otro lado, el flujo de gradientes a través de múltiples caminos durante el backpropagation facilita el entrenamiento de redes profundas, como esta, sin degradación del gradiente (Gao Huang, 2018).

El uso de esta red en el cáncer de mama sobre el dataset BreaKHis bastante común. Como la aplicación de DenTnet, basado en DenseNet, alcanzando un 99.28% de accuracy en clasificación de las imágenes (Musa Adamu Wakili, 2022). También se demostró que DenseNet121 pre entrenada en ImageNet y adaptada mediante fine tuning supera a VGG16 y ResNet50 en el mismo dataset (Xia Li, 2020). Además, se señaló que las conexiones densas de DenseNet son especialmente ventajosas en imágenes médicas, donde la información de textura y estructura celular presente en capas tempranas es relevante también para las decisiones de clasificación de capas profundas (Chetan L. Srinidhi, 2021).

Técnicas de explicabilidad

El concepto de explicabilidad en modelos de Deep Learning, también denominado XAI (Explainable Artificial Intelligence), hace referencia a cualquier técnica que permita comprender el proceso de decisión interno de un modelo, haciendo transparente información de la entrada que ha determinado la salida (IBM, s.f.). Además, se ha señalado que la necesidad de explicabilidad en modelos médicos no es únicamente ética sino también

regulatoria, ya que los sistemas de apoyo al diagnóstico deben poder justificar sus decisiones para ser certificados y adoptados en los entornos clínicos reales (Deepshikha Bhati, 2024).

Las técnicas de explicabilidad para CNNs pueden clasificarse en dos grandes categorías. Por un lado, están las técnicas globales que buscan entender el comportamiento general del modelo a lo largo de todo el dataset, Y, por otro lado, se tienen las técnicas locales, que son las relevantes para este trabajo, y son las que explican la decisión del modelo para una imagen concreta (Bas H.M. van der Velden, 2022). Dentro de esta segunda categoría de técnicas de explicabilidad, la familia de métodos basados en mapas de activación de clase (CAM) es la más adoptada en imágenes médicas (Ahmad Chaddad, 2023).

Grad-CAM++

Grad-CAM++ fue propuesta como una extensión mejorada de Grad-CAM (Ramprasaath R. Selvaraju, 2019). La diferencia fundamental entre ambas está en cómo se ponderan los gradientes para construir el mapa de calor. Grad-CAM utiliza la media global de los gradientes de cada canal de la última capa convolucional, lo que puede llevar a una localización imprecisa cuando la clase de interés aparece en múltiples regiones de la imagen o cuando las activaciones están distribuidas de forma no uniforme. Grad-CAM++, como mejora, introduce una ponderación píxel a píxel de esos gradientes mediante un sistema de pesos basado en derivadas de segundo y tercer orden, lo que producen mapas con mayor resolución espacial y mejor capacidad de localización (Aditya Chattopadhyay, 2018). En imágenes médicas, donde las regiones relevantes para el diagnóstico pueden ser pequeñas, múltiples y distribuidas a lo largo del tejido, esta mejora es crítica para que el mapa sea realmente informativo.

En clasificación de imágenes cáncer de mama se hizo uso de Grad-CAM++ directamente sobre EfficientNetV2 para el diagnóstico de cáncer de mama mediante mamografías, demostrando que los mapas generados ofrecen a los radiólogos información visual interpretable sobre las regiones de interés que determinan la predicción del modelo (Ameen, 2025). También se propuso BCaXAI, un sistema de diagnóstico explicable de cáncer de mama basado en Inception-ResNet V2 con Grad-CAM integrado, demostrando que la incorporación de técnicas de explicabilidad visual proporciona a los radiólogos

información sobre el proceso de decisión del modelo, fomentando así la confianza clínica en el sistema de IA (Fatma M. Talaat, 2024).

Métricas de clasificación

Para evaluar un modelo de clasificación, es fundamental analizar todas las métricas correspondientes, ya que, en este tipo de problemas, y más aún en el contexto médico, cada métrica aporta una perspectiva distinta del rendimiento del modelo (Steven A. Hicks, 2022). Por ello, en este proyecto, se utilizan varias métricas de forma complementaria entre las que se encuentra el accuracy o exactitud, la precisión, el recall, el F1-score, macro average, weighted average, la matriz de confusión y la curva ROC-AUC (Opitz, 2024).

- **La matriz de confusión**

Es la base de la mayoría de las métricas de clasificación, ya que resume cuántos ejemplos de cada clase han sido clasificados correctamente y cuántos han sido confundidos con otras clases. En un problema multiclase con K clases, puede representarse como una matriz KxK donde cada elemento indica el número de muestras cuya clase real es la fila y cuya clase predicha es la columna. Los valores en la diagonal principal corresponden a los aciertos, mientras que los valores fuera de la diagonal principal representan los errores realizados en la tarea de clasificación. La principal ventaja de esta métrica es que permite ver de forma rápida entre qué clases concretas se producen las confusiones, lo cual es especialmente útil en problemas médicos o en clases visualmente parecidas (Marina Sokolova, 2009).

- **Accuracy**

Esta métrica mide la proporción total de predicciones correctas sobre el total de muestras evaluadas, (ver Anexo 8).

En una tarea de clasificación multiclase, se representa como la división de los verdaderos positivos de la clase entre el número total de ejemplos. Es una métrica útil e intuitiva que ayuda a obtener una visión global del modelo, pero puede resultar engañosa cuando existe desbalanceo entre las clases, ya que un buen resultado global no garantiza un buen comportamiento en todas ellas (Castillon, 2024).

- **Precision**

Esta métrica mide qué proporción de las muestras predichas como pertenecientes a una clase realmente pertenecen a esa clase (ver Anexo 8).

Una precisión alta indica que, cuando el modelo asigna una imagen a una clase, esa predicción suele ser correcta. Por tanto, esta métrica refleja, en otras palabras, la fiabilidad de las predicciones positivas del modelo (Cyril Goutte, 2005).

- **Recall**

A esta métrica se le llama también sensibilidad y mide la capacidad del modelo para identificar correctamente las muestras reales de una clase (ver Anexo8).

Dicho de otra forma, esta métrica indica cuántos ejemplos reales de una clase consigue detectar el modelo. Es una métrica especialmente importante cuando se quiere minimizar los casos que el sistema deja sin identificar (Powers, 2011).

- **F1-score**

Esta métrica combina precisión y recall en una sola medida (ver Anexo 8).

Su principal utilidad es que penaliza los casos en los que una de las dos métricas es alta y la otra baja. Por ello, el F1-score se utiliza cuando se quiere una medida más equilibrada del rendimiento por clase y no solo saber el grado de acierto general del modelo (Cyril Goutte, 2005).

- **Macro Average**

Esta métrica se obtiene calculando primero la métrica de cada clase y después haciendo la media aritmética entre todas ella (ver Anexo 8).

En esta, Mc puede ser la precisión, el recall o el F1-score de la clase c. Este promedio da el mismo peso a todas las clases, por lo que resulta útil cuando se quiere comprobar si el modelo se comporta de manera equilibrada, incluso en las clases minoritarias (GeeksforGeeks, 2025).

- **Weighted Average**

Esta métrica también promedia las métricas por clase, pero a diferencia de la anterior, esta las pondera según el support o la cantidad de muestras reales que hay de cada clase (ver Anexo 8). Para ello sigue esta fórmula:

Esto hace que las clases con más observaciones influyan más en el resultado final. Es una medida útil para presumir del rendimiento global del clasificador, aunque su principal limitación es que puede ocultar un mal comportamiento en clases poco representadas si las clases mayoritarias están bien clasificadas (GeeksforGeeks, 2025).

- **Curva ROC**

Esta curva representa la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos en distintos umbrales de decisión (ver Anexo 8).

La curva ROC permite analizar la capacidad discriminativa del modelo sin fijar un único umbral de clasificación. De esta forma, no solo muestra si el modelo acierta, sino también cómo cambia su comportamiento cuando se modifica el criterio de decisión (Fawcett, 2006).

- **AUC (Area Under the Curve)**

Es el área bajo la curva ROC y resume en un único valor la capacidad discriminativa del modelo (ver Anexo 8).

Cuanto mayor es el AUC, mayor es la capacidad del modelo para distinguir entre clases (David J. Hand, 2001).

Métricas de Grad-CAM++: Fidelidad

Esta métrica mide cuánto cae la confianza del modelo cuando se enmascaran los píxeles más activados del mapa de calor, validando así que las zonas señaladas son genuinamente determinantes para la clasificación y no artefactos visuales. Además, se propuso esta evaluación en el propio paper original de Grad-CAM++ como métrica objetiva para comparar la calidad de los mapas generados frente a los de Grad-CAM y otros métodos, argumentando que una explicación fiel debe producir una caída significativa de confianza cuando se ocultan las regiones que señala (Aditya Chattopadhyay, 2018). En el contexto de imágenes médicas con CNNs, se introdujo un marco de evaluación cuantitativa que combina precisión de localización, fidelidad basada en perturbación y consistencia de la explicación para valorar la fiabilidad de Grad-CAM en clasificación de cáncer de pulmón en imágenes CT (tomografía computarizada), confirmando que la caída de confianza al tapar regiones activadas es una medida robusta y reproducible de la calidad explicativa del modelo (Panboonyuen, 2026).

4.3.Desarrollo de la estrategia de análisis

La estrategia de análisis planteada se ha llevado a cabo aplicando las técnicas definidas mediante una metodología basada en la configuración de los pesos de las clases, la adaptación de las imágenes a los requisitos de entrada de cada arquitectura, la implementación de Grad-CAM++ y el diseño del flujo de entrenamiento, para finalmente, analizar la mejor combinación de cada modelo.

Una cosa importante a tener en cuenta es el uso de Google Colab para el desarrollo, ya que, como se ha explicado anteriormente, permite trabajar con altas capacidades de RAM y GPU, lo que resulta muy útil en tareas pesadas como es el entrenamiento de redes neuronales convolucionales profundas. Además, para acelerar el entrenamiento, se ha optado por separar la experimentación en tres notebooks independientes, uno por cada arquitectura. Esto se debe a que se simplifica la gestión de la memoria RAM y se facilita la ejecución en paralelo de las diferentes arquitecturas con el fin de reducir el tiempo de entrenamiento de todos los modelos.

4.3.1. Configuración de los pesos

Como se ha comentado en la sección de Ingeniería del Dato, aunque se han aplicado las técnicas de data augmentation con el objetivo de reducir el desequilibrio de clases, este sigue existiendo, pero en menor medida, ya que, tras aplicar estas técnicas, la diferencia entre la clase mayoritaria y las minoritarias a pasado de cerca de 2000 a alrededor de 400 imágenes. Por ello, para que esta pequeña diferencia no tenga un efecto negativo en el entrenamiento de los modelos, se ha aplicado una ponderación automática de los pesos.

El objetivo de este método es que las clases con menos muestras o imágenes reciban un peso mayor en la función de pérdida, de modo que los errores sobre ellas penalicen más que los cometidos en la clase mayoritaria. De esta forma, se logra reducir el sesgo del modelo hacia la categoría más frecuente, lo cual es especialmente importante en problemas de clasificación de imágenes médicas (Mabrouka Salmi, 2024).

Tras aplicar las transformaciones de data augmentation, clase ductal carcinoma presenta un número mayoritario de imágenes con 2415, mientras que lobular carcinoma, mucinous carcinoma y papillary carcinoma son minoritarias con 1887, 1907 y 1892, respectivamente. Esto se ve reflejado en los pesos asignados por la ponderación automática a cada clase.

Tabla 7. Pesos automáticos de las clases

Clases	Pesos automáticos
ductal_carcinoma	0.8353
lobular_carcinoma	1.0713
mucinous_carcinoma	1.0617
papillary_carcinoma	1.0782

Fuente: Elaboración propia con Python

4.3.2. Tamaño de la imagen de entrada (input)

Como se ha comprobado en el análisis descriptivo, los tamaños de las imágenes de la base de datos BreaKHis son de 700x460, aunque hay un reducido número de imágenes que presentan unas dimensiones de 700x456 píxeles. Por ello, como se ha explicado, se aplica el redimensionamiento de cara al entrenamiento del modelo, ya que las imágenes se deben ser un input válido en cada una de las arquitecturas CNN.

Por definición, en DenseNet121 (TensorFlow, 2024) y ResNet101V2 (TensorFlow, ResNet101V2, 2024) se requiere un tamaño de entrada de 224x224, mientras que en InceptionV3 (Keras, InceptionV3, s.f.) se utiliza un input de 299x299. Aunque estas arquitecturas tengan tamaños de inputs distintos, se podrán aplicar los redimensionamientos correspondientes a cada uno. Aprovechando que se va a entrenar cada modelo en un notebook distinto, se aplicará el tamaño adecuado en los generadores respectivos. De esta manera, los generadores en los notebooks de ResNet101V2 y DenseNet121 mantendrán el parámetro de target size con (224,224), mientras que en el notebook de InceptionV3 el parámetro tendrá un valor de (299,299). Así, al mantener el tamaño estándar de entrada para cada modelo, se preserva la mayor compatibilidad posible con el preentrenamiento.

4.3.3. Número de capas de las arquitecturas

Además de tamaño de entrada que requieren las arquitecturas es importante tener en cuenta las características de cada una, como el número de capas. Conviene distinguir entre la profundidad original indicada en la definición de cada modelo y el número total de capas que muestra Keras, ya que no representan exactamente lo mismo. Esto se debe a que Keras también cuenta capas auxiliares, como las de batch normalization, activación o concatenación, mientras que en originalmente la profundidad suele referirse a la estructura principal del modelo.

Por ello, el número total de capas no debe entenderse por sí solo como una medida directa de complejidad. En DenseNet121, la complejidad está muy relacionada con sus conexiones densas y a la reutilización de características (Gao Huang, 2018); en ResNet101V2, al uso de bloques residuales (Karabulut, 2023); y en InceptionV3, al diseño de sus módulos multiescala, más que a una profundidad lineal concreta (Shah, 2022).

Tabla 8. Características de las arquitecturas pre entrenadas

Arquitectura	Capas por definición	Capas en Keras	Idea principal de la arquitectura
InceptionV3	48	311	Módulos multiescala con convoluciones paralelas
ResNet101V2	101	377	Bloques residuales
DenseNet121	121	427	Conexiones densas y reutilización de características

Fuente: (Gao Huang, 2018; Karabulut, 2023; Shah, 2022)

4.3.4. Param Grid

Tras conocer el funcionamiento de cada arquitectura, se podrá configurar mediante trasfer learning con los parámetros adecuados.

- **Learning rate**

En Transfer Learning el backbone, es decir, la red neuronal base pre entrenada con las imágenes de ImageNet que aprende a extraer las características de las imágenes, ya tiene los pesos optimizados para reconocer patrones visuales generales. Por ello, un learning rate alto destruiría dichas representaciones ya aprendidas y es por eso por lo que se han escogido dos valores pequeños para el fine-tuning. Además, se ha demostrado que las capas profundas de una CNN pre entrenada contienen características muy específicas del dominio y que el fine tuning requiere tasas de aprendizaje pequeñas para poder preservarlas (Jason Yosinski, 2014). En la misma línea, se ha validado que un learning rate entre el rango de 1e-4 y 1e-5 es el óptimo para aplicar fine tuning en modelos con datasets de dominio específico, como es el caso del dataset de este proyecto (Simon Kornblith, 2019). En el contexto médico en concreto, en el paper se ha demostrado que en Transfer Learning para imágenes médicas, valores de la tasa de aprendizaje superiores a 1e-3 producen degradación del rendimiento en la clasificación (Maithra Raghu, 2019). También se ha establecido que el learning rate es el

hiperparámetro más crítico en la transferencia entre dominios con distribuciones distintas, como es el caso entre ImageNet y los problemas basados en datasets de imágenes médicas (Sinno Jialin Pan, 2009).

- **Epochs con EarlyStopping patience**

Se ha establecido un límite 60 épocas o epochs, ya que representan un valor suficientemente alto para que el modelo converja en datasets de tamaño medio. El mecanismo de EarlyStopping hace que en la práctica el número real de epochs sea mucho menor. Esta se propuso como una técnica de regularización y se demostró que detener el entrenamiento cuando la pérdida de la validación deja de mejorar durante un numero de epochs es equivalente a una regularización L2 (Prechelt, 1997). Es recomendada una paciencia de entre 5 y 10 épocas para evitar paradas prematuras por fluctuaciones del gradiente (Ian Goodfellow, 2016). En este caso se ha escogido una paciencia de 7 con el objetivo de evitar una parada muy tardía pero también una parada temprana ya que al tratarse de un dominio muy específico los modelos pueden necesitar más tiempo para aprender las características específicas de las imágenes. Además, la decisión de utilizar 60 épocas se ve apoyada por el paper original del dataset escogido, BreKHis, donde se usaron configuraciones de entre 50 y 100 epochs con parada temprana para evitar overfitting dado que el tamaño del dataset es considerado pequeño-mediano (Fabio A. Spanhol, 2016).

- **Optimizadores**

La elección entre Adam y SGD con momentum es uno de los debates más activos en optimización de redes neuronales profundas. Adam se propuso como optimizador adaptativo que ajusta de forma automática el learning rate por parámetro, dando lugar a una convergencia más rápida que SGD en la mayoría de las tareas (Diederik P. Kingma, 2015). Sin embargo, se ha demostrado de forma empírica que los optimizadores adaptativos como Adam tienden a generalizar peor que SGD con momentum en tareas de clasificación de imágenes. Esto es porque SGD encuentra mejores mínimos, aunque converja más lento (Runzhe Wang, 2024). También se ha propuesto AdamW como mejora de Adam con decoupled weight decay, y en el análisis comparativo se observó que SGD sigue siendo competitivo en fine tuning de CNNs (Ilya Loshchilov, 2019). Pero, tras algunas comparativas, se concluyó que ningún optimizador domina en todos los escenarios (Ruder, 2017), lo que justifica la decisión de incluir ambos en el grid de parámetros para este proyecto. En el contexto específico del dataset BreaKHis utilizado en este proyecto, se

utilizó SGD con momentum de 0.9 como optimizador principal en la clasificación de las imágenes con CNNs, lo cual refuerza a inclusión de SGD en el grid de parámetros (Fabio A. Spanhol, 2016). Además, en aplicaciones médicas más ampliamente, se ha demostrado que tanto Adam como SGD aparecen con frecuencia similar en los mejores modelos (Geert Litjens, 2017).

- **Capas Entrenables**

La selección del número de capas a descongelar en fine tuning es uno de los aspectos más estudiados en Transfer Learning para imágenes médicas. Se ha demostrado que las primeras capas de una CNN aprenden características universales como los bordes o las texturas, las cuales son transferibles entre dominios, mientras que las últimas capas aprenden representaciones específicas del dominio de entrenamiento (Jason Yosinski, 2014). Asimismo, esto se ha analizado específicamente en imágenes médicas y se concluyó que descongelar solo las últimas capas es suficiente cuando el dataset objetivo es pequeño, ya que descongelar capas tempranas con pocos datos provoca overfitting (Maithra Raghu, 2019). En este contexto, también se ha estudiado el número óptimo de capas a entrenar en relación con la clasificación de imágenes médicas con datasets limitados y se observó que descongelar entre el 10% y el 30% de las últimas capas maximiza el rendimiento (Nima Tajbakhsh, 2017). En el contexto del cáncer de mama concretamente, se ha demostrado el que fine tuning parcial de las últimas capas supera consistentemente al entrenamiento completo del backbone cuando el dataset tiene menos de 10.000 imágenes por clase, lo cual es el caso del dataset seleccionado para este proyecto (Fabio A. Spanhol, 2016; (Heikkilä, 2016). También se ha demostrado que las representaciones de las capas intermedias son las más transferibles (Jeff Donahue, 2013), por lo que, en este proyecto, se ha decidido descongelar un número moderado de capas finales, entre 10 y 30.

- **Dropout**

En la definición de dropout se demostró que valores entre 0.2 y 0.5 son los más efectivos para capas densas, siendo 0.5 el valor que maximiza la regularización sin destruir información útil (Nitish Srivastava, 2014). Por ello, en el grid de parámetros de este proyecto se ha aplicado el valor de 0.5 para el dropout. Además, valores de dropout agresivos son útiles para para imágenes con clases visualmente similares como lo son el carcinoma ductal y el lobular, ya que tienen un riesgo de overfitting especialmente alto. También se extendió el análisis de dropout como aproximación bayesiana y se identificó que valores entre 0.3 y

0.5 son óptimos para tareas de clasificación de imágenes médicas con incertidumbre alta, es decir, donde las clases son similares y no es tan sencillo diferenciar las clases (Yarin Gal, 2016). Esto último es lo que sucede con las imágenes del dataset del proyecto, por lo que en el grid de parámetros se aplica tanto 0.3 como 0.5. En este contexto, con la aplicación de droput en clasificación de imágenes médicas, similares a las del dataset BreaKHis, se ha observado que el valor de 0.5 en las capas densas mejora la generalización en conjuntos de test independientes (Dinggang Shen, 2017). También se ha demostrado que para el análisis de visualización de CNNs un dropout más agresivo en las capas finales fuerza al modelo a distribuir la representación entre más neuronas, lo que resulta en activaciones más fuertes (Matthew D. Zeiler, 2013). De esta manera, se descartaron valores por debajo de 0.3, ya que en la clasificación de carcinomas con datasets aumentados, como es en el caso de este proyecto, las regularizaciones demasiado suaves no compensan la baja variabilidad real de las imágenes generadas por augmentation (Fabio A. Spanhol, 2016).

Con la aplicación de estos parámetros, se plantea el siguiente param grid para la configuración de los modelos:

Tabla 9. Param Grid

Learning rate	Epochs	Optimizador	Capas entrenables	Dropout
0.0001	60	Adam	10	0.3
0.00001		SGD	20	0.5
			50	

Fuente: Elaboración propia con Python

Estos parámetros se combinarán entre sí en todas las arquitecturas definidas con el objetivo de encontrar la configuración que ofrezca el mejor rendimiento.

4.3.5. Entrenamiento de los modelos

El entrenamiento se organiza como una combinación de un grid search sobre las combinaciones de hiperparámetros definidas en el param grid y parámetros fijos, como la función de perdida, la función de clasificación, la función de activación y otras funciones de control. Esto es similar en todas las arquitecturas que se han seleccionado, InceptionV3, ResNet101V2 y DenseNet121. Esto se de debe a que, aunque sean diferentes en su

arquitectura interna y la forma en la que procesan y extraen las características de los datos, todas siguen un mismo esquema de entrenamiento. Esto ocurre porque el enfoque del entrenamiento se basa el transfer learning, donde cada modelo se utiliza como un extractor de características pre entrenado al que posteriormente se le añade una cabeza de clasificación adaptada al problema. Así, el flujo del entrenamiento y las funciones utilizadas se mantienen constantes permitiendo comparar el rendimiento de las distintas arquitecturas bajo las mismas condiciones.

De esta manera, para cada combinación del param grid se inicializa el flujo de entrenamiento con un nuevo modelo en cada arquitectura. Para ello, se limpia la sesión de TensorFlow para reducir el consumo de los recursos de la RAM, se carga el backbone pre entrenado sobre ImageNet, se añade la nueva cabeza de clasificación y se entrena. Esta lógica garantiza que cada combinación se entrene desde un estado comparable y evita que queden restos en memoria de ejecuciones anteriores.

Durante el entrenamiento, el modelo utiliza la función de pérdida categorical crossentropy, que se ha escogido porque se trata de un problema de clasificación multiclase de etiqueta única y, además, los generadores se han configurado con el modo de la clase categorical, por lo que las etiquetas se representan en formato one hot. Esta función calcula la pérdida una la fórmula (ver Anexo 8) donde, y_c es la etiqueta real codificada one-hot e $\hat{y}_c$ es la probabilidad predicha para la clase c. Esta pérdida está específicamente diseñada para comparar distribuciones objetivo y distribuciones predichas en problemas multiclase (GeeksforGeeks, 2025).

También se utiliza la capa de salida softmax, ya que transforma los logits del modelo en una distribución de probabilidad sobre las K clases (GeeksforGeeks, 2025) (ver Anexo 8).

De esta manera la predicción final puede interpretarse como una probabilidad por clase y ser compatible con categorical crossentropy. En otras palabras, la combinación softmax con categorical crossentropy es la configuración estándar y más coherente para las tareas de clasificación multiclase (Anqi Mao, 2023).

Durante este proceso, la cabeza del modelo se modifica porque los backbones preentrenados se cargan sin la cabeza de clasificación original usada en ImageNet. Esto permite reutilizar el extractor de características aprendido en ImageNet y sustituir la salida por una cabeza adaptada al problema específico planteado, que en este caso tiene cuatro

clases e imágenes muy diferentes a las de la base de datos de ImageNet. Esta estrategia es la forma más habitual de hacer fine-tuning cuando el objetivo no coincide con las 1.000 clases originales del preentrenamiento (TensorFlow, Transferir el aprendizaje y la puesta a punto, 2022).

Esta nueva cabeza se compone de GlobalAveragePooling2D, dos capas densas con activación ReLU, capas de Batch Normalization y Dropout y la capa final de softmax. El uso de Global Average Pooling reduce mucho más el número de parámetros en comparación con un aplanado completo con fully conected y, además, es menos propenso al overfitting que las capas totalmente conectadas tradicionales (Min Lin, 2014).

Las capas densas intermedias con activación ReLU permiten aprender una transformación no lineal del espacio de características extraído por el backbone (ver Anexo 8).

Su uso es muy común, ya que evita la saturación típica de funciones como sigmoide o tanh, además de favorecer un entrenamiento más estable en redes profundas (GeeksforGeeks, 2025).

Las capas de Batch Normalization se introducen para estabilizar el entrenamiento, reducir la sensibilidad y facilitar la convergencia. Se ha demostrado que esta técnica acelera el entrenamiento y, en algunos casos, también aporta un efecto regularizador (Sergey Ioffe, 2015). Por otra parte, el Dropout se utiliza, como se ha explicado anteriormente, para reducir la coadaptación excesiva entre neuronas y ayudar a reducir el overfitting, algo crítico cuando se adapta una red profunda a un dataset médico relativamente pequeño (Nitish Srivastava, 2014).

Además, para llevar el control del entrenamiento se utilizan dos callbacks. El primero es EarlyStopping, que lo detiene cuando la métrica monitorizada deja de mejorar durante un número fijo de épocas. En el notebook, a lo largo del entrenamiento se monitoriza la métrica "val_loss" con paciencia de 7 epochs y la restauración de los mejores pesos (Keras, s.f.). Esta lógica es coherente porque regulariza y evita el sobreajuste basándose en las métricas del set de validación (Prechelt, 1997).

El segundo callback es ReduceLROnPlateau, que reduce la tasa de aprendizaje cuando la métrica de validación entra en una meseta (GeeksforGeeks, 2021). Al igual que en el EarlyStopping, también se monitoriza la métrica “val_loss”, con una reducción de 0.5, una paciencia de 3 epochs y un learning rate mínimo de 10e-7. Este callback se usa

principalmente cuando el aprendizaje se estanca, ya que bajar el learning rate permite realizar ajustes más detallados de los pesos sin cortar todavía el entrenamiento. Esta estrategia se plantea como un mecanismo útil cuando la mejora se ralentiza (Keras, s.f.).

De esta manera, se establece un flujo completo y común en el que la extracción, transformación y clasificación de las imágenes se integran en un proceso optimizado y controlado, donde todas las configuraciones se evalúan bajo las mismas condiciones, permitiendo comparar su rendimiento y seleccionar la más adecuada.

4.3.6. Análisis del mejor modelo

Una vez terminado el flujo de entrenamiento de todos los modelos, se construye un dataframe con los resultados de todas las ejecuciones y se ordena por el valor del accuracy en el set de validación, es decir, cuanto más alto sea el valor, mejor será la combinación de parámetros. Con esto, se selecciona, para cada arquitectura, la mejor configuración y se carga el modelo guardado para hacer un análisis de sus métricas más detallado, el cual se explicará más adelante.

Posteriormente, al mejor modelo de cada arquitectura se le aplicará Grad-CAM++ sobre las predicciones tanto correctas como incorrectas de cada una de las clases, y se visualizarán los mapas de calor junto con la fidelidad por clase para escoger la mejor combinación de modelo + Grad-CAM++.

4.3.7. Grad-CAM++

Para finalizar, se implementa el algoritmo de Grad-CAM++ mediante cuatro funciones, mostrando así el procedimiento completo para que el modelo no quede como una caja negra. Además, al implementarlo de forma manual, permite un mayor control sobre qué capa se usa, cómo se calculan los gradientes, cómo se superpone el mapa a la imagen original y cómo se cuantifica la fidelidad.

Aunque se ejecutan después del entrenamiento, para aplicarse únicamente al modelo con la mejor configuración de cada arquitectura, estas funciones se definien antes para dejar preparado desde el principio el procedimiento de explicabilidad que se aplicará. De esta forma, el análisis visual puede realizarse de forma inmediata en el notebook, ya que tras las métricas del modelo se observará inmediatamente la aplicación de Grad-CAM++.

La primera función, **‘get_last_conv_layer’**, busca la última capa convolucional del modelo. Esto es importante porque Grad-CAM++ se aplica sobre los mapas de activación que generan las capas convoluciones, específicamente sobre los más profundos ya que son los más ricos y los que contienen información espacial con alto nivel semántico. Esta selección se hace de forma automática para hacer el código totalmente reutilizable para cualquiera de las arquitecturas que se utilizan (Ramprasaath R. Selvaraju, 2019).

La segunda función, **‘gradcam_plus_plus’**, implementa el núcleo matemático del algorimo. Grad-CAM++ construye los mapas de activación a partir de la última capa convolucional y de los gradientes de la clase predicha respecto a dicha capa. A diferencia de Grad-CAM, este utiliza una ponderación basada en derivadas de segundo y tercer grado, lo que hace que la localización de la evidencia visual sea mejor, especialmente cuando esta evidencia está distribuida (Aditya Chattopadhyay, 2018) La formulación general de esta función (ver Anexo 8) define que A^k es el mapa de activación del canal k y w_k^c es el peso de ese canal para la clase c. En Grad-CAM++, esos pesos se calculan a partir de coeficientes α_{ij}^{kc} y gradientes locales (ver Anexo 8).

Por tanto, implementar esta función manualmente cobra sentido, ya que el método no se reduce a una simple llamada visual, sino que exige el acceso a las activaciones internas y gradientes de distinto orden (Aditya Chattopadhyay, 2018).

La tercera función, **‘apply_gradcam’**, se encarga de redimensionar el mapa, convertirlo en un mapa de calor y sobreponerlo sobre la imagen original. Esta función no altera el razonamiento del método, sino que controla la representación visual. Tener este método separado hace que el procedimiento sea más claro y permite la fácil reutilización del pipeline para las otras arquitecturas.

La cuarta función, **‘calcular_fidelidad’**, introduce una parte crítica del análisis, la medida cuantitativa de fidelidad. En ella se ‘tapa’ o enmascara la zona más activada del mapa y se observa cuánto cae la confianza del modelo. Si la caída es alta, la explicación es más coherente con la decisión real del modelo. Esta función se ha implementado de forma explícita porque en imágenes médicas no basta con mostrar un heatmap visualmente convincente, sino que es importante evaluar también si realmente se señalan las regiones decisivas (Panboonyuen, 2026).

4.4.Métricas de evaluación

Para escoger el modelo con la mejor configuración de cada arquitectura se ha realizado una evaluación del rendimiento de cada uno mediante las métricas correspondientes a los problemas de clasificación, que se han explicado anteriormente. Para cada modelo en cada arquitectura se realizado una evaluación en dos partes:

1. Primero se han analizado las métricas de clasificación para evaluar la capacidad del modelo para distinguir correctamente entre los distintos tipos de cáncer de mama malignos.
2. Después se ha analizado el efecto de Grad-CAM++ en el mejor modelo mediante la métrica de fidelidad, para evaluar la calidad y fiabilidad de las explicaciones visuales.

De esta manera, se ha podido conocer el rendimiento de los modelos de cada arquitectura en la clasificación, para escoger el mejor y comprobar el efecto de Grad-CAM++

4.4.1. InceptionV3

Métricas de clasificación

Tras evaluar las 24 combinaciones de parámetros planteadas para InceptionV3, se ha observado que esta arquitectura ofrece un rendimiento sólido y bastante estable para el problema de clasificación multiclase de este proyecto.

La mejor combinación para esta arquitectura, elegida a partir del rendimiento en validación, obtuvo los siguientes valores en los parámetros:

Tabla 10. Mejores parámetros en InceptionV3

Parámetros	Mejor valor
Learning Rate	0.0001
Capas Entrenables	20
Optimizador	Adam
Dropout	0.5
Epochs	60
Stopped Epoch	16

Fuente: Elaboración propia

Esta configuración, logró en el conjunto de test, los siguientes resultados globales:

Tabla 11. Métricas de mejor InceptionV3

Métricas	Valor
Test accuracy	0.8074
Test precision	0.7475
Test recall	0.7704
Test F1-Score	0.7560
Val accuracy	0.7951

Fuente: Elaboración propia con Python

Estos valores reflejan un rendimiento sólido, con un accuracy de 0.80 lo que indica una buena capacidad de clasificación general. Además, la precisión y el recall tienen valores similares entre ellos lo que sugiere que el comportamiento del modelo es bastante equilibrado, aunque tiene una ligera tendencia a acertar más casos reales como consecuencia de identificar algunos falsos positivos. Esto se puede ver reflejado también en el F1-score ya que resume de forma conjunta ambas métricas. Por último, como los valores del accuracy de test y del accuracy de validación son cercanos, se puede concluir que el modelo tiene una buena capacidad de generalización y no muestra evidencias claras de sobreajuste.

Para reforzar esta interpretación, a continuación, se muestran las curvas de accuracy y loss a lo largo del entrenamiento, tanto para el conjunto de entrenamiento como para el de validación.

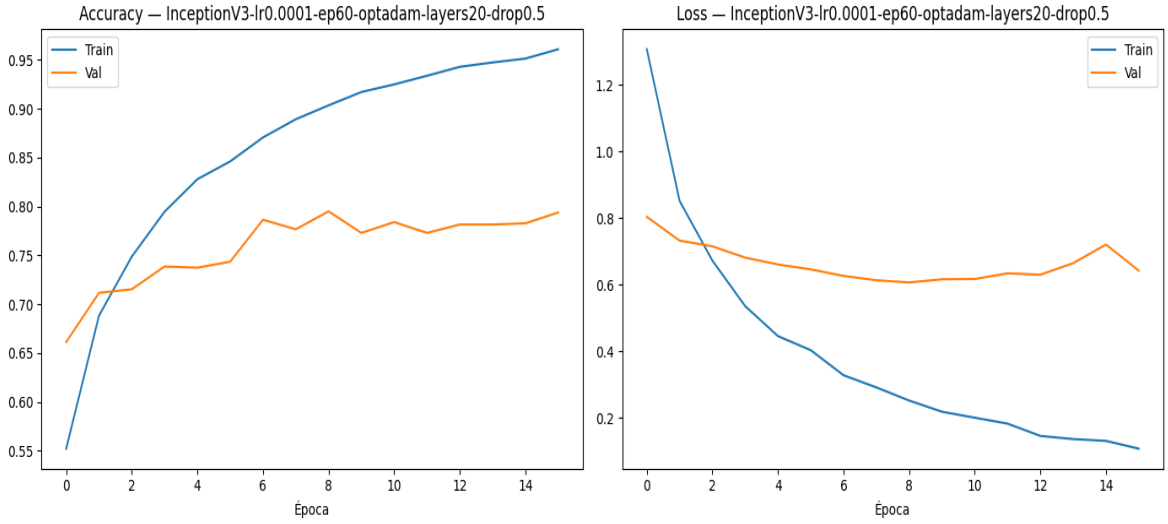

Ilustración 7. Accuracy y Loss durante el entrenamiento del mejor InceptionV3
(Fuente: Elaboración propia con Python)

En la gráfica de accuracy, se puede observar que el valor de la métrica en el set de entrenamiento aumenta de forma continua a lo largo de las épocas, llegando al 95%, mientras que la de validación, aunque mejora durante las primeras épocas, después se estabiliza en valores cercanos al 0.80. Esto indica que el modelo, con esta configuración, aprende de manera efectiva, pero a partir de cierto punto las mejoras no se traducen en una mejora clara sobre las imágenes de validación. Por otra parte, en la gráfica de la pérdida, se muestra una disminución progresiva de la pérdida en el set de entrenamiento, mientras que, la pérdida en la validación desciende al principio y luego se mantiene estable.

En conjunto, ambas curvas surgieren que el modelo converge de forma adecuada y que, aunque existe una separación visible entre train y validación, no se observa un sobreajuste excesivo.

Además del análisis global, también se estudia, a través del classification report, el comportamiento del modelo por clase para ver con más detalle en que subtipos de tumor el modelo tiene mejor rendimiento y en cuales tiene más dificultades.

Tabla 12. Classification report del mejor InceptionV3

Clase	Precision	Recall	F1-Score	Support
ductal_carcinoma	0.88	0.84	0.86	518
lobular_carcinoma	0.60	0.77	0.67	94
mucinious_carcinoma	0.80	0.75	0.77	119
papillary_carcinoma	0.72	0.73	0.72	84
Accuracy			0.81	815
Macro avg	0.75	0.77	0.76	815
Weighted avg	0.82	0.81	0.81	815

Fuente: Elaboración propia con Python

A nivel de clases, se puede observar que ductal carcinoma es la categoría que mejor clasifica el modelo, ya que presenta los valores más altos en las 3 métricas. Esto es lógico ya que es la clase mayoritaria e indica que el modelo clasifica este tipo con mayor solidez que el resto. En cambio, lobular carcinoma es la clase más difícil para el modelo, ya que aunque tiene un recall relativamente alto, su precisión es bastante baja, lo que sugiere que el modelo identifica muchos casos correctamente de esta clase pero también tiene un elevado número de falsos positivos al confundir con ella imágenes de otros subtipos.

Mucinous carcinoma tiene un comportamiento bastante equilibrado, con valores consistentes en las tres métricas, mientras que papillary carcinoma presenta un rendimiento aceptable, aunque más moderado que la clase anterior. Además, la diferencia entre los valores de las métricas macro average y weighted average indica que el modelo tiene un mejor rendimiento en las clases más representadas en el conjunto de test, especialmente en ductal carcinoma ya que esta es la más representada.

A continuación, para entender con más detalle dónde está fallando el modelo, se presenta la matriz de confusión.

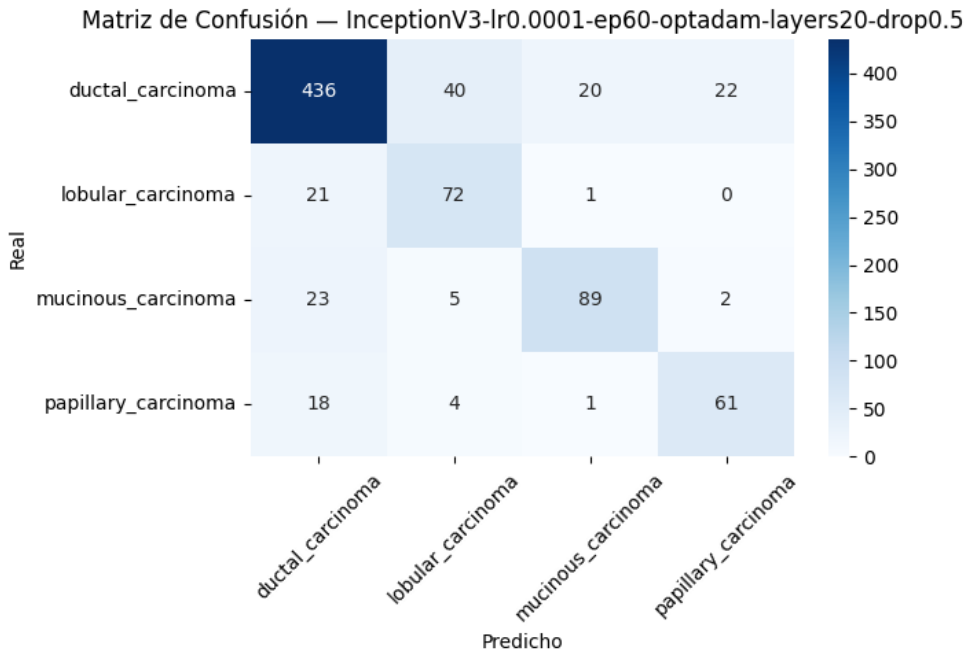

Ilustración 8. Matriz de confusión del mejor InceptionV3
(Fuente: Elaboración propia con Python)

Aquí se muestra que la mayoría de las predicciones correctas se concentran en la diagonal principal, lo que confirma el buen rendimiento general del modelo. Sin embargo, se pueden identificar de forma clara los errores más frecuentes. En el caso de la clase ductal carcinoma, aunque es la clase mejor reconocida, parte de sus imágenes se confunden sobre todo con lobular carcinoma. Esto tiene sentido ya que ambos tipos de tumores están relacionados con los órganos conductores de la leche, por lo que ambos se producen en la misma zona o similar. Esta elevada confusión entre ambas clases es lo que explica la menor precisión en esta segunda clase. Algo parecido ocurre también con las otras dos clases, mucinous carcinoma y papillary carcinoma, ya que sus imágenes tienden a ser clasificadas como ductal carcinoma. Esto sugiere que el modelo tiene tendencia a favorecer la clase mayoritaria cuando la evidencia visual no es lo suficientemente clara.

Además de las métricas anteriores, también se ha analizado la curva ROC-AUC para estudiar con más detalle la capacidad discriminativa del modelo.

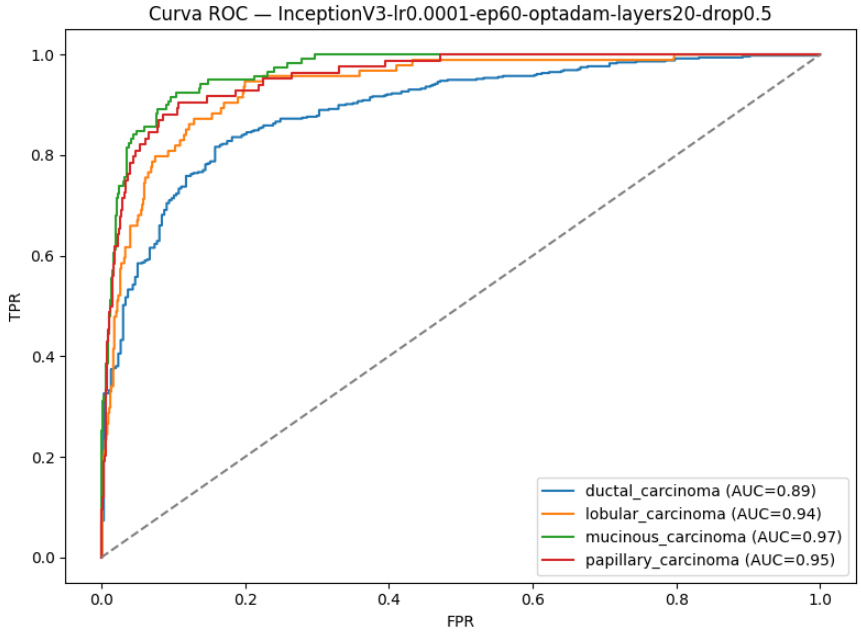

Ilustración 9. Curva ROC-AUC del mejor InceptionV3

(Fuente: Elaboración propia con Python)

Estos valores indican que el modelo tiene una alta capacidad discriminativa en las cuatro clases, ya que todas presentan un AUC superior a 0.80. La clase con mejor comportamiento es mucinous carcinoma seguida de papillary carcinoma y lobular carcinoma, mientras que ductal carcinoma tiene el menor de los valores. Esto se da porque, aunque ductal carcinoma es la clase mejor clasificada en términos globales, generaba al mismo tiempo mucha confusión con las otras clases y por tanto su capacidad de separación frente al resto de clases no es la más alta.

Después de analizar estas métricas, InceptionV3 muestra un rendimiento sólido en este problema, con buenos resultados tanto a nivel global como por clase. Esto puede explicarse por la capacidad que tiene esta arquitectura de extraer características a diferentes escalas ya que en imágenes médicas es algo realmente útil.

Fidelidad de Grad-CAM++

Después de aplicar Grad-CAM++ se calcula la métrica de fidelidad con el objetivo de comprobar hasta qué punto las regiones resaltadas por el mapa de calor influyen realmente en la decisión del modelo. En este caso, la fidelidad media global alcanzada es de un 33% lo

que indica que las zonas destacadas por Grad-CAM++ tienen cierta influencia sobre la predicción final del modelo.

Tabla 13. Fidelidad media por clase de Grad-CAM++ en mejor InceptionV3

Clase	Fidelidad media
ductal_carcinoma	25.40%
lobular_carcinoma	36.03%
mucinious_carcinoma	26.34%
papillary_carcinoma	45.05%
Global	33.20%

Fuente: Elaboración propia con Python

A nivel de clase, se observan diferencias entre los cuatro subtipos de carcinomas. El valor más alto, cerca de un 45%, es de papillary carcinoma, seguida de lobular carcinoma con un 36%, lo que refleja que, en estas clases, las regiones señaladas en el mapa de calor están bastante relacionadas con la decisión final del modelo. En cambio, mucinous carcinoma, que tiene un 26% de fiabilidad, y ductal carcinoma, que tiene un 25%, presentan valores mucho más moderados, lo que indica que la predicción depende más de patrones identificados en la imagen y no tanto de zonas concentradas y visuales.

Tras analizar tanto las métricas de clasificación como la metrica de grad cam, se puede concluir que este modelo tiene un buen rendimiento en clasificación y que además proporciona un nivel aceptable de interpretabilidad visual.

4.4.2. ResNet101V2

Métricas de clasificación

Tras evaluar las 24 combinaciones de parámetros planteadas para ResNet101V2, se observa que esta arquitectura ofrece un rendimiento correcto, aunque algo menos sólido que el obtenido con InceptionV3. En este caso, la mejor combinación para esta arquitectura obtuvo los siguientes valores en los parámetros:

Tabla 14. Mejores parámetros en ResNet101V2

Parámetros	Mejor valor
Learning Rate	0.0001
Capas Entrenables	30
Optimizador	Adam
Dropout	0.3
Epochs	60
Stopped Epoch	14

Fuente: Elaboración propia

Esta configuración logró, en el conjunto de test, los siguientes resultados globales:

Tabla 15. Métricas de mejor ResNet101V2

Métricas	Valor
Test accuracy	0.7644
Test precision	0.6918
Test recall	0.6808
Test F1-Score	0.6862
Val accuracy	0.7816

Fuente: Elaboración propia con Python

Estos valores reflejan un rendimiento global correcto, con una accuracy de 0.76, lo que indica una buena capacidad de clasificación, aunque inferior a la obtenida por InceptionV3. Además, la precision, el recall y el F1-score presentan valores cercanos entre sí, lo que sugiere un comportamiento relativamente equilibrado, pero algo más limitado en su capacidad para distinguir con claridad entre todas las clases. Por otro lado, la cercanía entre la accuracy de validación y la accuracy de test indica que el modelo generaliza de forma razonable y que no presenta un sobreajuste muy marcado.

Para reforzar esta interpretación, a continuación, se muestran las curvas de accuracy y loss a lo largo del entrenamiento, tanto para el conjunto de entrenamiento como para el de validación.

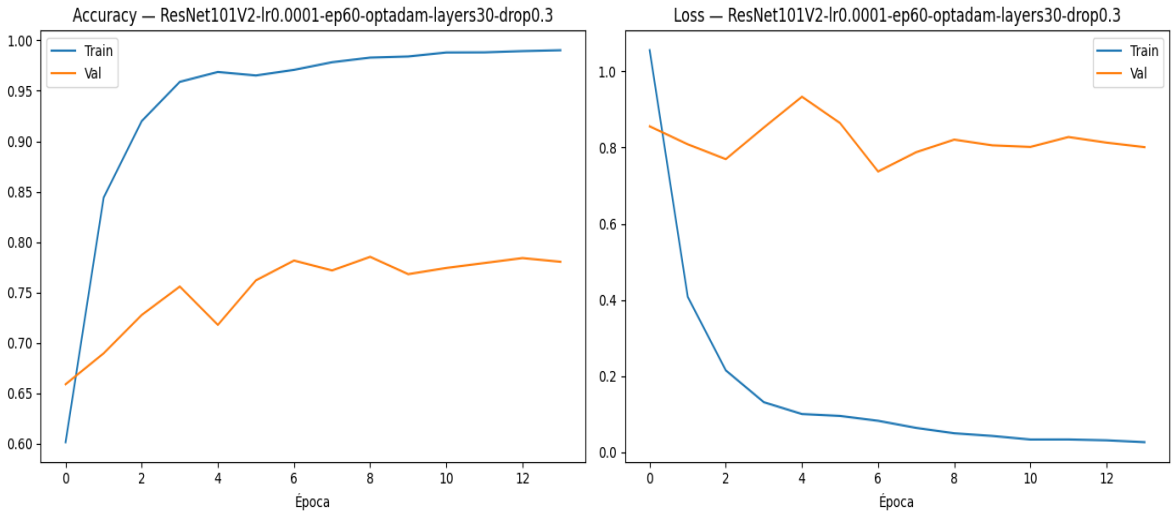

Ilustración 10. Accuracy y Loss durante el entrenamiento del mejor ResNet101V2
(Fuente: Elaboración propia con Python)

En la gráfica de accuracy se observa que el valor en entrenamiento aumenta muy rápidamente hasta situarse cerca del 100%, mientras que la accuracy de validación mejora durante las primeras épocas y después se estabiliza en torno a valores levemente superiores a 0.75. Esto indica que el modelo aprende con mucha intensidad sobre el conjunto de entrenamiento, pero que esas mejoras no se trasladan al conjunto de validación. En la gráfica de loss se aprecia una disminución muy pronunciada de la pérdida en entrenamiento, mientras que la pérdida de validación se mantiene bastante más estable y con oscilaciones a lo largo de las épocas. En conjunto, ambas curvas sugieren que el modelo converge, pero muestran una separación más clara entre entrenamiento y validación que en InceptionV3, lo que apunta a una mayor tendencia al sobreajuste, aunque todavía controlada gracias a los dos callbacks implementados y las técnicas de regularización.

Además del análisis global, también se estudia, a través del classification report, el comportamiento del modelo por clase para ver con más detalle en qué subtipos de tumor presenta mejor rendmiento y en cuáles tiene más dificultades.

Tabla 16. Classification report del mejor ResNet101V2

Clase	Precision	Recall	F1-Score	Support
ductal_carcinoma	0.83	0.84	0.83	518
lobular_carcinoma	0.53	0.53	0.53	94
mucinious_carcinoma	0.75	0.72	0.74	119
papillary_carcinoma	0.66	0.63	0.65	84
Accuracy			0.76	815
Macro avg	0.69	0.68	0.69	815
Weighted avg	0.76	0.76	0.76	815

Fuente: Elaboración propia con Python

A nivel de clases, puede observarse que ductal carcinoma vuelve a ser la categoría que mejor clasifica el modelo, con los valores más altos en las tres métricas principales. Esto indica que ResNet101V2 identifica esta clase con bastante más facilidad que el resto. En cambio, lobular carcinoma es claramente la clase más difícil, ya que presenta los valores más bajos de precision, recall y F1-score, lo que refleja una mayor dificultad para separarla correctamente del resto de subtipos. Por otra parte, mucinous carcinoma mantiene un comportamiento relativamente equilibrado, con métricas intermedias y consistentes, mientras que papillary carcinoma muestra un rendimiento aceptable, aunque más moderado que la clase anterior. Además, la diferencia entre la macro average y la weighted average indica que el modelo obtiene mejores resultados en las clases más representadas del conjunto de test, especialmente en ductal carcinoma, lo que vuelve a demostrar que el rendimiento no es completamente homogéneo entre las cuatro clases.

A continuación, para entender con más detalle dónde está fallando el modelo, se presenta la matriz de confusión.

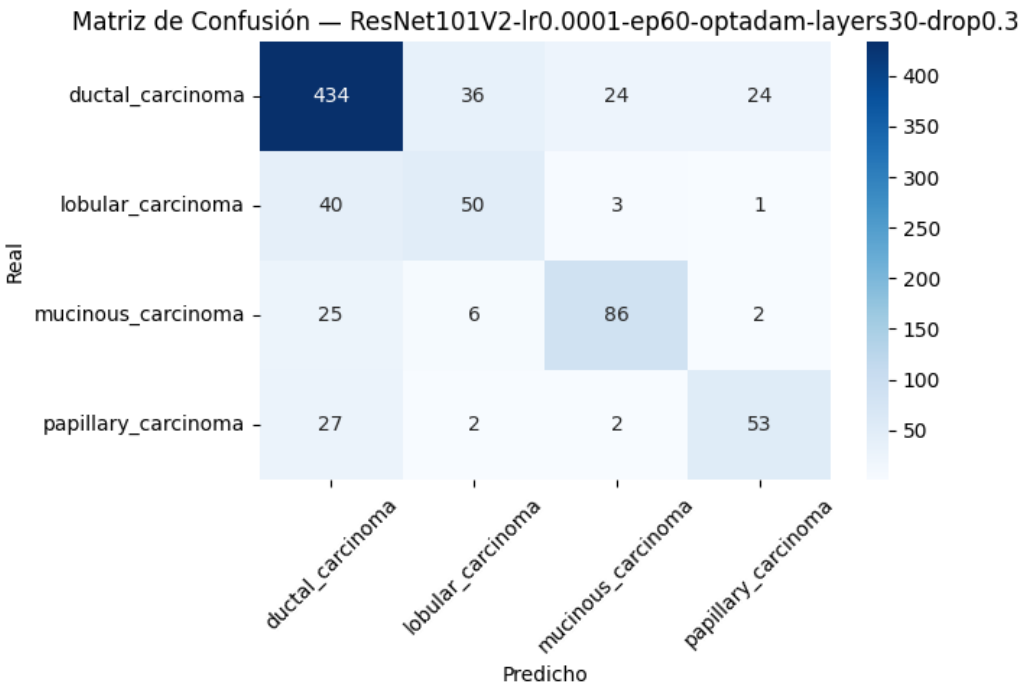

Ilustración 11. Matriz de confusión del mejor ResNet10V2
(Fuente: Elaboración propia con Python)

La matriz de confusión muestra que la mayoría de las predicciones correctas se concentran en la diagonal principal, lo que confirma que el modelo es capaz de distinguir correctamente una parte importante de las imágenes. Sin embargo, también se observan errores bastante claros. En particular, lobular carcinoma presenta una confusión elevada con ductal carcinoma, ya que muchos ejemplos reales de esta clase se predicen como ductal. Algo parecido ocurre con mucinous carcinoma y papillary carcinoma, cuyas imágenes erróneas también tienden a desplazarse hacia la clase mayoritaria. Esto sugiere que, cuando la evidencia visual no es suficientemente clara, ResNet101V2 tiene una tendencia a favorecer ductal carcinoma, ya que es la clase mayoritaria, lo que explica parte de la caída en precision y recall de las clases minoritarias.

Además de las métricas anteriores, también se ha analizado la curva ROC-AUC para estudiar con más detalle la capacidad discriminativa del modelo.

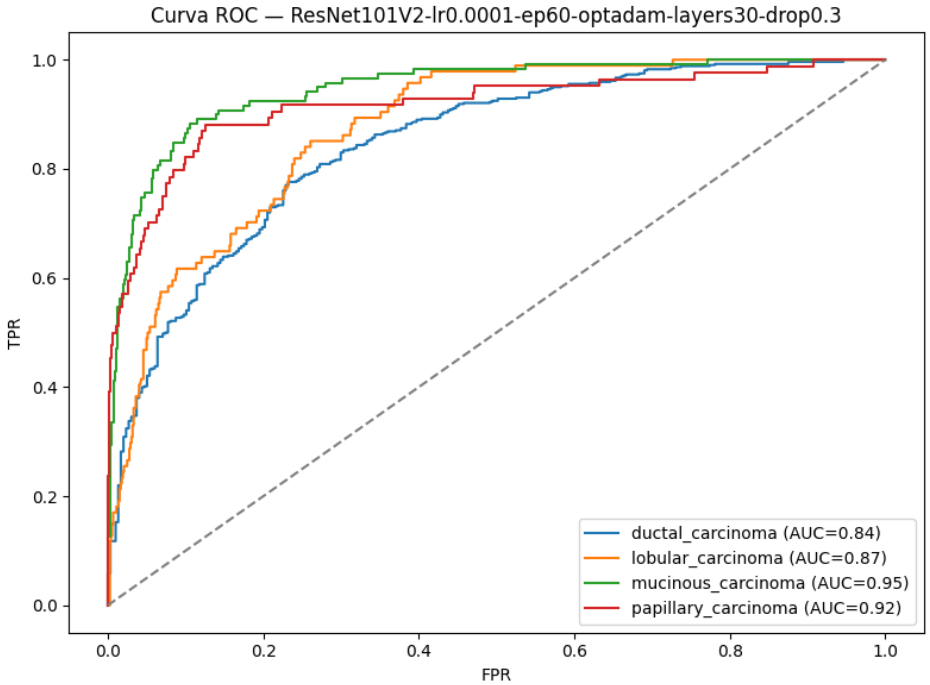

Ilustración 12. Accuracy y Loss durante el entrenamiento del mejor ResNet101V2 (Fuente: Elaboración propia con Python)

Estos valores indican que el modelo mantiene una capacidad discriminativa alta en las cuatro clases, ya que todas presentan un AUC superior a 0.80. La clase con mejor comportamiento es mucinous carcinoma, seguida de papillary carcinoma, mientras que lobular carcinoma y ductal carcinoma presentan los valores más bajos. Esto resulta interesante porque, aunque ductal carcinoma es la clase mejor clasificada en términos globales, su capacidad de separación frente al resto es la más baja. En conjunto, estos resultados muestran que ResNet101V2 tiene una capacidad discriminativa razonable, aunque menos uniforme que la de InceptionV3.

Después de analizar estas métricas, puede concluirse que ResNet101V2 ofrece un rendimiento correcto en este problema, con un comportamiento especialmente sólido en la clase mayoritaria, pero con más dificultades en las clases minoritarias. Esto puede explicarse por su diseño residual, que favorece el aprendizaje profundo y estable, aunque en este caso no parece adaptarse tan bien como InceptionV3 a la variabilidad multiescala presente en las imágenes médicas.

Fidelidad de Grad-CAM++

Tras aplicar Grad-CAM++ a las predicciones del mejor modelo de ResNet101V2, se calcula la métrica de fidelidad con el objetivo de comprobar si las regiones resaltadas por el heatmap influyen realmente en la decisión del modelo. En este caso, la fidelidad media global alcanzada es del 35.84 %, lo que indica que las zonas destacadas por Grad-CAM++ tienen una influencia apreciable sobre la predicción final del modelo.

Tabla 17. Fidelidad media por clase de Grad-CAM++ en mejor ResNet101V2

Clase	Fidelidad media
ductal_carcinoma	28.55%
lobular_carcinoma	34.45%
mucinious_carcinoma	32.33%
papillary_carcinoma	48.04%
Global	35,84%

Fuente: Elaboración propia con Python

A nivel de clase, se observan diferencias entre los cuatro subtipos de carcinoma. El valor más alto corresponde a papillary carcinoma, con cerca de un 50%, seguida de lobular carcinoma con un 34% y de mucinous carcinoma con un 32% de fidelidad, lo que sugiere que, en estas clases, las regiones señaladas por Grad-CAM++ están más relacionadas con la decisión final del modelo. Por otra parte, ductal carcinoma obtiene el valor más bajo, un 28%. Esto sugiere que, en esta última clase, la predicción podría depender de patrones más distribuidos por la imagen y no tanto de una región concreta especialmente dominante.

Tras analizar tanto las métricas de clasificación como la métrica de Grad-CAM++, puede concluirse que ResNet101V2 ofrece un rendimiento aceptable en clasificación y, además, proporciona un nivel razonable de interpretabilidad visual. No obstante, sus resultados muestran más limitaciones que los de InceptionV3, tanto en la homogeneidad entre clases como en la claridad de algunas de sus decisiones.

4.4.3. DenseNet121

Métricas de clasificación

Tras evaluar las 24 combinaciones de parámetros para DenseNet121, se observa que esta arquitectura ofrece un comportamiento muy competitivo dentro del problema planteado. La configuración seleccionada como mejor fue la que obtuvo el mayor rendimiento en validación y quedó definida por los siguientes parámetros:

Tabla 18. Mejores parámetros en DenseNet121

Parámetros	Mejor valor
Learning Rate	0.0001
Capas Entrenables	20
Optimizador	Adam
Dropout	0.5
Epochs	60
Stopped Epoch	21

Fuente: Elaboración propia

Esta configuración alcanzó, en el conjunto de test, los siguientes resultados globales:

Tabla 19. Métricas de mejor DenseNet121

Métricas	Valor
Test accuracy	0.8172
Test precision	0.7713
Test recall	0.7559
Test F1-Score	0.7610
Val accuracy	0.8245

Fuente: Elaboración propia con Python

En términos generales, estos valores reflejan un rendimiento sólido. La accuracy de 0.8172 muestra una buena capacidad de clasificación global, mientras que la precision, el recall y el F1-score mantienen valores próximos entre sí, lo que sugiere un comportamiento bastante equilibrado. Además, la cercanía entre la accuracy de validación y la accuracy de test apunta a una capacidad de generalización adecuada, sin señales claras de sobreajuste.

Para completar esta interpretación, a continuación, se muestran las curvas de accuracy y loss a lo largo del entrenamiento, tanto para entrenamiento como para validación.

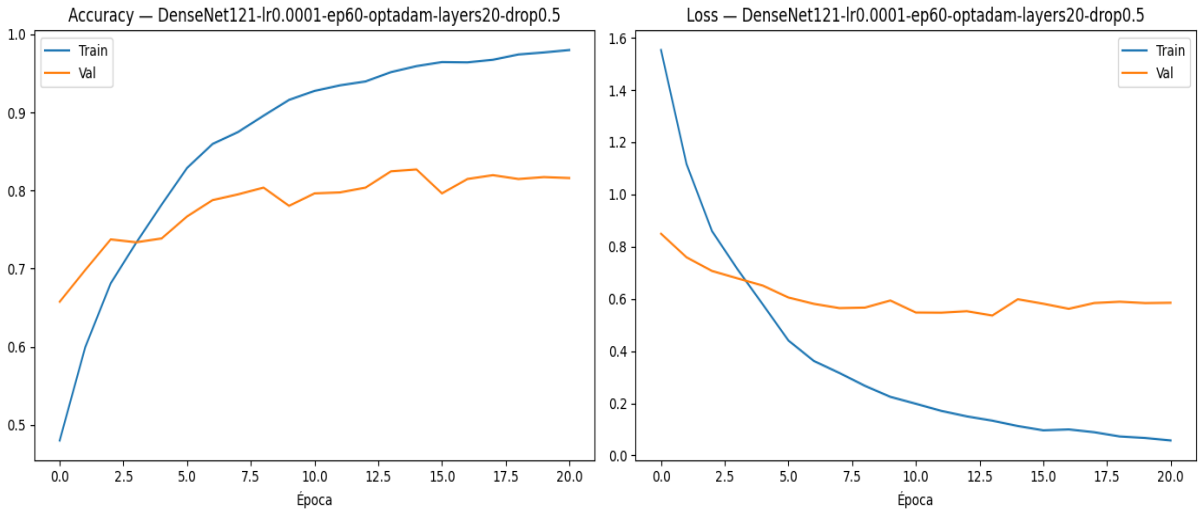

Ilustración 13. Accuracy y Loss durante el entrenamiento del mejor DenseNet121
(Fuente: Elaboración propia con Python)

En la gráfica de accuracy se aprecia una mejora progresiva y continua en el conjunto de entrenamiento, mientras que la curva de validación también aumenta durante las primeras épocas y después se estabiliza en torno a valores cercanos a 0.82. Esto indica que el modelo aprende de forma efectiva, aunque llega un punto en el que las mejoras sobre train ya no se traducen en ganancias claras sobre validación. En la gráfica de loss puede verse una reducción marcada de la pérdida en entrenamiento, mientras que la de validación desciende al principio y luego permanece relativamente estable, con pequeñas oscilaciones. En conjunto, ambas curvas muestran una convergencia adecuada y una separación razonable entre train y validación, sin evidencias de un sobreajuste excesivo.

Además del análisis global, también se estudia el comportamiento del modelo por clase a través del classification report, ya que esto permite ver con más detalle en qué subtipos funciona mejor y en cuáles encuentra más dificultades.

Tabla 20. Classification report del mejor DenseNet121

Clase	Precision	Recall	F1-Score	Support
ductal_carcinoma	0.86	0.88	0.87	518
lobular_carcinoma	0.57	0.64	0.60	94
mucinious_carcinoma	0.86	0.70	0.77	119
papillary_carcinoma	0.80	0.81	0.80	84
Accuracy			0.82	815
Macro avg	0.77	0.76	0.76	815
Weighted avg	0.82	0.82	0.82	815

Fuente: Elaboración propia con Python

Por clases, ductal carcinoma vuelve a ser la categoría mejor reconocida, con los valores más altos en las tres métricas principales. Esto indica que el modelo identifica este subtipo con bastante solidez. La clase más problemática es lobular carcinoma, que presenta los valores más bajos de precision, recall y F1-score, lo que evidencia una mayor dificultad para separarla del resto. En mucinous carcinoma se observa un comportamiento interesante: su precision es alta, pero su recall es más moderado, lo que sugiere que cuando el modelo predice esta clase suele acertar, aunque deja escapar parte de sus casos reales. Por su parte, papillary carcinoma presenta un rendimiento bastante consistente, con valores equilibrados y superiores a los de ResNet101V2. Además, la diferencia entre la macro average y la weighted average vuelve a indicar que el rendimiento global está algo favorecido por las clases más representadas, especialmente por ductal carcinoma.

Para entender mejor en qué errores concretos está fallando el modelo, se analiza también la matriz de confusión.

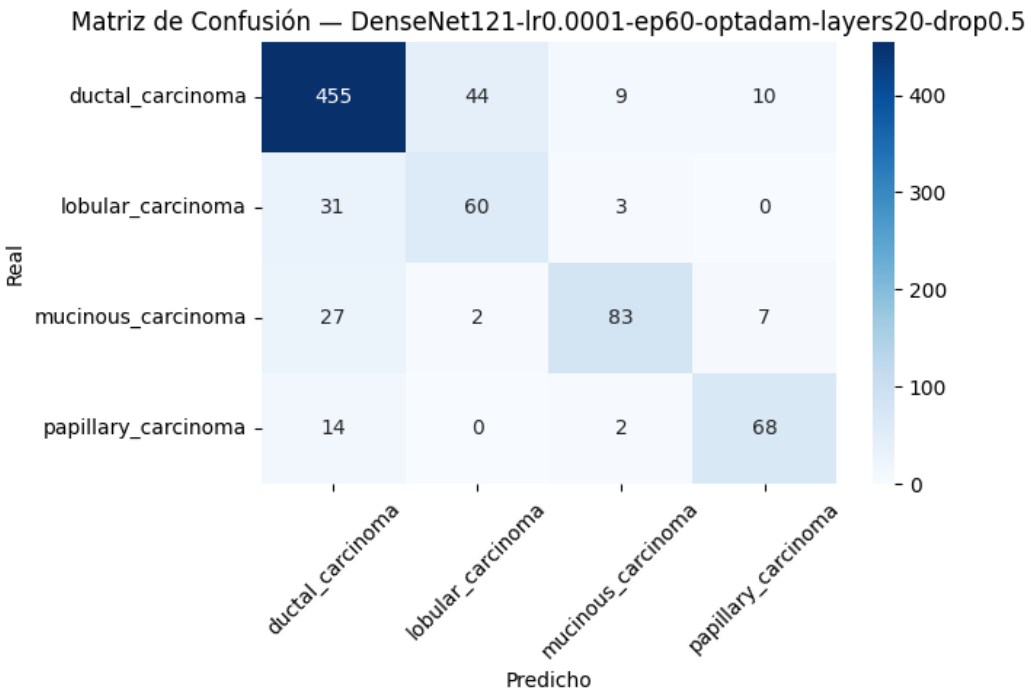

Ilustración 14. Matriz de confusión del mejor DenseNet121
(Fuente: Elaboración propia con Python)

La matriz muestra que la mayor parte de las predicciones correctas se concentran en la diagonal principal, lo que confirma el buen comportamiento general del modelo. Aun así, también se aprecian algunos patrones claros de confusión. En ductal carcinoma, una parte de las imágenes se confunde con lobular carcinoma, y esta misma relación aparece en sentido contrario, ya que muchos casos reales de lobular se clasifican como ductal. Además, tanto mucinous carcinoma como papillary carcinoma presentan varios errores que también se desvían hacia ductal carcinoma, lo que sugiere que, cuando la evidencia visual no es suficientemente clara, el modelo sigue mostrando cierta tendencia a favorecer la clase mayoritaria. Aun así, en comparación con otras arquitecturas, DenseNet121 consigue mantener una diagonal más consistente y una mejor separación en clases como papillary carcinoma.

Además de estas métricas, también se analizó la curva ROC-AUC para estudiar con mayor detalle la capacidad discriminativa del modelo en cada clase.

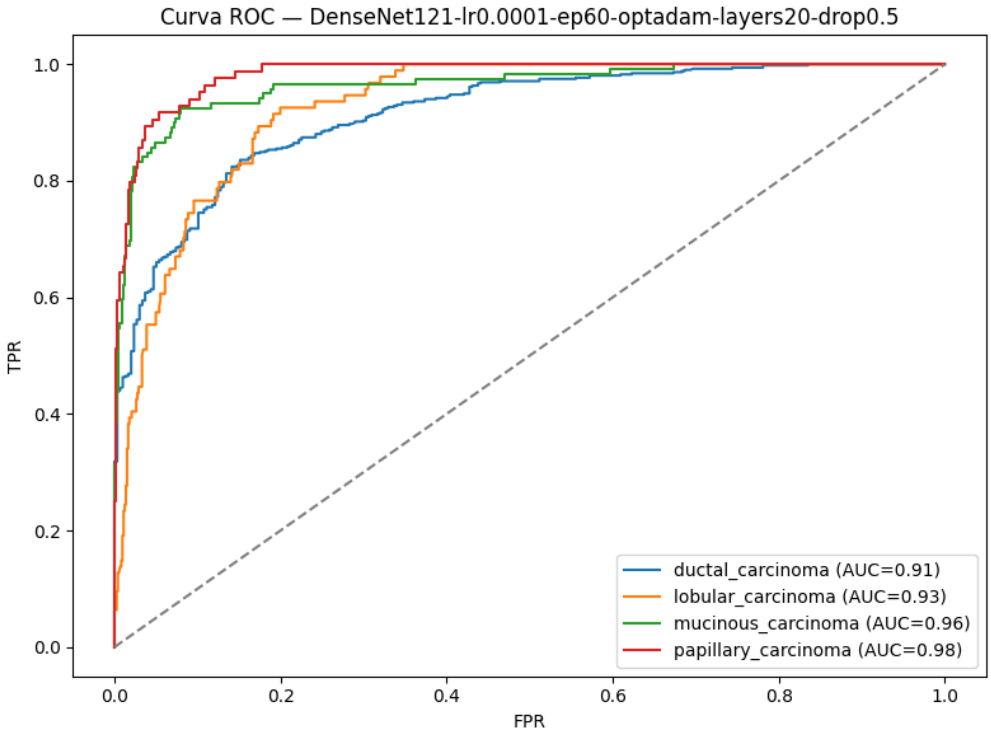

Ilustración 15. Curva ROC-AUC del mejor DenseNet121

(Fuente: Elaboración propia con Python)

Estos valores muestran una capacidad discriminativa alta en las cuatro clases, ya que todas superan claramente el valor de 0.90. La clase con mejor comportamiento es papillary carcinoma, seguida de mucinous carcinoma, mientras que lobular carcinoma y ductal carcinoma presentan valores algo menores, aunque igualmente altos. Esto confirma que DenseNet121 no solo ofrece buenos resultados en las métricas globales de clasificación, sino también una capacidad notable para separar cada subtipo frente al resto.

En conjunto, DenseNet121 ofrece un rendimiento muy sólido en este problema. Sus buenos resultados pueden explicarse por su capacidad para reutilizar características a lo largo de la red, algo especialmente útil en imágenes médicas, donde tanto los detalles finos como los patrones de textura tienen un papel importante.

Fidelidad de Grad-CAM++

Después de aplicar Grad-CAM++, se calcula la métrica de fidelidad para comprobar hasta qué punto las regiones resaltadas por el mapa de calor influyen realmente en la decisión del modelo. En este caso, la fidelidad media global alcanzada fue del 37.28 %, lo que indica

que las zonas destacadas por Grad-CAM++ tienen una influencia apreciable sobre la predicción final.

Tabla 21. Fidelidad media por clase de Grad-CAM++ en mejor DenseNet121

Clase	Fidelidad media
ductal_carcinoma	41.11%
lobular_carcinoma	18.46%
mucinious_carcinoma	49.51%
papillary_carcinoma	40.02%
Global	37.28%

Fuente: Elaboración propia con Python

Al analizar la fidelidad por clase, se observan diferencias claras. El valor más alto corresponde a mucinous carcinoma (49.51 %), seguida de ductal carcinoma (41.11 %) y papillary carcinoma (40.02 %), lo que sugiere que en estas clases las regiones señaladas por Grad-CAM++ guardan una relación bastante directa con la decisión del modelo. En cambio, lobular carcinoma (18.46 %) presenta una fidelidad considerablemente más baja, lo que indica que, en esta clase, las explicaciones visuales son menos consistentes con la predicción final. Esto encaja también con lo observado en las métricas de clasificación, donde lobular era la categoría más difícil para la red.

Tras analizar tanto las métricas de clasificación como la métrica de Grad-CAM++, puede concluirse que DenseNet121 combina un buen rendimiento predictivo con un nivel razonable de interpretabilidad visual. En conjunto, se presenta como una arquitectura especialmente sólida dentro de la comparativa, tanto por su capacidad de clasificación como por la coherencia de varias de sus explicaciones visuales.

4.4.4. Comparativa global

DenseNet121 es la arquitectura que ofrece el mejor equilibrio entre rendimiento predictivo e interpretabilidad, ya que alcanza las mejores métricas globales de clasificación y también la mayor fidelidad media en Grad-CAM++. InceptionV3 se sitúa muy cerca, con

un comportamiento especialmente sólido y estable, además de una buena capacidad discriminativa por clase, por lo que también puede considerarse una opción muy competitiva. En cambio, ResNet101V2 obtiene los resultados más discretos de las tres, sobre todo en clasificación por clase y en homogeneidad entre subtipos, aunque mantiene una interpretabilidad razonable. Por tanto, la comparación sugiere que, para este problema concreto, las arquitecturas que mejor aprovechan la información multiescala y la reutilización de características, como InceptionV3 y DenseNet121, se adaptan mejor a la complejidad visual de las imágenes médicas que ResNet101V2.

4.5. Visualización e interpretación de los resultados

4.5.1. InceptionV3 + Grad-CAM++

Antes de analizar los mapas de calor generados con Grad-CAM++, se ha observado algunos ejemplos de predicciones correctas e incorrectas realizadas por la mejor configuración de InceptionV3. Esto permite identificar de forma visual en qué casos el modelo clasifica correctamente cada subtipo tumoral y en qué situaciones aparecen las principales confusiones. En la siguiente figura, a la izquierda se muestran ejemplos correctamente clasificados y a la derecha ejemplos mal clasificados, indicando en cada caso la clase real, la clase predicha y el nivel de confianza asociado a la predicción.

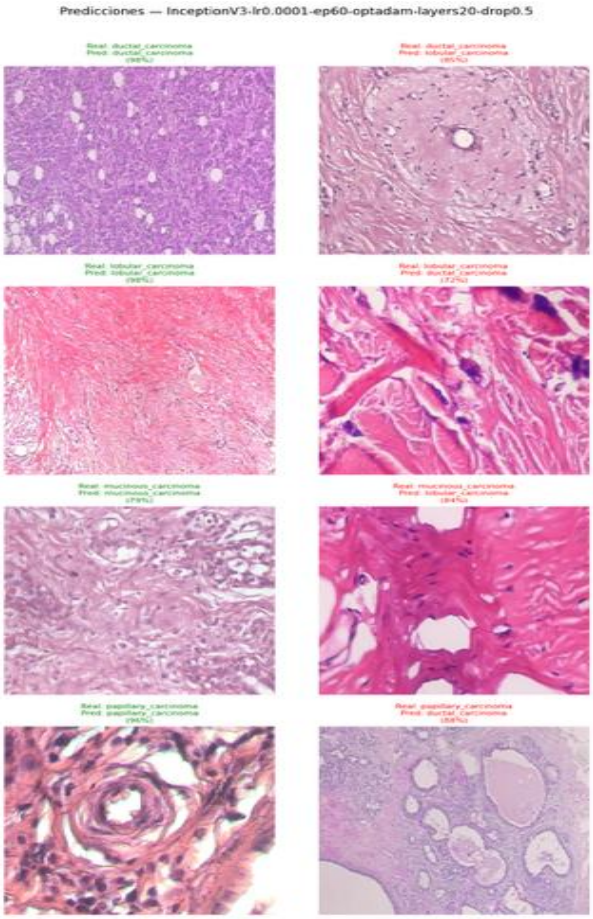

Ilustración 16. Resultados del mejor InceptionV3
(Fuente: Elaboración propia con Python)

Se puede ver que, cuando el modelo acierta, suele hacerlo con un nivel de confianza alto, como ocurre en los ejemplos correctos de ductal carcinoma, lobular carcinoma y papillary carcinoma. En mucinous carcinoma la predicción correcta también es adecuada, aunque con una confianza algo menor, lo que sugiere que esta clase puede resultar algo más ambigua incluso cuando el modelo acierta. En cambio, los ejemplos incorrectos permiten ver mejor las principales dificultades del modelo. Destaca la confusión entre ductal carcinoma y lobular carcinoma, ya que aparecen errores en ambos sentidos También se observa que mucinous carcinoma y papillary carcinoma pueden llegar a ser clasificados como ductal carcinoma con una confianza relativamente alta. Esto indica que InceptionV3 aprende patrones representativos de cada clase, pero sigue encontrando dificultades cuando existen similitudes morfológicas entre subtipos o cuando la evidencia visual no es lo suficientemente clara.

Una vez observados estos ejemplos, resulta han analizado los mapas de calor generados con Grad-CAM++, ya que permiten comprobar en qué regiones de la imagen se ha apoyado el modelo tanto cuando acierta como cuando falla. En la siguiente figura se muestran, para cada clase, la imagen original, el heatmap y la superposición del mapa sobre la imagen, tanto en un caso correctamente clasificado como en uno incorrecto.

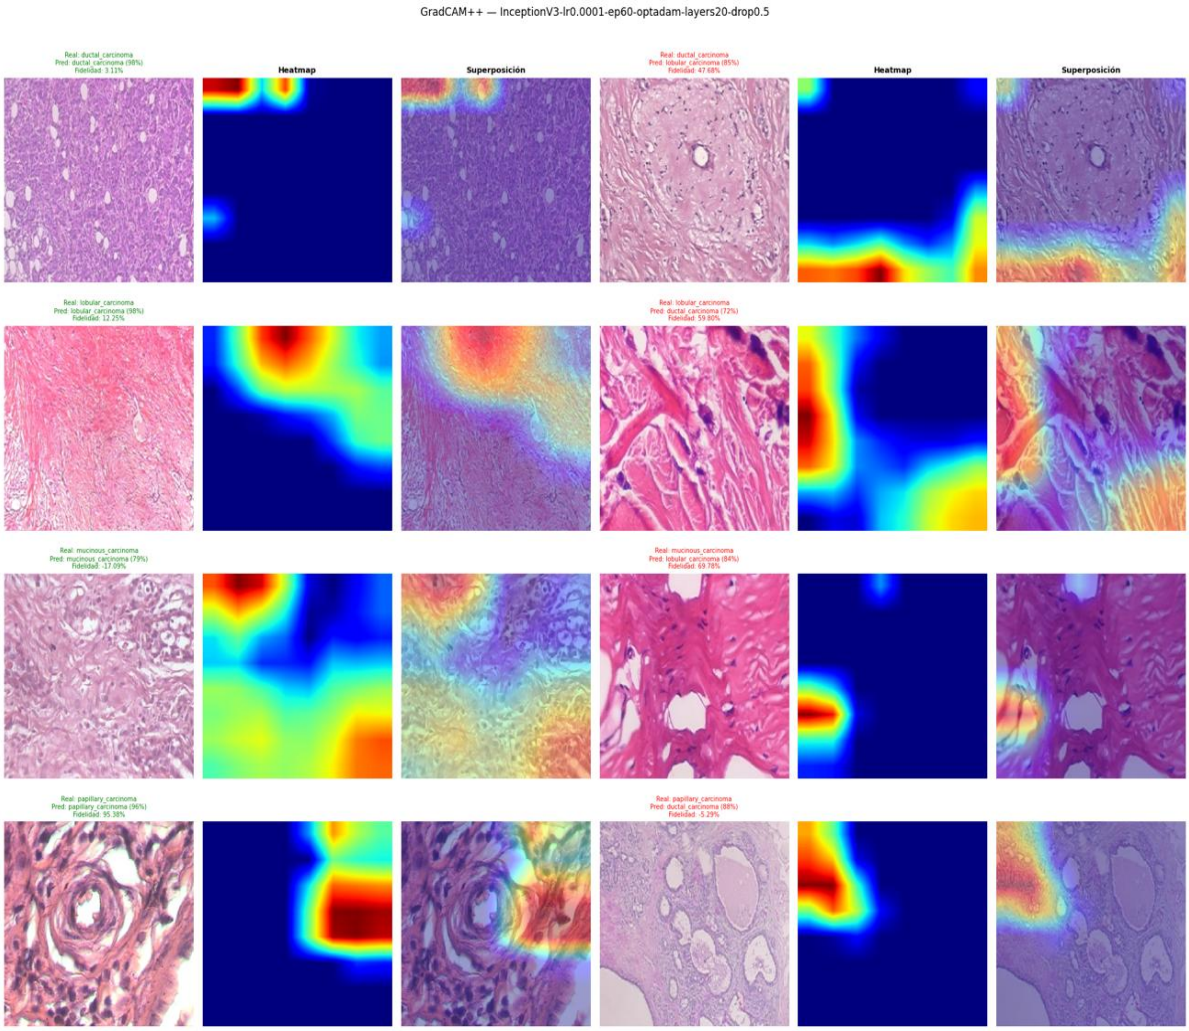

Ilustración 17. Resultados del mejor InceptionV3 con Grad-CAM++
(Fuente: Elaboración propia con Python)

A partir de estos mapas puede observarse que, en las predicciones correctas, la atención del modelo suele concentrarse en regiones del tejido con contenido morfológico relevante, en lugar de repartirse de forma completamente aleatoria por toda la imagen. Esto sugiere que, cuando InceptionV3 acierta, su decisión se apoya en patrones visuales que realmente contienen información útil para la clasificación. Además, en varias de las

imágenes correctas la superposición muestra una activación bastante localizada, lo que refuerza la idea de que el modelo está utilizando zonas concretas del tejido para tomar la decisión.

En los ejemplos incorrectos, en cambio, se aprecia con más frecuencia una activación desplazada hacia regiones menos informativas o una atención más difusa, lo que ayuda a explicar el error cometido. Aun así, los mapas no parecen completamente incoherentes, ya que en varios casos el modelo sigue fijándose en las estructuras relevantes, aunque las interpreta como pertenecientes a otra clase. Esto es especialmente interesante en las confusiones entre ductal carcinoma y lobular carcinoma, donde el error parece deberse más a la similitud morfológica entre ambos subtipos que a una atención arbitraria sobre la imagen. En los casos en los que mucinous carcinoma o papillary carcinoma son confundidos con ductal carcinoma, el mapa de calor sugiere que el modelo está priorizando patrones que asocia con la clase mayoritaria, lo que encaja con lo observado previamente en la matriz de confusión.

La visualización con Grad-CAM++ confirma que InceptionV3 no solo obtiene buenos resultados de clasificación, sino que además basa sus decisiones en regiones con significado visual dentro del tejido. Aunque en los errores la atención no siempre recae en la zona más discriminativa, los mapas muestran una coherencia razonable con la predicción realizada, lo que refuerza la utilidad de esta arquitectura también desde el punto de vista interpretativo.

4.5.2. ResNet101V2 + Grad-CAM++

Antes de interpretar los mapas de calor generados con Grad-CAM++, se han observado algunos ejemplos de predicciones correctas e incorrectas realizadas por la mejor configuración de ResNet101V2. Esto permite ver de forma directa en qué situaciones el modelo reconoce correctamente cada subtipo tumoral y en cuáles aparecen las principales confusiones. En la siguiente figura, a la izquierda se muestran ejemplos bien clasificados y a la derecha casos mal clasificados, indicando en cada uno la clase real, la clase predicha y el nivel de confianza asociado.

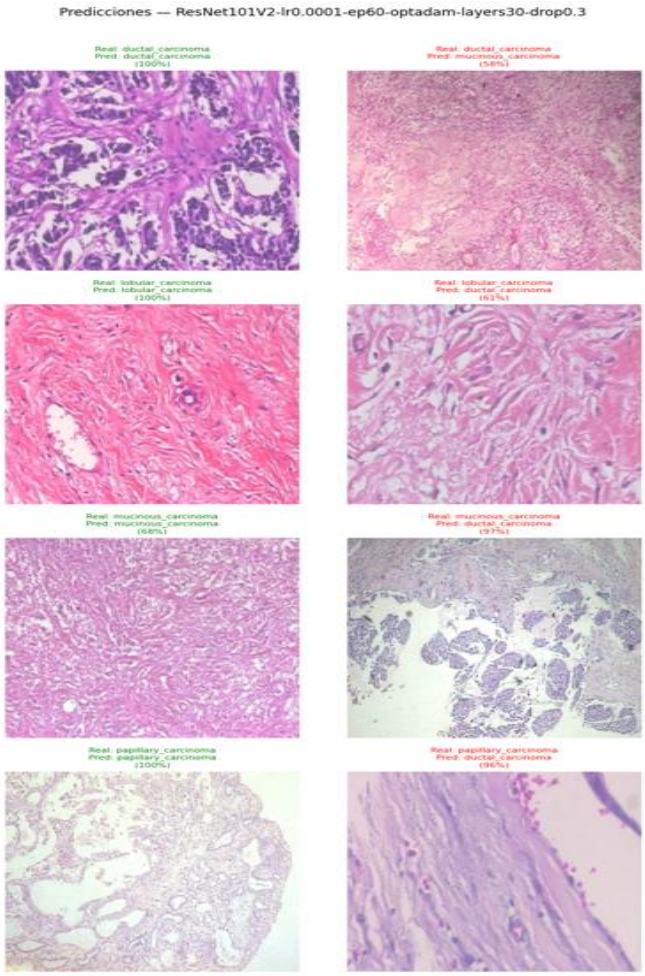

Ilustración 18. Resultados del mejor ResNet101V2

(Fuente: Elaboración propia con Python)

Puede verse que cuando ResNet101V2 acierta, suele hacerlo con una confianza muy alta, llegando incluso al 100 % en los ejemplos correctos de ductal carcinoma, lobular carcinoma y papillary carcinoma. En mucinous carcinoma, la predicción correcta también es adecuada, aunque con una confianza algo menor (68 %), lo que vuelve a sugerir que esta clase puede resultar más ambigua incluso en los aciertos. En cambio, los errores muestran un patrón bastante claro: varias clases terminan siendo confundidas con ductal carcinoma, especialmente lobular carcinoma, mucinous carcinoma y papillary carcinoma. Además, algunos de estos fallos se producen con niveles de confianza elevados, como ocurre en el caso de mucinous carcinoma, que es clasificado como ductal carcinoma con un 97 % de confianza, o en papillary carcinoma, que también es asignado a esa clase con un 96 %. Esto sugiere que el modelo no solo se equivoca en imágenes difíciles, sino que en algunos casos refuerza de manera excesiva su preferencia por la clase mayoritaria. En conjunto, estas

predicciones encajan con lo observado previamente en las métricas, que ResNet101V2 identifica bien los patrones más representativos, pero presenta más problemas cuando las diferencias visuales entre subtipos son más sutiles.

A partir de estos ejemplos, se han observado los mapas de calor de Grad-CAM++, ya que permiten analizar en qué zonas de la imagen se ha apoyado el modelo para emitir cada predicción. En la siguiente figura se muestra, para cada clase, la imagen original, el heatmap y la superposición del mapa sobre la imagen, tanto en un ejemplo correctamente clasificado como en uno incorrecto.

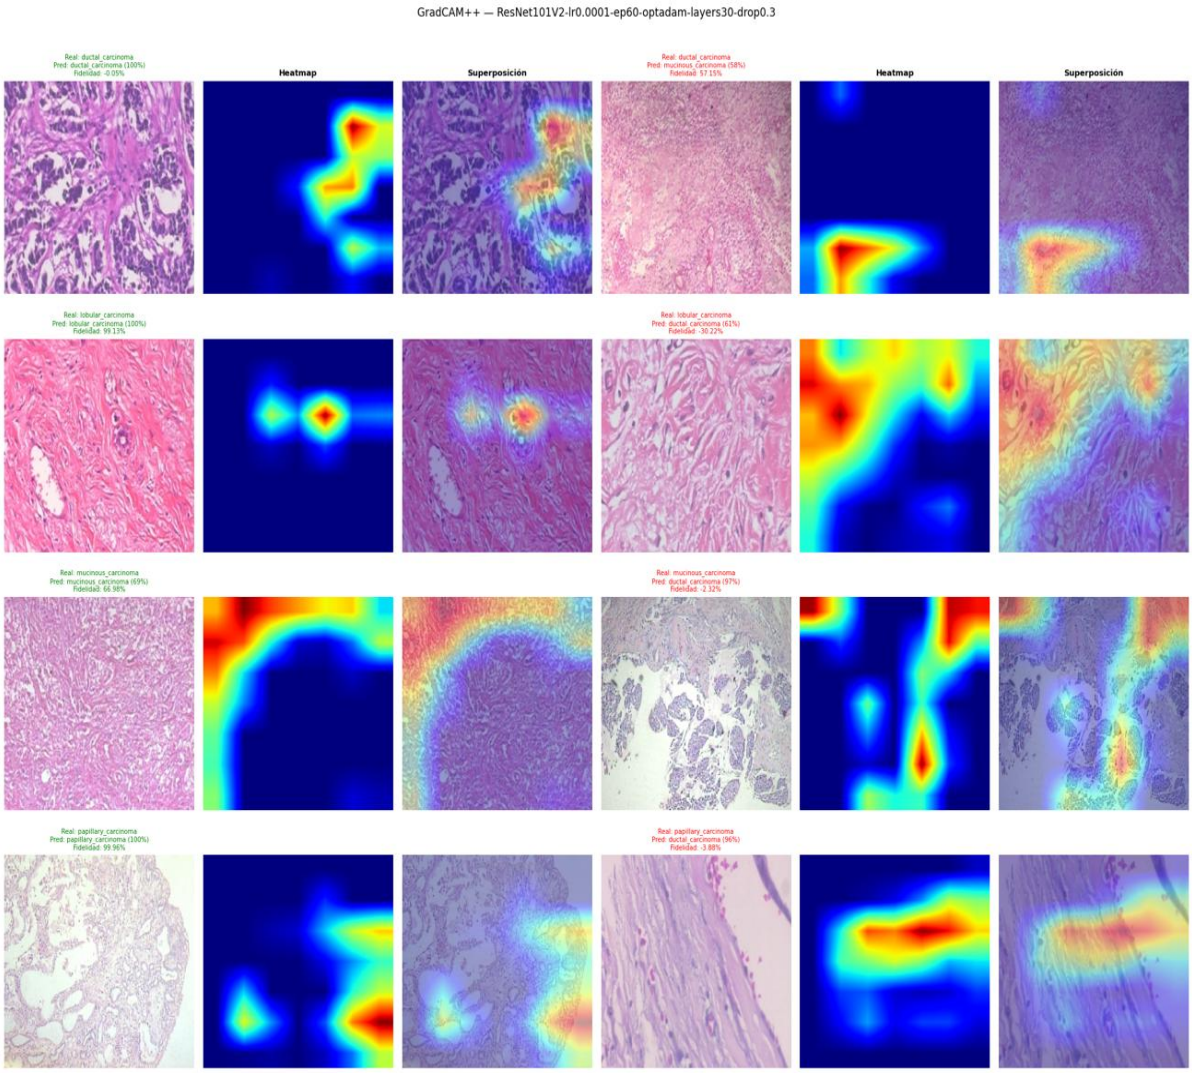

Ilustración 19. Resultados del mejor ResNet101V2 con Grad-CAM++
(Fuente: Elaboración propia con Python)

Los mapas de calor permiten observar diferencias claras entre los aciertos y los errores. En varios de los ejemplos correctamente clasificados, la atención del modelo se concentra en regiones concretas del tejido con estructura visible, lo que sugiere que la decisión no se está tomando de manera arbitraria. Esto se aprecia especialmente en lobular carcinoma y papillary carcinoma, donde la activación aparece bastante localizada y coincide además con valores de fidelidad muy altos, cercanos al 100 %. En mucinous carcinoma, aunque la predicción correcta tiene una confianza más moderada, el mapa también señala una zona relevante y la fidelidad se mantiene en un valor aceptable. En cambio, en ductal carcinoma ocurre algo llamativo: aunque la predicción es correcta y con confianza máxima, la fidelidad es prácticamente nula, lo que sugiere que el mapa resaltado no está reflejando con claridad la parte de la imagen que realmente determina la decisión del modelo.

En los casos incorrectos, la interpretación resulta todavía más interesante. En varias imágenes mal clasificadas, la atención aparece desplazada hacia regiones amplias o poco específicas, y en algunos casos la fidelidad incluso toma valores negativos o muy bajos. Esto ocurre, por ejemplo, en las imágenes de lobular carcinoma, mucinous carcinoma y papillary carcinoma que son confundidas con ductal carcinoma, donde el mapa no parece centrarse en una zona claramente discriminativa. Esto sugiere que, cuando ResNet101V2 falla, no siempre lo hace por fijarse en una región coherente pero ambigua, sino que en algunos casos su atención se distribuye de forma menos precisa. Aun así, en el ejemplo incorrecto de ductal carcinoma clasificado como mucinous carcinoma, la fidelidad es relativamente alta, lo que indica que incluso una decisión errónea puede apoyarse en regiones que el modelo considera importantes, aunque las interprete de manera incorrecta.

El análisis visual muestra que ResNet101V2 es capaz de generar explicaciones útiles en varios casos correctos, pero también presenta ejemplos en los que la relación entre la zona resaltada y la decisión final es menos consistente. Esto refuerza la idea ya observada en las métricas, que se trata de una arquitectura con un rendimiento aceptable, pero con un comportamiento menos estable que el de InceptionV3, tanto en clasificación como en interpretabilidad.

4.5.3. DenseNet121 + Grad-CAM++

Antes de interpretar los mapas de calor generados con Grad-CAM++, conviene observar algunos ejemplos de predicciones correctas e incorrectas realizadas por la mejor

configuración de DenseNet121. Esto permite ver de forma directa qué tipo de imágenes reconoce bien el modelo y en qué casos aparecen las principales confusiones. En la siguiente figura, a la izquierda se muestran ejemplos correctamente clasificados y a la derecha casos mal clasificados, indicando en cada uno la clase real, la clase predicha y el nivel de confianza asociado.

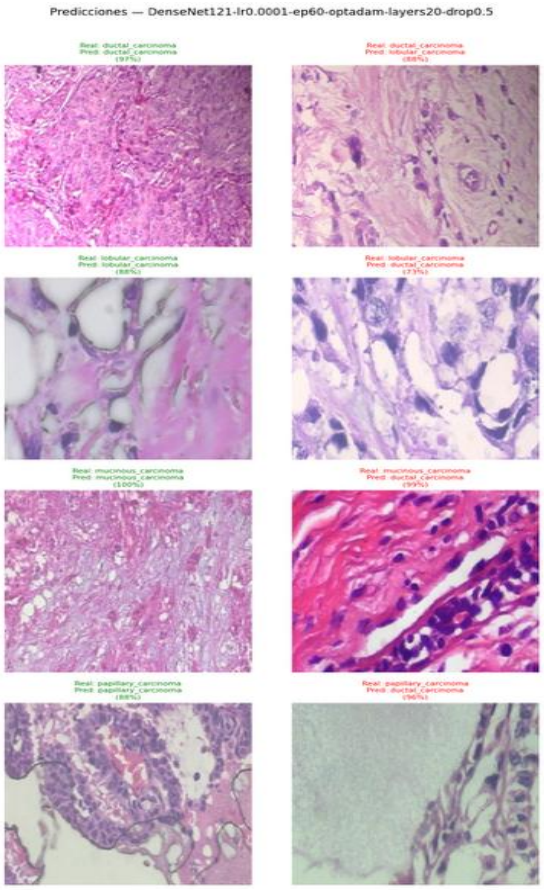

Ilustración 20. Resultados del mejor DenseNet121
(Fuente: Elaboración propia con Python)

Puede verse que, cuando DenseNet121 acierta, suele hacerlo con una confianza alta, especialmente en mucinous carcinoma, donde alcanza el 100 %, y también en ductal carcinoma, lobular carcinoma y papillary carcinoma, con valores entre el 88 % y el 97 %. Esto indica que el modelo no solo clasifica correctamente, sino que además muestra bastante seguridad en sus aciertos. Sin embargo, los errores revelan un patrón ya observado en las métricas anteriores: varias clases tienden a confundirse con ductal carcinoma o con lobular carcinoma. En concreto, aparece una confusión clara entre ductal carcinoma y lobular

carcinoma, y también se observa que ejemplos reales de mucinous carcinoma y papillary carcinoma pueden ser clasificados como ductal carcinoma con niveles de confianza muy elevados, llegando al 99 % y al 96 %, respectivamente. Esto sugiere que, cuando la imagen presenta rasgos menos distintivos o más ambiguos, el modelo tiende a apoyarse en patrones que asocia con las clases más representativas.

Una vez observadas estas predicciones, el análisis con Grad-CAM++ permite estudiar en qué regiones de la imagen se ha fijado la red para tomar su decisión. En la siguiente figura se muestran, para cada clase, la imagen original, el heatmap y la superposición del mapa sobre la imagen, tanto en un ejemplo correctamente clasificado como en uno incorrecto.

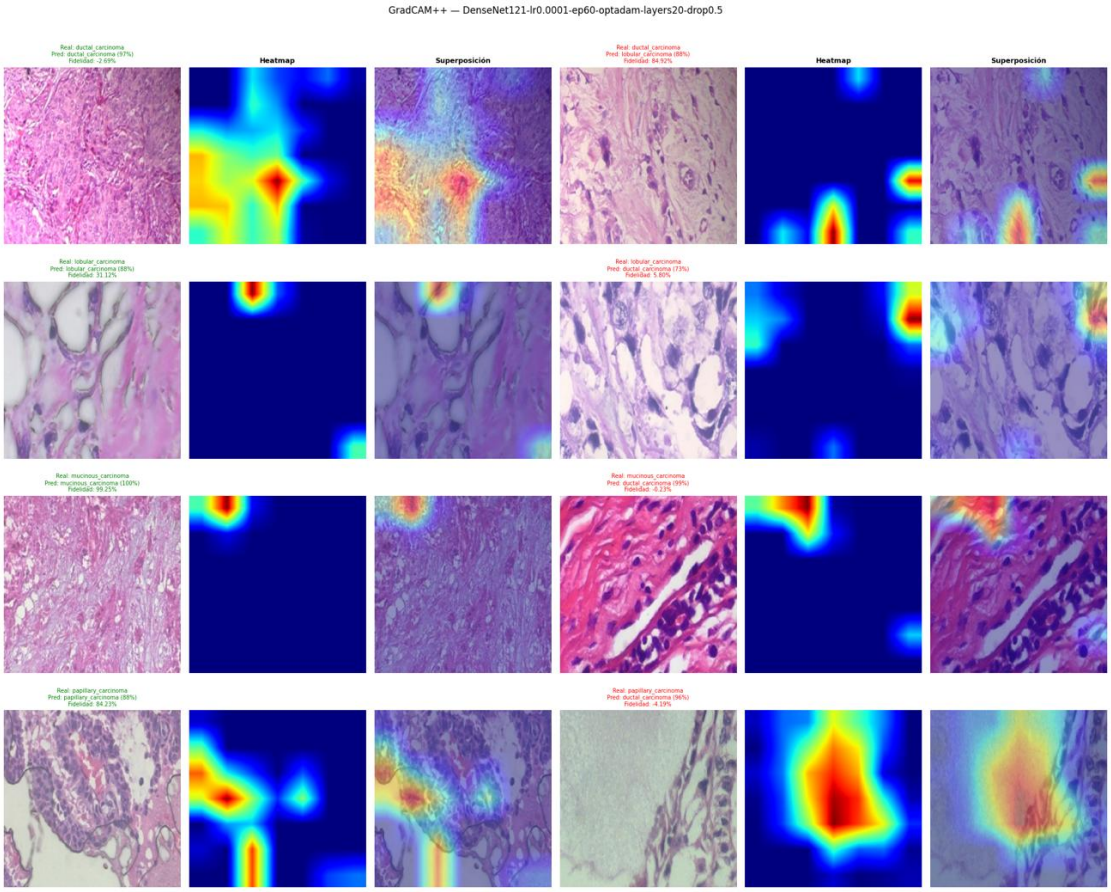

Ilustración 21. Resultados del mejor DenseNet121 con Grad-CAM++
(Fuente: Elaboración propia con Python)

Los mapas de calor muestran un comportamiento interesante. En varios de los ejemplos correctamente clasificados, la atención del modelo se concentra en zonas del tejido

que contienen estructuras morfológicas visibles y, además, esa atención va acompañada de valores de fidelidad altos. Esto se aprecia especialmente en mucinous carcinoma, con una fidelidad cercana al 99 %, y en papillary carcinoma, con un valor superior al 84 %. En ambos casos, el heatmap aparece bastante localizado y la superposición sugiere que la red está utilizando regiones concretas y visualmente relevantes para apoyar su decisión. También en lobular carcinoma se observa una activación razonablemente coherente, aunque con una fidelidad más moderada, lo que indica que la explicación es útil pero menos contundente. El caso más llamativo entre los aciertos es ductal carcinoma, ya que, aunque la predicción es correcta y con una confianza alta, la fidelidad es ligeramente negativa. Esto sugiere que la región resaltada por Grad-CAM++ no coincide claramente con la parte verdaderamente determinante para la decisión del modelo.

En los ejemplos incorrectos, los mapas ayudan a entender mejor el origen del error. En algunos casos, como el de ductal carcinoma clasificado como lobular carcinoma, la fidelidad es alta, lo que indica que el modelo sí se está apoyando en una región concreta e influyente, pero la interpreta de forma incorrecta. En cambio, en otros errores, como los de mucinous carcinoma y papillary carcinoma clasificados como ductal carcinoma, la fidelidad es muy baja o incluso negativa, lo que sugiere que la zona resaltada no está siendo realmente decisiva en la predicción. Esto puede interpretarse como una señal de menor estabilidad explicativa: el modelo se equivoca y, además, el mapa de calor no siempre consigue señalar con precisión la evidencia visual que ha conducido a ese error.

DenseNet121 muestra un comportamiento bastante sólido tanto en clasificación como en interpretabilidad, aunque no de forma totalmente uniforme en todas las clases. Cuando acierta, especialmente en mucinous carcinoma y papillary carcinoma, los mapas de Grad-CAM++ resultan bastante coherentes y apoyan bien la decisión del modelo. Sin embargo, algunos ejemplos, como el de ductal carcinoma, muestran que una predicción correcta no siempre va acompañada de una explicación visual especialmente fiel. Aun así, el balance general es positivo y refuerza la idea de que DenseNet121 es una de las arquitecturas más consistentes dentro de la comparativa del trabajo.

4.6.Conclusión

En conclusión, este análisi ha demostrado que la combinación de Transfer Learning y Grad-CAM++ es una estrategia adecuada para abordar la clasificación automática e

interpretable de los cuatro tipos de tumores malignos del dataset BreaKHis, ya que permite evaluar no solo el rendimiento predictivo de los modelos, sino también la coherencia visual de sus decisiones. A nivel experimental, el uso de técnicas como data augmentation, ponderación de clases, fine-tuning parcial, búsqueda de hiperparámetros y callbacks de regularización ha permitido entrenar las tres arquitecturas en condiciones comparables y estables. En cuanto a los resultados, DenseNet121 ha sido la arquitectura que ha ofrecido el mejor equilibrio entre clasificación e interpretabilidad, seguida muy de cerca por InceptionV3, mientras que ResNet101V2 ha mostrado un peor comportamiento. Los resultados obtenidos confirman que las arquitecturas que mejor aprovechan la reutilización de características y la información multiescala se adaptan mejor a la complejidad de las imágenes médicas, y refuerzan la idea de que la explicabilidad debe considerarse un componente esencial para que este tipo de sistemas pueda ser realmente útil como apoyo al diagnóstico médico.

BIBLIOGRAFÍA

Aditya Chattopadhyay, A. S. (2018). Grad-CAM++: Improved Visual Explanations for Deep Convolutional Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1710.11063

Agnieszka Mikołajczyk-Bareła, M. G. (2018). Data augmentation for improving deep learning in image classification problem. 2018 International Interdisciplinary PhD Workshop (IIPhDW).

Ahmad Chaddad, J. P. (2023). Survey of Explainable AI Techniques in Healthcare. Sensors.

Alex Krizhevsky, I. S. (2012). ImageNet Classification with Deep Convolutional Neural Networks. NeurIPS.

Ali Erdem Ozcelik, N. O. (2025). Optimizing malignancy prediction: A comparative analysis of transfer learning techniques on EBUS images. Clinics.

Ameen, M. (2025). Explainable Mammogram Analysis with EfficientNetV2 and Grad-CAM++ for Robust Cancer Diagnosis. Diagnostics.

Andre Esteva, B. K. (2017). Dermatologist-level classification of skin cancer with deep neural networks. Obtenido de Nature: https://doi.org/10.1038/nature21056

Anqi Mao, M. M. (2023). Cross-Entropy Loss Functions: Theoretical Analysis and Applications. Obtenido de Arxiv: https://arxiv.org/pdf/2304.07288

Azzedine El mrabet, M. B. (2025). Explainable AI for Skin Cancer Classification Unlocking Insights with Grad-Cam and Grad-Cam++. 2025 International Conference on Circuit, Systems and Communication (ICCSC). Fez, Morocco.

Balamurali, J. H. (2022). Transfer Learning and Data Augmentation in the Diagnosis of Knee MRI. AI 2021: Advances in Artificial Intelligence. Sydney.

Bas H.M. van der Velden, H. J. (2022). Explainable artificial intelligence (XAI) in deep learning-based medical image analysis. Medical Image Analysis.

Bedmar, I. S. (2023). Procesamiento del Lenguaje Natural con Aprendizaje Profundo. Obtenido de Universidad Carlos III de Madrid: https://ocw.uc3m.es/pluginfile.php/7195/mod_page/content/5/6-da-ocw2023.pdf

Biblioteca Nacional de Medicina. (2025). Cáncer de Mama. Obtenido de Mediline Plus: https://medlineplus.gov/spanish/ency/article/000913.htm

Bradley, A. P. (1997). The use of the area under the ROC curve in the evaluation of machine learning algorithms. Pattern Recognition.

Castillon, J. G. (2024). Evaluación y Métricas en la Evaluación de Modelos de IA. Obtenido de Dev: https://dev.to/gcjordi/evaluacion-y-metricas-en-la-evaluacion-de-modelos-de-ia-no4

Chávez, C. E. (2023). Sistema automático para la interpretación inmediata de mamografías para la determinación del riesgo de cáncer. Obtenido de Universidad Autónoma de Aguascalientes: http://hdl.handle.net/11317/2583

Chetan L. Srinidhi, O. C. (2021). Deep neural network models for computational histopathology: A survey. Medical Image Analysis.

Chollet, F. (2021). Deep Learning with Python. MANNING.

Christian Szegedy, V. V. (2015). Rethinking the Inception Architecture for Computer Vision. Obtenido de Arxiv: https://arxiv.org/pdf/1512.00567

Christian Szegedy, W. L. (2014). Going deeper with convolutions. Obtenido de Arxiv: https://arxiv.org/pdf/1409.4842

Collazo, N. d. (2020). Predicción en el diagnóstico de tumores de cáncer de mama empleando métodos de clasificación. Revista de Investigación en Tecnologías de la Información, 96-104.

Connor Shorten, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. Journal of Big Data.

Criollo, E. G. (2024). Comparativa de redes de aprendizaje profundo empleando transfer learning para detección de cáncer de mama en el corpus CBIS-DDSM. Obtenido de Repositorio Institucional de la Universidad Politécnica Salesiana: http://dspace.ups.edu.ec/handle/123456789/28664

Cyril Goutte, E. G. (2005). A Probabilistic Interpretation of Precision, Recall and F-Score, with Implication for Evaluation. Advances in Information Retrieval.

David J. Hand, R. J. (2001). A Simple Generalisation of the Area Under the ROC Curve for Multiple Class Classification Problems. Machine Learning.

David Tellez, G. L.-M. (2019). Quantifying the effects of data augmentation and stain color normalization in convolutional neural networks for computational pathology. Medical Image Analysis.

Deepshikha Bhati, F. N. (2024). A Survey on Explainable Artificial Intelligence (XAI) Techniques for Visualizing Deep Learning Models in Medical Imaging. Journal of Imaging .

Diederik P. Kingma, J. L. (2015). ADAM: A METHOD FOR STOCHASTIC OPTIMIZATION. ICLR 2015. Obtenido de Arxiv.

Dinggang Shen, G. W.-I. (2017). Deep Learning in Medical Image Analysis. Annual Review of Biomedical Engineering.

Dominic Masters, C. L. (2018). REVISITING SMALL BATCH TRAINING FOR DEEP NEURAL NETWORKS. Obtenido de Arxiv: https://arxiv.org/pdf/1804.07612

Fabio A. Spanhol, L. S. (2016). A Dataset for Breast Cancer Histopathological Image Classification. Obtenido de IEEE TRANSACTIONS ON BIOMEDICAL ENGINEERING: https://www.inf.ufpr.br/lesoliveira/download/TBME-00608-2015-R2-preprint.pdf

Fatma M. Talaat, S. A.-B. (2024). Grad-CAM Enabled Breast Cancer Classification with a 3D Inception-ResNet V2: Empowering Radiologists with Explainable Insights. Cancers.

Fawcett, T. (2006). An introduction to ROC analysis. Science Direct.

Gao Huang, Z. L. (2018). Densely Connected Convolutional Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1608.06993

GeeksforGeeks. (2021). Adjusting Learning Rate of a Neural Network in PyTorch. Obtenido de GeeksforGeeks: https://www.geeksforgeeks.org/deep-learning/adjusting-learning-rate-of-a-neural-network-in-pytorch/

GeeksforGeeks. (2025). Categorical Cross-Entropy in Multi-Class Classification. Obtenido de GeeksforGeeks: https://www.geeksforgeeks.org/deep-learning/categorical-cross-entropy-in-multi-class-classification/

GeeksforGeeks. (2025). Macro average vs Weighted average. Obtenido de GeeksforGeeks: https://www.geeksforgeeks.org/machine-learning/macro-average-vs-weighted-average/

GeeksforGeeks. (2025). ReLU Activation Function in Deep Learning. Obtenido de GeeksforGeeks: https://www.geeksforgeeks.org/deep-learning/relu-activation-function-in-deep-learning/

GeeksforGeeks. (2025). Softmax Activation Function in Neural Networks. Obtenido de GeeksforGeeks: https://www.geeksforgeeks.org/deep-learning/the-role-of-softmax-in-neural-networks-detailed-explanation-and-applications/

Geert Litjens, T. K. (2017). A Survey on Deep Learning in Medical Image Analysis. Obtenido de Arxiv: https://arxiv.org/pdf/1702.05747

Gelan Ayana, J. P.-W.-W. (2022). A Novel Multistage Transfer Learning for Ultrasound Breast Cancer Image Classification. Diagnostics.

Heikkilä, N. B. (2016). Transfer Learning for Cell Nuclei Classification in Histopathology Images. Obtenido de University of Oulu: https://scispace.com/pdf/transfer-learning-for-cell-nuclei-classification-in-1a4w0k7w77.pdf

HT. (2019). ImageDataGenerator. Obtenido de Medium: https://medium.com/@hackares/imagedatagenerator-bbc935a88f7b

Hugo Chanampe, S. A. (2019). Modelo de redes neuronales convolucionales profundas para la clasificación de lesiones en ecografías mamarias. XXI Workshop de Investigadores en Ciencias de la Computación - WICC 2019. San Juan.

Ian Goodfellow, Y. B. (2016). Deep Learning.

IBM. (s.f.). ¿Qué es la IA explicable? Obtenido de IBM: https://www.ibm.com/es-es/think/topics/explainable-ai

Ibrahem Kandel, M. C. (2020). The effect of batch size on the generalizability of the convolutional neural networks on a histopathology dataset. ICT Express.

Ilya Loshchilov, F. H. (2019). DECOUPLED WEIGHT DECAY REGULARIZATION. ICLR 2019.

Institute, A. C. (s.f.). Papillary carcinoma. Obtenido de Advocate Health Care: https://www.advocatehealth.com/health-services/cancer-institute/cancers-we-treat/breast-cancer/papillary-carcinoma-breast

J, V. (2018). Tutorial on Keras flow_from_dataframe. Obtenido de Medium: https://vijayabhaskar96.medium.com/tutorial-on-keras-flow-from-dataframe-1fd4493d237c

J.A. Gómez Ruiz, J. J. (2000). Un Modelo para la Predicción de Recidiva de Pacientes Operados de Cáncer de Mama (CMO) Basado en Redes Neuronales. Revista Iberoamericana de Inteligencia Artificial, 39-45.

Jason Wang, L. P. (2017). The Effectiveness of Data Augmentation in Image Classification using Deep Learning. Obtenido de Arxiv: https://arxiv.org/pdf/1712.04621

Jason Yosinski, J. C. (2014). How transferable are features in deep neural networks? Obtenido de NeurIPS Proceedings: https://proceedings.neurips.cc/paper_files/paper/2014/file/532a2f85b6977104bc93f8580abbb330-Paper.pdf

Jeff Donahue, Y. J. (2013). DeCAF: ADeepConvolutional Activation Feature for Generic Visual Recognition. Obtenido de Arxiv: https://arxiv.org/pdf/1310.1531

Jonathan de Matos, S. T. (2021). Machine Learning Methods for Histopathological Image Analysis: A Review. Electronics.

Joseph Lemley, S. B. (2017). Smart Augmentation - Learning an Optimal Data Augmentation Strategy. Obtenido de IEEE: 10.1109/ACCESS.2017.2696121

Kaiming He, X. Z. (2015). Deep Residual Learning for Image Recognition. Obtenido de Arxiv: https://arxiv.org/pdf/1512.03385

Karabulut, M. B. (2023). Unveiling the Power of ResNet101v2: A Deep Dive into Image Classification. Obtenido de Medium: https://mtburakk.medium.com/unveiling-the-power-of-resnet101v2-a-deep-dive-into-image-classification-d1a10ad02f29

Karen Simonyan, A. Z. (2015). VERY DEEP CONVOLUTIONAL NETWORKS FOR LARGE-SCALE IMAGE RECOGNITION. ICLR 2015.

Keras. (s.f.). EarlyStopping. Obtenido de Keras: https://keras.io/api/callbacks/early_stopping/

Keras. (s.f.). Image data loading. Obtenido de Keras: https://keras.io/api/data_loading/image/

Keras. (s.f.). InceptionV3. Obtenido de Keras: https://keras.io/2/api/applications/inceptionv3/

Keras. (s.f.). ReduceLROnPlateau. Obtenido de Keras: https://keras.io/api/callbacks/reduce_lr_on_plateau/

Luschi, D. M. (2018). REVISITING SMALL BATCH TRAINING FOR DEEP NEURAL NETWORKS. Obtenido de Arxiv: https://arxiv.org/pdf/1804.07612

Mabrouka Salmi, D. A. (2024). Handling imbalanced medical datasets: review of a decade of research. Artificial Intelligence Review.

Maithra Raghu, C. Z. (2019). Transfusion: Understanding Transfer Learning for Medical Imaging. Obtenido de Arxiv: https://arxiv.org/pdf/1902.07208

Marina Álvarez-Benito, E. E.-C.-M. (2025). Inteligencia artificial en el diagnóstico por imagen de patología mamaria. Revista de Senología y Patología Mamaria - Journal of Senology and Breast Disease.

Marina Sokolova, G. L. (2009). A systematic analysis of performance measures for classification tasks. Information Processing & Management.

Matthew D. Zeiler, R. F. (2013). Visualizing and Understanding Convolutional Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1311.2901

Meena Prakash Ramasamy, T. S. (2024). Performance analysis of breast cancer histopathology image classification using transfer learning models. International Journal of Electrical and Computer Engineering (IJECE).

Min Lin, Q. C. (2014). Network In Network. Obtenido de Arxiv: https://arxiv.org/pdf/1312.4400

Mingxing Tan, Q. V. (2020). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1905.11946

Miriam Hägele, P. S. (2020). Resolving challenges in deep learning-based analyses of histopathological images using explanation methods. Scientific Reports.

Mitko Veta, J. P. (2014). Breast Cancer Histopathology Image Analysis: A Review. Obtenido de IEEE TRANSACTIONS ONBIOMEDICALENGINEERING: https://helios2.mi.parisdescartes.fr/~lomn/Cours/CV/BME/HistoPatho/LongPapers/TBMEHistopathoBreastImageProcessingReview2014.pdf

Musa Adamu Wakili, H. A. (2022). Classification of Breast Cancer Histopathological Images Using DenseNet and Transfer Learning. Computational Intelligence and Neuroscience.

Nadia Harbeck, F. P.-L. (2019). Breast cancer. Nature Reviews Disease Primers.

Neslihan Bayramoglu, J. K. (2016). Deep Learning for Magnification Independent Breast Cancer Histopathology Image Classification. ICPR 2016.

NIH, I. N. (s.f.). carcinoma ductal. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/carcinoma-ductal

NIH, I. N. (s.f.). carcinoma lobulillar. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/carcinoma-lobulillar

NIH, I. N. (s.f.). carcinoma mucinoso. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/carcinoma-mucinoso

NIH, I. N. (s.f.). Metástasis. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/metastasis

NIH, I. N. (s.f.). tinción H y E. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/tincion-h-y-e

Nima Tajbakhsh, J. Y. (2017). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning? Obtenido de Arxiv: https://arxiv.org/pdf/1706.00712

Nitish Srivastava, G. H. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research.

Ocariz, J. P. (2025). Análisis Sistemático de Métodos de Explicabilidad Aplicados al Deep Learning en Oncología. Obtenido de Universidad Politécnica de Madrid: https://oa.upm.es/91155/3/TFG_PASTOR_OCARIZ_JAIME.pdf

Olga Russakovsky, J. D.-F. (2015). ImageNet Large Scale Visual Recognition Challenge. International Journal of Computer Vision.

Opitz, J. (2024). ACloser Look at Classification Evaluation Metrics and a Critical Reflection of Common Evaluation Practice. Obtenido de ACL Anthology: https://aclanthology.org/2024.tacl-1.46.pdf

Panboonyuen, T. (2026). Seeing Isn't Always Believing: Analysis of Grad-CAM Faithfulness and Localization Reliability in Lung Cancer CT Classification. Obtenido de Arxiv: https://arxiv.org/pdf/2601.12826

Powers, D. (2011). EVALUATION: FROM PRECISION, RECALL AND F-MEASURE TO ROC, INFORMEDNESS, MARKEDNESS & CORRELATION . Journal of Machine Learning Technologies.

Prechelt, L. (1997). Early Stopping - but when? Obtenido de Universit•at Karlsruhe: https://page.mi.fu-berlin.de/prechelt/Biblio/stop_tricks1997.pdf

Puay Hoon Tan, I. E. (2020). The 2019 World Health Organization classification of tumours of the breast. Hystopathology.

Ramprasaath R. Selvaraju, M. C. (2019). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. Obtenido de Arxiv: https://arxiv.org/pdf/1610.02391

Reshma Ahmed Swarna, M. M. (2024). Concrete Crack Detection and Segregation: A Feature Fusion, Crack Isolation, and Explainable AI-Based Approach. Journal of Imaging.

Rishi Rai, D. S. (2021). Real-Time Data Augmentation Based Transfer Learning Model for Breast Cancer Diagnosis Using Histopathological Images. Advances in Biomedical Engineering and Technology.

Ruder, S. (2017). Anoverview of gradient descent optimization. Obtenido de Arxiv: https://arxiv.org/pdf/1609.04747

Runzhe Wang, S. M. (2024). THE MARGINAL VALUE OF MOMENTUM. ICLR 2024.

Santora, T. (2025). Información sobre los adenomas de mama: síntomas y tratamientos. Obtenido de BREASTCANCER.ORG: https://www.breastcancer.org/es/afecciones-mamarias-benignas/adenoma

Sergey Ioffe, C. S. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Obtenido de Arxiv: https://arxiv.org/pdf/1502.03167

Shah, A. (2022). Understanding Inception-v3. Obtenido de Medium: https://medium.com/@akshayhitendrashah/understanding-inception-v3-d43fe7ca66a9

Simon Kornblith, J. S. (2019). DoBetterImageNetModelsTransferBetter? Obtenido de Arxiv: https://arxiv.org/pdf/1805.08974

Simón, J. A. (2023). Clasificación y explicabilidad de imágenes tumorales cerebrales con Aprendizaje Profundo (Deep Learning). Obtenido de Universidad de Valladolid: https://uvadoc.uva.es/handle/10324/62839

Sinno Jialin Pan, Q. Y. (2009). A Survey on Transfer Learning. IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING.

Society, A. C. (2022). Adenosis del seno. Obtenido de American Cancer Society: https://www.cancer.org/es/cancer/tipos/cancer-de-seno/afecciones-no-cancerosas-de-los-senos/adenosis-del-seno.html

Society, A. C. (2022). Fibroadenomas del seno. Obtenido de American Cancer Society: https://www.cancer.org/es/cancer/tipos/cancer-de-seno/afecciones-no-cancerosas-de-los-senos/fibroadenomas-del-seno.html

Society, A. C. (2022). Tumores filodes del seno. Obtenido de American Cancer Society: https://www.cancer.org/es/cancer/tipos/cancer-de-seno/acerca/tipos-de-cancer-de-seno/tumores-filoides-del-seno.html

Steven A. Hicks, I. S. (2022). On evaluation metrics for medical applications of artificial intelligence. Scientific Reports.

Suorong Yang, W. X. (2023). Image Data Augmentation for Deep Learning: A Survey. Obtenido de Arxiv: https://arxiv.org/pdf/2204.08610

Sushovan Chaudhury, N. M. (2021). A Novel Approach to Classifying Breast Cancer Histopathology Biopsy Images Using Bilateral Knowledge Distillation and Label Smoothing Regularization. Computational and Mathematical Methods in Medicine.

TensorFlow. (2022). Transferir el aprendizaje y la puesta a punto. Obtenido de TensorFlow: https://www.tensorflow.org/guide/keras/transfer_learning?hl=es-419

TensorFlow. (2024). DenseNet121. Obtenido de TensorFlow: https://www.tensorflow.org/api_docs/python/tf/keras/applications/DenseNet121

TensorFlow. (2024). ResNet101V2. Obtenido de TensorFlow: https://www.tensorflow.org/api_docs/python/tf/keras/applications/ResNet101V2

UFPR, U. F. (2016). Base de datos histopatológica del cáncer de mama (BreakHis). Obtenido de Laboratorio de Visión, Robótica e Imagen: https://web.inf.ufpr.br/vri/databases/breast-cancer-histopathological-database-breakhis/

University, S. (2021). ImageNet. Obtenido de ImageNet: https://www.image-net.org/

Vásquez, D. A. (2025). Desarrollo de un algoritmo basado en transfer learning para el análisis de imágenes médicas de cáncer de mama. Obtenido de Universidad Estatal Península de Santa Elena: https://repositorio.upse.edu.ec/handle/46000/14157

Xia Li, X. S.-Q. (2020). Classification of breast cancer histopathological images using interleaved DenseNetwith SENet(IDSNet). Plos One.

Yann LeCun, L. B. (1998). GradientBased Learning Applied to Document Recognition. Obtenido de Stanford Vision and Learning Lab: http://vision.stanford.edu/cs598_spring07/papers/Lecun98.pdf

Yarin Gal, Z. G. (2016). Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning. Obtenido de Arxiv: https://arxiv.org/pdf/1506.02142

ANEXO 1. DESCARGA DEL DATASET BREAKHIS

Para descargar este dataset hay que usar el link ‘http://www.inf.ufpr.br/vri/databases/BreaKHis_v1.tar.gz’, que se encuentra en la sección ‘How to obtain access to the images’, al final de la web ‘https://web.inf.ufpr.br/vri/databases/breast-cancer-histopathological-database-breakhis/’.

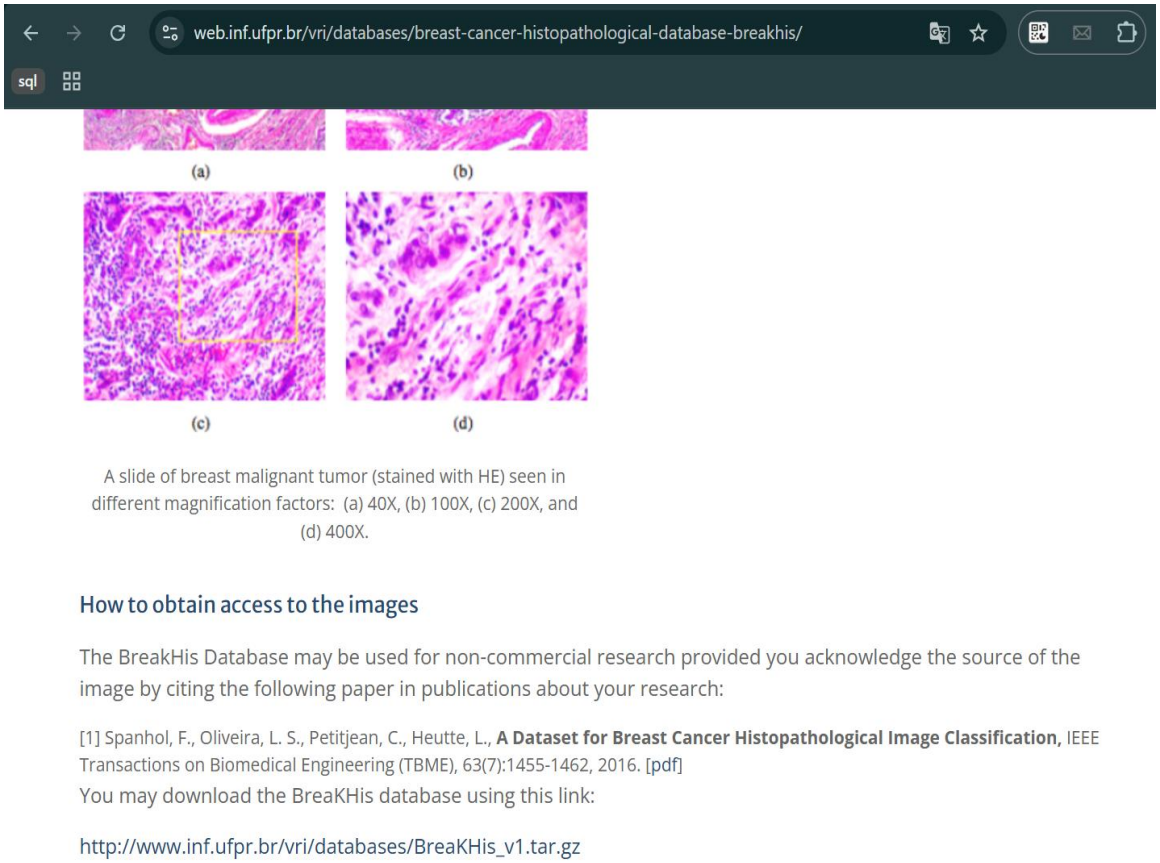

Ilustración 22. Captura de la sección de descarga del dataset BreakHis (Fuente: (UFPR, 2016))

ANEXO 2. COMPROBACIÓN DE LAS CLASES DE LAS IMÁGENES

```
--- ductal_carcinoma ---
SOB_M_DC-14-10926-100-001.png
SOB_M_DC-14-10926-100-002.png
SOB_M_DC-14-10926-100-003.png

--- lobular_carcinoma ---
SOB_M_LC-14-12204-100-015.png
SOB_M_LC-14-12204-100-031.png
SOB_M_LC-14-12204-100-032.png

--- mucinous_carcinoma ---
SOB_M_MC-14-10147-100-001.png
SOB_M_MC-14-10147-100-002.png
SOB_M_MC-14-10147-100-003.png

--- papillary_carcinoma ---
SOB_M_PC-14-12465-100-001.png
SOB_M_PC-14-12465-100-002.png
SOB_M_PC-14-12465-100-003.png
```

Ilustración 23. Comprobación de las clases de las imágenes
(Fuente: Elaboración propia con Python)

ANEXO 3. DISTRIBUCIÓN DE LAS DIMENSIONES

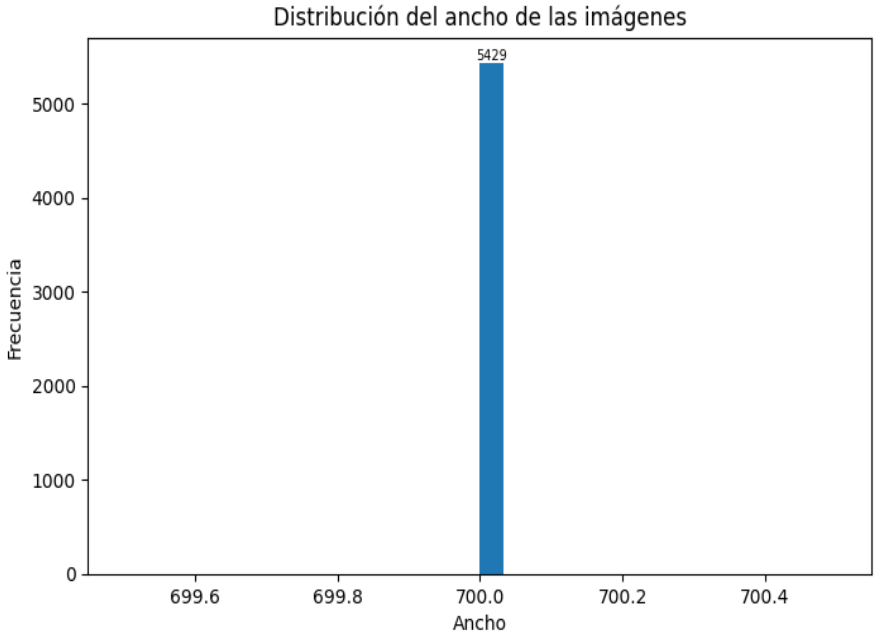

Ilustración 24. Distribución del ancho de las imágenes
(Fuente: Elaboración propia con Python)

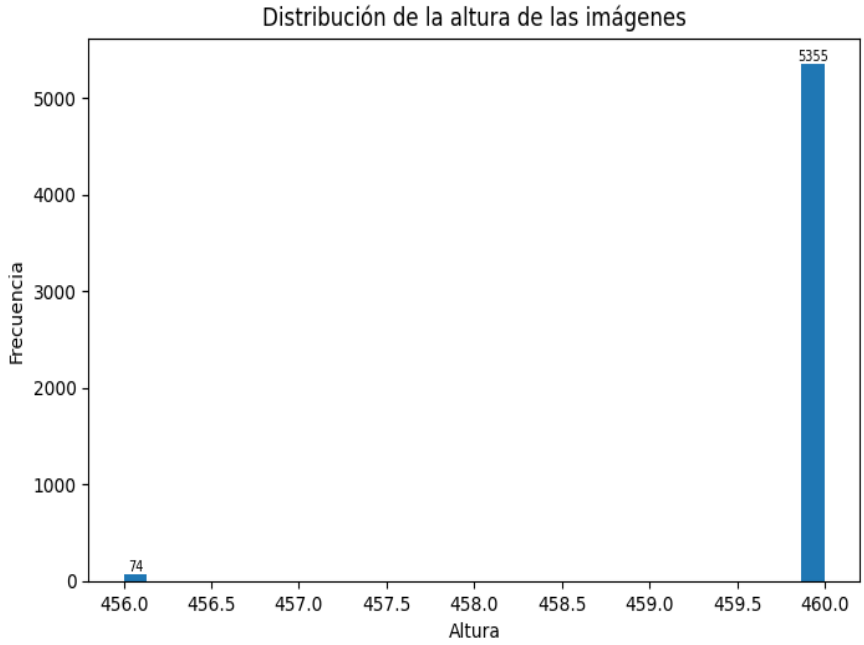

Ilustración 25. Distribución de la altura de las imágenes
(Fuente: Elaboración propia con Python)

ANEXO 4. EJEMPLOS DE IMÁGENES CON DIMENSIONES DISTINTAS

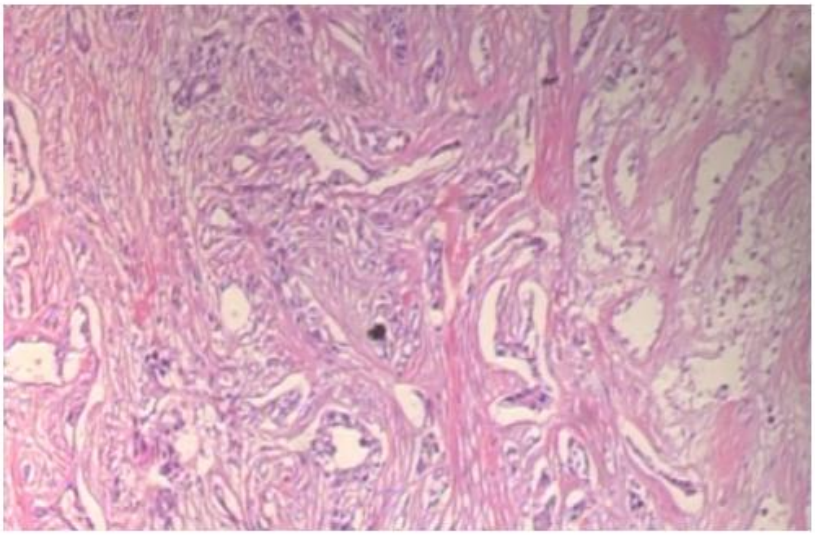

Ilustración 26. Imagen de 700x460
(Fuente: (Fabio A. Spanhol, 2016))

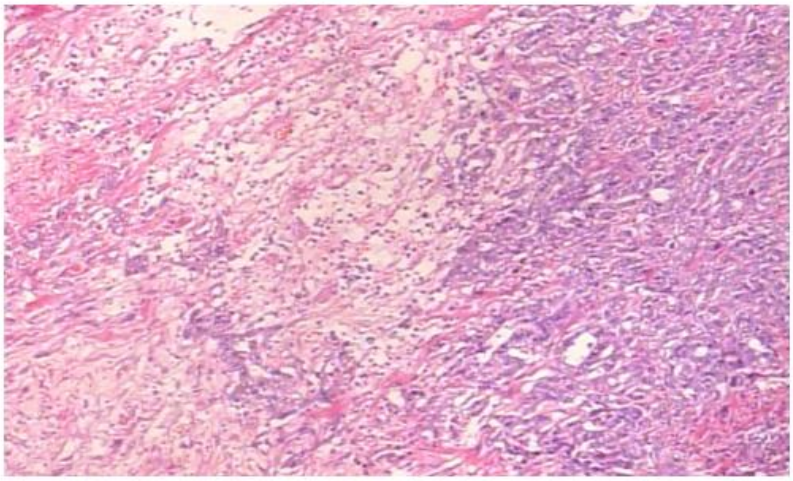

Ilustración 27. Imagen de 700x456
(Fuente: (Fabio A. Spanhol, 2016))

ANEXO 5. DISTRIBUCIÓN DEL MODO Y N.º DE CANALES

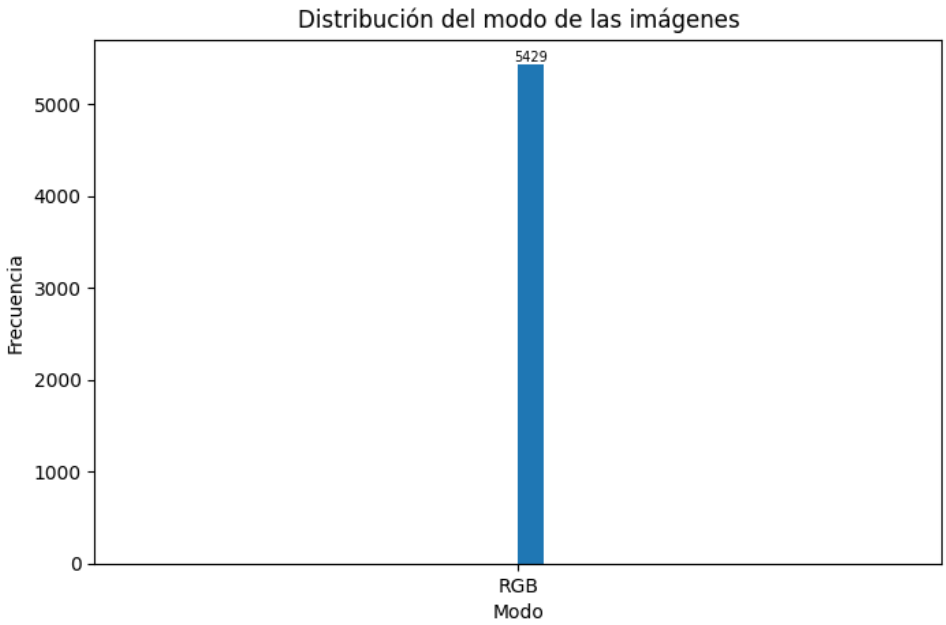

Ilustración 28. Distribución del modo de las imágenes

(Fuente: Elaboración propia con Python)

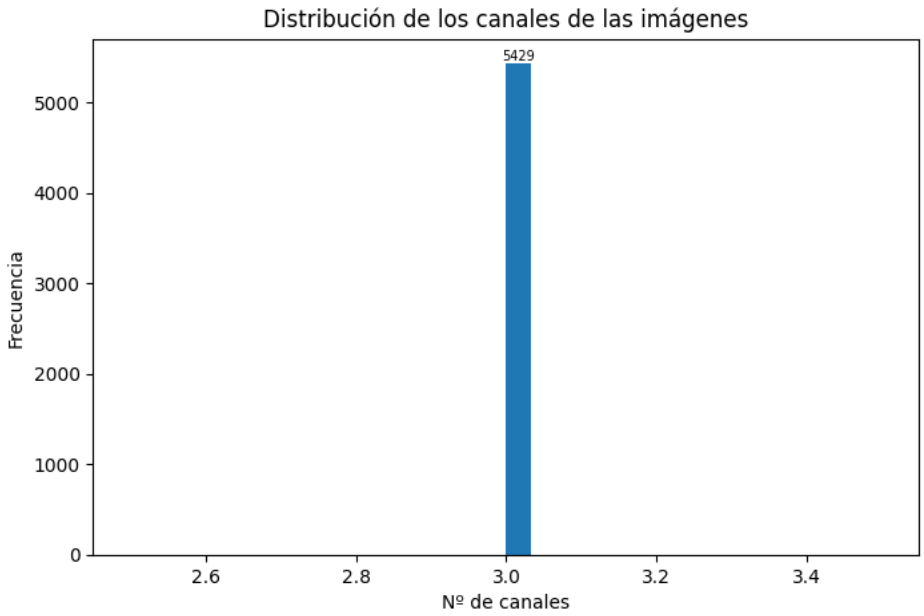

Ilustración 29. Distribución de los canales de las imágenes

(Fuente: Elaboración propia con Python)

ANEXO 6. TRANSFORMACIONES DE DATA AUGMENTATION

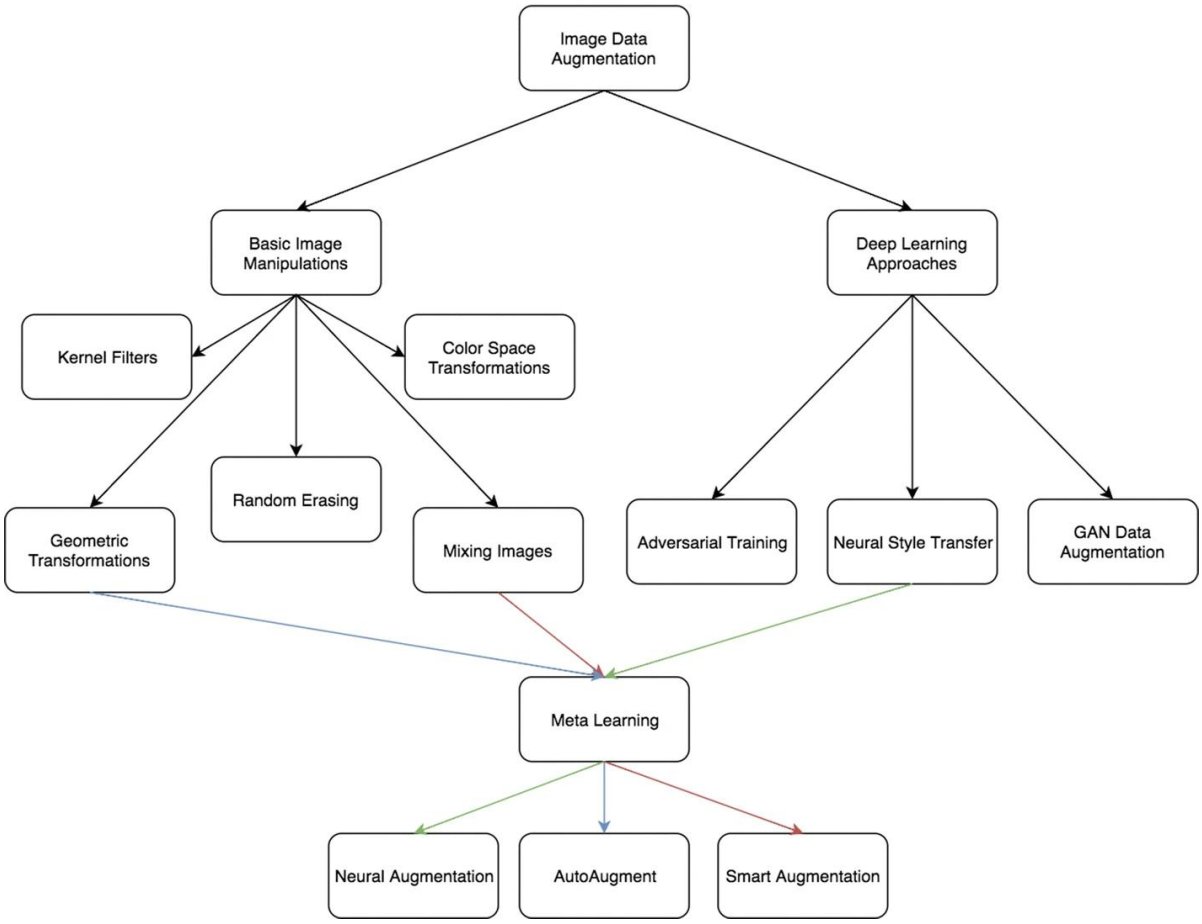

Ilustración 30. Transformaciones de data augmentation

(Fuente: (Connor Shorten, 2019))

ANEXO 7. COMPARACIÓN DE DIFERENTES VALORES DE BATCH SIZE

Table 1. The results of the test AUC of the Adam optimizer.

Test AUC		
Batch size	**Adam LR = 0.0001**	**Adam LR = 0.001**
16	**0.9677**	0.9144
32	0.9636	0.9332
64	0.9616	0.9381
128	0.9567	0.9432
256	0.9585	**0.9652**

Table 2. The results of the test AUC of the SGD optimizer.

Test AUC		
Batch size	**SGD LR = 0.0001**	**SGD LR = 0.001**
16	0.9555	0.9461
32	**0.9570**	0.9521
64	0.9512	0.9545
128	0.9302	0.9567
256	0.9077	**0.9579**

Ilustración 31. Comparación de diferentes valores de batch size (1)

(Fuente: (Ibrahem Kandel, 2020))

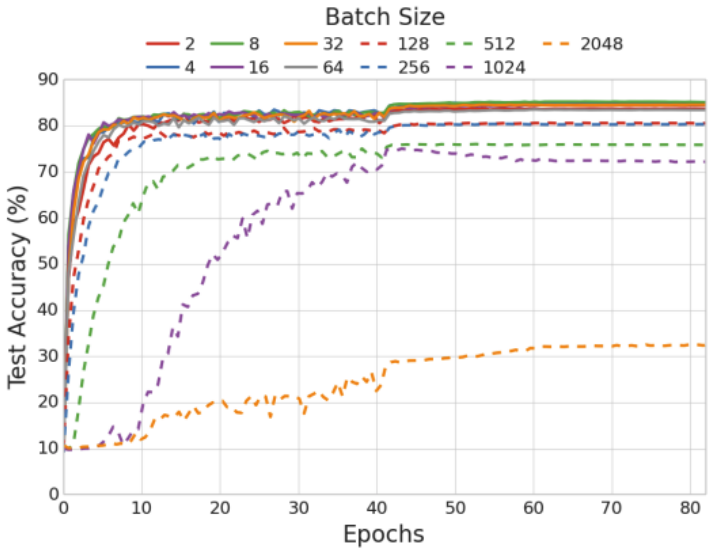

Ilustración 32. Comparación de diferentes valores de batch size (2)

(Fuente: (Dominic Masters, 2018))

ANEXO 8. FÓRMULAS

$$Accuracy = \frac{número\ de\ predicciones\ correctas}{número\ total\ de\ predicciones}$$

Ecuación 1. Fórmula de accuracy

Fuente: (Steven A. Hicks, 2022)

$$Precisión = \frac{muestras\ correctamente\ clasificadas}{muestras\ asignadas\ a\ la\ clase}$$

Ecuación 2. Fórmula de precisión

Fuente: (Steven A. Hicks, 2022)

$$Recall = \frac{muestras\ verdaderamente\ positivas}{muestras\ clasificadas\ como\ positivas}$$

Ecuación 3. Fórmula de recall

Fuente: (Steven A. Hicks, 2022)

$$F1 - score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

Ecuación 4. Fórmula de F1-score

Fuente: (Steven A. Hicks, 2022)

$$Macro\ Average = \frac{1}{K}\sum_{c=1}^{K} Mc$$

Ecuación 5. Fórmula de macro average

Fuente: (GeeksforGeeks, 2025)

$$Weighted\ Average = \frac{1}{N}\sum_{c=1}^{K} nc * Mc$$

Ecuación 6. Fórmula de weighted average

Fuente: (GeeksforGeeks, 2025)

$$TPR = \frac{Verdaderos\ Positivos}{Verdaderos\ Positivos + Falsos\ Negativos}$$

Ecuación 7. Fórmula de weighted average

Fuente: (Fawcett, 2006)

$$FPR = \frac{Falsos\ Positivos}{Falsos\ Positivos + Verdaderos\ Negativos}$$

Ecuación 8. Tasa de falsos positivos

Fuente: (Fawcett, 2006)

$$AUC = \int_0^1 TPR(FPR)d(FPR)$$

Ecuación 9. Fórmula AUC

Fuente: (Bradley, 1997)

$$\mathcal{L} = -\sum_{c=1}^{K} y_c * \ log(\hat{y}_c)$$

Ecuación 10. Fórmula de categorical crossentropy

Fuente: (GeeksforGeeks, 2025)

$$\hat{y}_c = \frac{e^{Z_c}}{\sum_{j=1}^{K} e^{Z_j}}$$

Ecuación 11. Fórmula de softmax

Fuente: (GeeksforGeeks, 2025)

$$f(x) = \max\ (0\ , x)$$

Ecuación 12. Fórmula de ReLU

Fuente: (GeeksforGeeks, 2025)

$$L^c = ReLU\left(\sum_k w_k^c * \ A^k\right)$$

Ecuación 13. Fórmula de la función 'gradcam_plus_plus'

Fuente: (Aditya Chattopadhyay, 2018)

$$w_k^c = \sum_{i,j} \alpha_{ij}^{kc} * ReLU\left(\frac{\partial Y^c}{\partial A_{ij}^k}\right)$$

Ecuación 14. Fórmula del peso de los canales de la función 'gradcam_plus_plus'

Fuente: (Aditya Chattopadhyay, 2018)