CLASIFICACIÓN DE TIPOS DE TUMORES MALIGNOS DE CÁNCER DE MAMA MEDIANTE TÉCNICAS DE TRANSFER LEARNING Y EXPLICABILIDAD

CLASSIFICATION OF MALIGNANT BREAST CANCER TUMOR TYPES USING TRANSFER LEARNING AND EXPLICABILITY TECHNIQUES

Alumno: Felipe Galarza

Email: 9001649@alumnos.ufv.es

Grado en Business Analytics

Curso académico 2025-2026

Resumen

El cáncer de mama es una de las enfermedades con mayor impacto en la población femenina a nivel mundial y para disminuir su riesgo es fundamental detectarlo de forma temprana. En este contexto, este proyecto tiene como objetivo desarrollar un sistema de apoyo al diagnóstico basado en el análisis de imágenes del dataset BreakHis mediante técnicas aprendizaje profundo y explicabilidad. Para ello, se emplean distintas arquitecturas de redes neuronales convolucionales (CNN), como Inception, ResNet y DenseNet, aplicando aprendizaje por transferencia para adaptar modelos pre entrenados al problema planteado. Además, se incorporan técnicas de *data augmentation* con el fin de generar nuevas imágenes artificialmente para añadir variabilidad al dataset y mejorar la capacidad de generalización, especialmente ante la limitada disponibilidad de datos y los problemas de desbalanceo. De esta manera, se compara el rendimiento de las arquitecturas mediante métricas de clasificación y se introduce un enfoque de explicabilidad utilizando Grad-CAM++, con el objetivo de añadir interpretabilidad a las decisiones del modelo y analizar su fiabilidad en un ámbito médico. Los resultados muestran el potencial de estos modelos como herramientas de apoyo al diagnóstico, aunque su rendimiento podría mejorar con más datos y recursos computacionales.

Palabras clave: Cáncer de Mama, Data Augmetation, Redes Neuronales Convolucionales (CNN), Transfer Learning, Explicabilidad, Grad-CAM++

Abstract

Breast cancer is one of the diseases with the greatest impact on women worldwide, and early detection is crucial to reducing the risk. In this context, this project aims to develop a diagnostic support system based on image analysis of the BreakHis dataset using deep learning and explainability techniques. To achieve this, different convolutional neural network (CNN) architectures, such as Inception, ResNet, and DenseNet, are employed, applying transfer learning to adapt pre-trained models to the problem posed. Furthermore, data augmentation techniques are incorporated to artificially generate new images, adding variability to the dataset and improving its generalizability, especially given the limited data availability and imbalance issues. The performance of the architectures is then compared using classification metrics, and an explainability approach is introduced using Grad-CAM++ to add interpretability to the model's decisions and analyze its reliability in a medical setting. The results demonstrate the potential of these models as diagnostic support tools, although their performance could be improved with more data and computational resources.

Key words: Breast Cancer, Data Agmentation, Convolutional Neural Networks (CNN), Transfer Learning, Explainability, Grad-CAM++

ÍNDICE

ÍNDICE DE FIGURAS 6
ÍNDICE DE TABLAS 6
1. INTRODUCCIÓN 1
1.1. Descripción del Problema 1
1.2. Motivación 2
1.3. Estado del arte 4
2. OBJETIVOS 7
2.1. Objetivo General 7
2.2. Objetivos Específicos 8
3. INGENIERÍA DEL DATO 8
3.1. Herramientas utilizadas 8
3.1. Origen de los Datos 9
3.2. Extracción y almacenamiento de los datos 11
3.3. Análisis Descriptivo 12
3.4. Preprocesamiento de los datos 15
3.4.1. División de los datos 16
3.4.2. Data Augmentation 19
3.4.3. Generadores 26
3.5. Conclusión ..... **¡Error! Marcador no definido.**
BIBLIOGRAFÍA 29
Anexo 1. Descarga del dataset BreakHis 33
Anexo 2. Comprobación de las clases de las imágenes 34
Anexo 3. Distribución de las dimensiones 35
Anexo 4. Ejemplos de imágenes con dimensiones distinTas 36
Anexo 5. Distribución del modo y N.º de canales 37
Anexo 6. Transformaciones de data augmentation 38
Anexo 7. Comparación de diferentes valores de batch size 39

ÍNDICE DE FIGURAS

Ilustración 1. Distribución inicial de las imágenes por clase 12
Ilustración 2. Número de imágenes corruptas por clase 15
Ilustración 3. Distribución de imágenes por clase en Train antes del augmentation..... 16
Ilustración 4. Distribución de imágenes por clase en Validation antes del augmentation .. 17
Ilustración 5. Distribución de imágenes en Test antes del augmentation..... 18
Ilustración 6. Distribución de las imágenes en Train después del augmentation 25
Ilustración 7. Captura de la sección de descarga del dataset BreakHis 33
Ilustración 8. Comprobación de las clases de las imágenes 34
Ilustración 9. Distribución del ancho de las imágenes 35
Ilustración 10. Distribución de la altura de las imágenes 35
Ilustración 11. Imagen de 700x460 36
Ilustración 12. Imagen de 700x456 36
Ilustración 13. Distribución del modo de las imágenes 37
Ilustración 14. Distribución de los canales de las imágenes 37
Ilustración 15. Transformaciones de data augmentation 38
Ilustración 16. Comparación de diferentes valores de batch size (1) 39
Ilustración 17. Comparación de diferentes valores de batch size (2) 39

ÍNDICE DE TABLAS

Tabla 1. Distribución de las imágenes en BreakHis 9
Tabla 2. Dimensión, modo y nº de canales de las imágenes 13
Tabla 3. Conteo de dimensiones 13
Tabla 4. Conteo de canales 14
Tabla 5. Parámetros de data augmentation 25
Tabla 6. Parámetros de los generadores para cada set 28

1. INTRODUCCIÓN

1.1. Descripción del Problema

El diagnóstico definitivo del cáncer de mama requiere el análisis de muestras de tejido obtenidas mediante biopsia. Este proceso consiste en la inspección visual de imágenes microscópicas del tejido por parte de un patólogo especializado, quien debe identificar y clasificar el subtipo tumoral en función de las características morfológicas de las células y la arquitectura del tejido. Sin embargo, este proceso presenta limitaciones fundamentales que condicionan su aplicabilidad (Mitko Veta, 2014).

Por un lado, el análisis médico es un proceso altamente especializado, lento y depende de la experiencia del profesional. Se ha señalado que existe una variabilidad intra-observador considerable entre patólogos, lo cual introduce inconsistencias en el diagnóstico (Chetan L. Srinidhi, 2021). Esta idea se refuerza indicando que el análisis de imágenes médicas es una tarea altamente exigente incluso para patólogos experimentados, dando lugar a discrepancias diagnósticas que pueden comprometer el tratamiento del paciente (Jonathan de Matos, 2021).

Por otro lado, la creciente demanda de análisis médicos contrasta con la disponibilidad limitada de especialistas. En ese contexto, los sitemas de Inteligencia Artificial basados en Deep Learning han demostrado una capacidad notable para clasificar imágenes médicas con un rendimiento comparable al de los especialistas. Sin embargo, estos sistemas presentan un problema crítico para su adopción, y es que actúan como cajas negras que generan una predicción sin explicar en qué características de la imagen se han basado. Además, se ha demostrado que la aplicabilidad clínica de estos modelos se ve seriamente limitada precisamente por esta falta de transparencia en el proceso de decisión, ya que ni los analistas de datos ni los médicos son capaces de comprender cómo el modelo llega a su resultado (Miriam Hägele, 2020).

Para abordar este problema, se han desarrollado técnicas de explicabilidad aplicables a redes neuronales convolucionales entre las que se destaca Grad-CAM++. El objetivo de estas técnicas es generar mapas de calor sobre la imagen indicando qué regiones han influido más en la decisión del modelo. Esto permite transformar el sistema de un modelo opaco o de caja negra en una herramienta que ofrece resultados interpretables para que el médico pueda analizar y entender en qué zonas del tejido se ha

fijado el modelo para realizar su diagnóstico. Esto facilita la validación clínica del diagnóstico (Aditya Chattopadhyay, 2018).

En este contexto, el presente proyecto aborda el problema de la clasificación automática e interpretable de los cuatro tipos de tumores malignos de mama presentes en el dataset BreaKHis mediante técnicas de Transfer Learning sobre arquitecturas de redes neuronales convolucionales (CNN) pre entrenadas, combinadas con el algoritmo de explicabilidad Grad-CAM++ para que el sistema tenga transparencia clínica completa.

1.2. Motivación

La motivación de este proyecto surge de la gran cantidad de mujeres que sufren cáncer de mama cada año, llegando la mayoría a morir debido a un diagnóstico tardío. Esto supone una gran preocupación ya que, en muchos de los casos, si se detectase a tiempo, la paciente sería capaz de sobrevivir.

Aunque muchas personas mueran a causa de este cáncer, los avances y las investigaciones que ha habido a lo largo de los años están continuamente ayudando a que la tasa de mortalidad disminuya, ya que permiten que cada vez se diagnostique más rápido (Mayo Clinic, 2025). Esto se debe a que se trata de un cáncer que, en estados avanzados, sobre todo cuando se ha desarrollado metástasis (las células cancerosas viajan a otras zonas del cuerpo a través de la sangre o el sistema linfático y generan un nuevo tumor, haciendo que este se multiplique (NIH, s.f.)) es muy difícil o imposible de curar, por lo que diagnosticarlo lo más pronto posible es lo mejor, ya que un diagnóstico temprano haría que entre un 70% y un 80% de las personas se pueda curar (Nadia Harbeck, 2019).

Existen varios tipos de cáncer de mama que pueden empezar desde cualquier zona de la mama, pero el más común es el carcinoma ductal, que surge en los tubos (conductos) que llevan la leche desde la mama hasta el pezón (Puay Hoon Tan, 2020). El carcinoma lobular es el segundo más común y surge en las partes de las mamas que producen la leche, es decir, los lóbulos. Los otros dos tipos de tumores malignos, menos comunes, son el carcinoma papilar y el mucinoso (Fabio A. Spanhol, 2016).

Además, el tratamiento dependerá del estado en el que se encuentre el cáncer. Este puede presentarse en 5 estados o estadios. Los estadios 0, I, II o III son los más iniciales y su tratamiento se basa en erradicar el cáncer e impedir que reaparezca, mientras que, si se encuentra en un estadio IV, se basa en intentar disminuir los síntomas y alargar el tiempo

de vida, ya que en este estado se considera prácticamente incurable. Incluso si superan el cáncer, los pacientes deberán seguir tomando medicamentos y haciéndose pruebas para vigilar su reaparición. Para conocer el estadio en el que se encuentra también es importante estar pendiente de los síntomas, ya que en las fases iniciales no se suele sufrir ninguno, pero según va creciendo el tumor pueden aparecer bultos, líquidos o cambios notables en la mama o en el pezón; y cuando el tumor se encuentra en un estado muy avanzado se pueden sufrir dolores, dificultad respiratoria, hinchazón y pérdida de peso (Biblioteca Nacional de Medicina, 2025).

Por esto, como ya se ha mencionado antes, es importante que se puedan realizar diagnósticos tempranos para poder identificar los tumores en los estadios iniciales y así poder erradicarlo. Pero, a pesar de los avances en las técnicas de diagnóstico, la interpretación de los resultados sigue siendo un proceso complejo y depende principalmente de la experiencia del médico

En los últimos años, se han desarrollado sistemas de Inteligencia Artificial que han demostrado tener una gran capacidad para realizar diagnósticos. Sin embargo, el problema de estos sistemas es que no explican ni el cómo ni el por qué han llegado a esa conclusión o resultado (Miriam Hägele, 2020). Esto da lugar a que se siga dependiendo del médico para realizar el diagnóstico. Y, aunque se haya demostrado que cuando los sistemas de IA trabajan de forma autónoma son capaces de mantener un rendimiento similar al de un médico, es importante destacar que cuando los médicos han utilizado estas herramientas como apoyo, los resultados en los diagnósticos mejoraron (Marina Álvarez-Benito, 2025). Por ello, el origen de este proyecto surge de la necesidad de crear un método fiable e interpretable que permita al médico apoyarse en el sistema sin perder el control del diagnóstico, reduciéndole el proyecto y permitiéndole centrarse en planificar el tratamiento.

Sin embargo, la aplicación de Deep Learning en imágenes médicas presenta un obstáculo adicional que es la escasez de datos etiquetados. Obtener imágenes médicas clínicas requiere procedimientos invasivos, costes elevados y restricciones éticas, lo que hace que los datasets médicos sean significativamente más pequeños que los utilizados en otras aplicaciones de visión por computador (Geert Litjens, 2017). Esta limitación convierte al Transfer Learning en la solución técnica más adecuada para este tipo de proyectos en lugar de entrenar un modelo desde cero sobre un dataset reducido. Para ello, se parte de arquitecturas ya pre-entrenadas sobre millones de imágenes en ImageNet, que

han aprendido a detectar patrones visuales generales como bordes, texturas y formas, y se adaptan al dominio médico mediante fine-tuning (Nima Tajbakhsh, 2017). Esto permite obtener modelos robustos incluso con los datos disponibles, aprovechando el conocimiento previo acumulado por arquitecturas consolidadas como ResNet, DenseNet o InceptionV3 (Jason Yosinski, 2014).

La intención inicial del proyecto, centrada en comparar el rendimiento de distintas arquitecturas CNN en la clasificación de tumores malignos, evolucionó al detectar que la precisión del modelo por sí sola no es suficiente para que un sistema sea útil en un contexto clínico real. Un modelo que clasifica correctamente pero no explica su decisión seguiría siendo una caja negra inaceptable para el médico. Por ello, se incorporó Grad-CAM++ como componente central del proyecto, no como un añadido opcional, sino como el mecanismo que permite cerrar la brecha entre el rendimiento técnico del modelo y su aplicabilidad clínica real, generando mapas de calor que señalan visualmente en qué regiones del tejido se ha basado el modelo para realizar cada clasificación (Aditya Chattopadhyay, 2018).

1.3. Estado del arte

En los últimos años, la aplicación de técnicas aprendizaje automático y profundo en el ámbito médico ha adquirido una gran importancia, especialmente en el diagnóstico del diagnóstico del cáncer de mama, donde, como se ha mencionado anteriormente, la detección temprana resulta clave para mejorar la supervivencia de los pacientes.

Los avances en este ámbito se han encontrado mediante el uso de modelos de aprendizaje automático aplicados a datasets estructurados, donde algoritmos como máquinas de soporte de vectores (SVM), random forest y redes neuronales demostraron una alta capacidad para clasificar tumores malignos y benignos (Collazo, 2020). Además, se evidenció que el uso de redes neuronales es útil como apoyo al diagnóstico médico por su precisión (J.A. Gómez Ruiz, 2000). Sin embargo, se encontró una gran limitación, ya que estos enfoques dependían de variables extraídas previamente y no eran capaces ofrecer el apoyo al diagnóstico utilizando directamente las imágenes médicas (Chávez, 2023). Esta limitación supone un punto de partida para este proyecto, ya que indica la necesidad de utilizar modelos capaces de trabajar directamente con imágenes, como las redes neuronales convolucionales (CNN).

Los siguientes avances se apoyaron en el aprendizaje profundo, ya que se enfocaron en el análisis directo de imágenes médicas mediante CNN, lo que permitió capturar patrones complejos y relaciones espaciales imposibles de modelar con técnicas más tradicionales (Hugo Chanampe, 2019). De esta manera, en el ámbito del cáncer de mama, también se han aplicado arquitecturas de CNN para el análisis de imágenes mamarias, como ecografías, logrando mejoras significativas en la precisión del diagnóstico (Vásquez, 2025). Pero, a pesar de las mejoras en el diagnóstico, se ha observado que el rendimiento de estos modelos depende principalmente del tamaño y calidad de los datos disponibles y de las estrategias empleadas en el entrenamiento (Ocariz, 2025). En este sentido, se valida el uso de CNN en el ámbito médico y se presenta un principio para uno de los problemas a los que se enfrenta este tipo de proyectos, como lo es la necesidad de optimizar el rendimiento de los modelos con datasets limitados y especializados.

Siguiendo esta línea, se ha demostrado que el uso de técnicas de transfer learning en arquitecturas pre entrenadas de CNN permite mejorar su rendimiento en tareas de clasificación de imágenes médicas, especialmente cuanto se cuenta con datos limitados (Criollo, 2024). Para ello, además se han comparado arquitecturas como VGG, ResNet e Inception, observando mejoras en su capacidad de generalización tras aplicar fine tuning. Destacando Inception al mostrar un buen rendimiento combinando filtros de distintos tamaños dentro de la misma capa, permitiendo capturar información a múltiples escalas (Reshma Ahmed Swarna, 2024). También se ha visto que, de forma complementaria, el uso de técnicas de preprocesado de imágenes como transformaciones de data augmentation, ha sido comúnmente aplicado para incrementar artificialmente la variabilidad del conjunto de entrenamiento, reduciendo el sobreajuste y mejorando la eficacia de los modelos (Vásquez, 2025). Este aspecto resulta relevante para este proyecto, ya que apoya el uso de las dos técnicas en las que se basa, transfer learning y data augmentation.

Además, se han hecho comparaciones de distintas arquitecturas de CNN, para encontrar las que ofrezcan el mejor equilibrio entre precisión, sensibilidad y eficiencia. Arquitecturas de modelos como ResNet han demostrado un alto rendimiento gracias a su capacidad para mitigar problemas como el desvanecimiento del gradiente (Balamurali, 2022). Por otro lado, en modelos como DenseNet, se ha destacado su arquitectura con conexiones densas entre capas, lo que favorece la reutilización de características y mejora la eficiencia en el aprendizaje (Gao Huang, 2018). Esto apoya lo comentado anteriormente

y resalta la necesidad de comparar distintas arquitecturas con diferentes configuraciones como uno de los objetivos de este proyecto.

Como limitación a estos avances, se encuentra la falta de interpretabilidad de los modelos en medicina, lo que limita su uso en este ámbito. En el contexto de las CNNs, los modelos suelen comportarse como cajas negras, dificultando la comprensión del proceso de clasificación para los médicos, lo que supone un obstáculo, ya que en este ámbito no solo es necesario obtener predicciones precisas, sino también comprender cómo se han conseguido para poder interpretar el diagnóstico (Ali Erdem Ozcelik, 2025). Esta necesidad apoya otro de los objetivos de esto proyecto, que es el de poder interpretar los resultados de los modelos entrenados.

Para solucionar esto, surgieron técnicas de Inteligencia Artificial Explicable (XAI), cuyo objetivo es proporcionar interpretaciones comprensibles sobre el comportamiento de los modelos. Entre estas técnicas destacan SHAP y LIME, comúnmente utilizados para explicar modelos de aprendizaje automático con datos estructurados mediante la contribución de cada característica en la predicción (Azzedine El mrabet, 2025). En cambio, para el contexto del análisis de imágenes, se desarrollaron técnicas diseñadas para modelos convolucionales, como Grad-CAM, que permite generar mapas de activación resaltando las regiones de la imagen que más influyen en la predicción del modelo facilitando su interpretación visual, lo que es fundamental para el ámbito médico (Simón, 2023). Siguiendo esta línea, se creó Grad-CAM++ como mejora de Grad-CAM, ya que optimiza la localización de las características relevantes y proporcionan explicaciones más precisas, especialmente cuando existen múltiples regiones de interés dentro de la imagen (Ameen, 2026). El desarrollo de estas técnicas supone un gran avance a la hora aportar herramientas útiles para este proyecto, ya que sirven como soporte para el objetivo de mejorar la interpretación de los resultados de los modelos, sobre todo con Grad-CAM++ al ser la versión mejorada y más útil para el contexto de las imágenes.

También se ha demostrado la utilidad de aplicar estas técnicas en el ámbito médico, ya que no solo mejoran la transparencia de los modelos, sino que aportan una mayor interpretabilidad para que los médicos puedan validar las predicciones de los diagnósticos (Ali Erdem Ozcelik, 2025). En este contexto, la evaluación de la explicabilidad de estas técnicas requiere analizar su fidelidad, entendida como el grado en que las regiones destacadas por el modelo se corresponden con áreas clínicamente relevantes y consistentes

con el diagnóstico (Azzedine El mrabet, 2025). De esta forma, en este proyecto se destaca la importancia de evaluar la fidelidad de Grad-CAM++, ya que va a ser la técnica utilizada.

En conclusión, en el ámbito de las redes neuronales y la medicina ha habido muchos avances en las predicciones de los diagnósticos tanto con datos estructurados como con imágenes. En el contexto de estas últimas se ha comprobado la eficiencia del uso de arquitecturas de CNN combinándolas con técnicas de transfer learning y técnicas de explicabilidad para mejora la interpretación de los resultados con la evaluación de la fidelidad. Esto sugiere una base que este proyecto usará como soporte para tratar de conseguir los objetivos aportando una solución al problema planteado mediante la comparación de distintas configuraciones en arquitecturas, como ResNet, DenseNet e Inception, y la aplicación de Grad-CAM++.

2. OBJETIVOS

2.1. Objetivo General

El objetivo principal de este proyecto se basa en analizar si la aplicabilidad de técnicas de transfer learning y de explicabilidad a distintas arquitecturas de redes neuronales convolucionales para la clasificación de tipos de tumores malignos mediante imágenes microscópicas puede ser eficaz para encontrar la configuración que permita aportar una herramienta para el diagnóstico de cáncer de mama de una manera fácil, precisa y explicativa.

Para ello se personalizarán las arquitecturas de CNN pre entrenadas DenseNet121, ResNet50 y EfficientNetB0 mediante distintas configuraciones, para comparar, mediante métricas de evaluación, su eficacia a la hora de clasificar los distintos tipos de tumores malignos. Además, se analizará la fidelidad con la que el algoritmo de explicabilidad Grad-CAM++ es capaz de indicar la razón de los resultados de los modelos.

2.2. Objetivos Específicos

Para lograr el objetivo general del proyecto hará falta elaborar una pauta en forma de objetivos específicos. Esta consistirá en:

- Analizar la necesidad de aplicar técnicas de preprocesamiento de datos como data augmentation.
- Encontrar la arquitectura y configuración que mejor clasifique los tipos de tumores malignos mediante distintas métricas de evaluación.
- Analizar la fidelidad de Grad-CAM++ para identificar las regiones relevantes en la clasificación de las imágenes.

Para dar respuesta a estos objetivos, y por tanto resolver el objetivo general, se llevará a cabo una metodología basada en la preparación de los datos, desarrollo de los modelos y análisis de los resultados.

3. INGENIERÍA DEL DATO

3.1. Herramientas utilizadas

El proyecto se ha desarrollado en Google Colab, ya que cuenta con más recursos computacionales que el ordenador local. Estos recursos son necesarios, ya que se va a trabajar con imágenes, que son mucho más pesadas que datos numéricos, y arquitecturas redes neuronales pre entrenadas, que requieren de altas capacidades de RAM y GPU para procesar dichas imágenes.

Además, permite trabajar con notebooks en lenguaje Python, que es el que se pretende utilizar debido a la gran cantidad de librerías que posee para trabajar con datos y en concreto, para este caso, con imágenes, redes neuronales y algoritmos de explicabilidad como Tensorflow y Keras, además de Sklearn para las métricas de evaluación de los modelos, Numpy, Matplotlib y Sns para la manipulación y visualización de los datos, y otras librerías útiles para el desarrollo del proyecto.

Por otro lado, Google Colab también permite conectarse con Google Drive facilitando el uso de datasets de imágenes, que suelen ocupar mucho espacio y requieren mucho tiempo de descarga. Sin embargo, al estar almacenados en la nube de Google Drive, la conexión con Google Colab permite acceder a ellos sin tener que descargarlos

reduciendo el uso de memoria y de tiempo. Además, aunque Google Colab trabaja por sesiones y al final de cada una borra todo el entorno incluyendo variables y archivos, esta funcionalidad evita que se tenga que descargar el dataset al principio de cada sesión, lo que es útil para el proyecto, ya que permite trabajar con imágenes y redes neuronales de forma eficiente.

3.1. Origen de los Datos

Los datos con los que se cuenta para este proyecto se han descargado de la web del repositorio público de la Universidad Federal de Paraná (ver cómo en Anexo 1) y provienen de la base de datos Breast Cancer Histopathological Image Classification (BreakHis), construida mediante una colaboración entre dicha universidad y el Laboratorio de I+D – Anatomía Patológica y Citopatología de Paraná, ambos de Brasil. Esta base de datos cuenta con 7909 imágenes microscópicas (con una dimensión de 700x460 píxeles en RGB de 3 canales, profundidad de 8 bits por canal y formato PNG), recogidas de 82 pacientes de cáncer de mama, con diferentes factores de magnificación (40X, 100X, 200X y 400X), siguiendo la siguiente distribución:

Tabla 1. Distribución de las imágenes en BreakHis

Magnification	Benign	Malignant	Total
40X	652	1370	1995
100X	644	1437	2081
200X	623	1390	2013
400X	588	1232	1820
Total of Images	2480	5429	7909

Fuente: (Fabio A. Spanhol, 2016)

Estas imágenes se obtuvieron mediante el método SOB (Biopsia Quirúrgica Abierta), también conocido como mastectomía parcial o biopsia por escisión, mediante el cual se extrae una muestra de tejido de mayor tamaño que por biopsia con aguja.

Los tumores, benignos y malignos, se clasifican en distintos tipos y subtipos según su apariencia en el microscopio y cada uno de estos tipos ofrece un pronóstico diferente y tiene unas implicaciones terapéuticas diferentes:

- **Benignos**:
    - **Adenosis (A):** Afección benigna del seno en la que los lobulillos del seno están agrandados y hay más glándulas de lo normal (Society, 2022).
    - **Fibroadenoma (F):** Tumores de los senos comunes compuestos por tejido granular y tejido estromal (conectivo). Tienen forma ovalada o redonda y se pueden sentir como una canica o balín dentro del seno (Society, 2022).
    - **Tumor filodes (PT):** Tumores poco comunes que comienzan en el tejido conectivo y no en los conductos ni en las glándulas (Society, 2022).
    - **Adenoma Tubular (TA):** Tumores poco comunes similares a los fibroadenomas en aspecto y tacto, pero diferentes ante el microscopio (Santora, 2025).
- **Malignos:**
    - **Carcinoma ductal (DC):** Cancer de seno más común, que empieza en el revestimiento de los conductos galactóforos (tubos que llevan la leche desde los lobulillos hasta el pezón). Puede ser in situ (CDIS), donde las células anómalas se encuentran en el revestimiento de los conductos, o invasivo, donde las células anómalas se expanden fuera de los conductos a otras partes del cuerpo (NIH, s.f.)
    - **Carcinoma lobulillar (LC):** Cáncer similar al ductal pero que empieza en los lobulillos (o glándulas lácteas), en lugar de en los conductos. También puede ser in situ (CLIS) o invasivo (NIH, s.f.).
    - **Carcinoma mucinoso (MC):** Cáncer que comienza en células que revisten ciertos órganos internos y que se caracterizan por la producción de mucina (componente principal del moco) (NIH, s.f.).
    - **Carcinoma papilar (PC):** Cáncer poco común que se origina en los conductos mamarios y se caracteriza por la presencia de crecimientos o proyecciones digitiformes. También puede ser in situ o invasivo, además de encapsulado, contenido en una cápsula fibrosa dificultando la diseminación, o sólido, presentado como masas sólidas (Institute, s.f.).

En el dataset, cada archivo de imagen almacena información sobre la imagen indicando el método de biopsia, la clase de tumor, el tipo, identificación del paciente, factor de magnificación y número de la imagen; por ejemplo, de esta manera: **SOB_B_TA-14-4659-40-001.png** (Fabio A. Spanhol, 2016).

De esta manera se obtienen los datos originales que se analizarán y procesarán para su uso en los modelos.

3.2. Extracción y almacenamiento de los datos

Como se ha explicado anteriormente, el objetivo de este proyecto se basa en identificar los distintos tipos de tumores malignos. Por ello, solo se han mantenido estos tumores del dataset. Además, como la estructura del dataset original se divide en **clase de tumor > tipo de tumor > factor de magnificación**, y se quiere simplificar teniendo únicamente los tipos, pero manteniendo la variabilidad, se han mezclado los factores de magnificación por los tipos dejando la siguiente estructura: **Malignos > Tipos de tumor.**

Para esto, como el dataset original se encuentra en formato tar.gz de 4GB, lo cual es muy pesado para Google Colab, primero se subió a Google Drive, aprovechando la conexión entre ambos programas. Una vez en drive, se extrajo el contenido guardando las imágenes con la estructura de carpetas original en Google Colab, evitando así duplicar el uso de memoria (si se hubiera subido directamente a Google Colab habría ocupado la memoria del tar.gz original y de la carpeta con las imágenes extraídas). Una vez se tienen las imágenes originales, se creó otra carpeta de 'Malignos', con la estructura simplificada, donde se almacenaron las imágenes correspondientes a cada tipo y se guardaron en sus respectivas carpetas mezclando los distintos factores de magnificación.

Para asegurarse de que las imágenes se han guardado de manera correcta en el dataset final, se ha comprobado que los nombres de los archivos de las imágenes coincidan con la carpeta de su tipo. Y se ha observado (ver Anexo 2) que las imágenes DC corresponden a la carpeta ductal_carcinoma, las imágenes LC corresponden a la carpeta lobular_carcinoma, las imágenes MC corresponden a la carpeta mucinous_carcinoma y las imágenes PC corresponden a la carpeta papillary_carcinoma. Por lo que el dataset se habría creado con la estructura correcta para poder analizarlo.

3.3. Análisis Descriptivo

Una vez se obtuvieron las imágenes con las que se quiere trabajar, se analizaron mediante un análisis descriptivo para conocer si existían imágenes corruptas, el número final de observaciones, su distribución en las clases, sus dimensiones y canales.

Distribución de las clases y número de observaciones

Se observó que en el dataset final se cuentan con 5429 imágenes distribuidas en 3.451 para carcinoma ductal (con etiqueta ductal_carcinoma), 626 para carcinoma lobular (con etiqueta lobular_carcinoma), 792 para carcinoma mucinoso (con etiqueta mucinous_carcinoma) y 560 para carcinoma papilar (con etiqueta papillary_carcinoma)

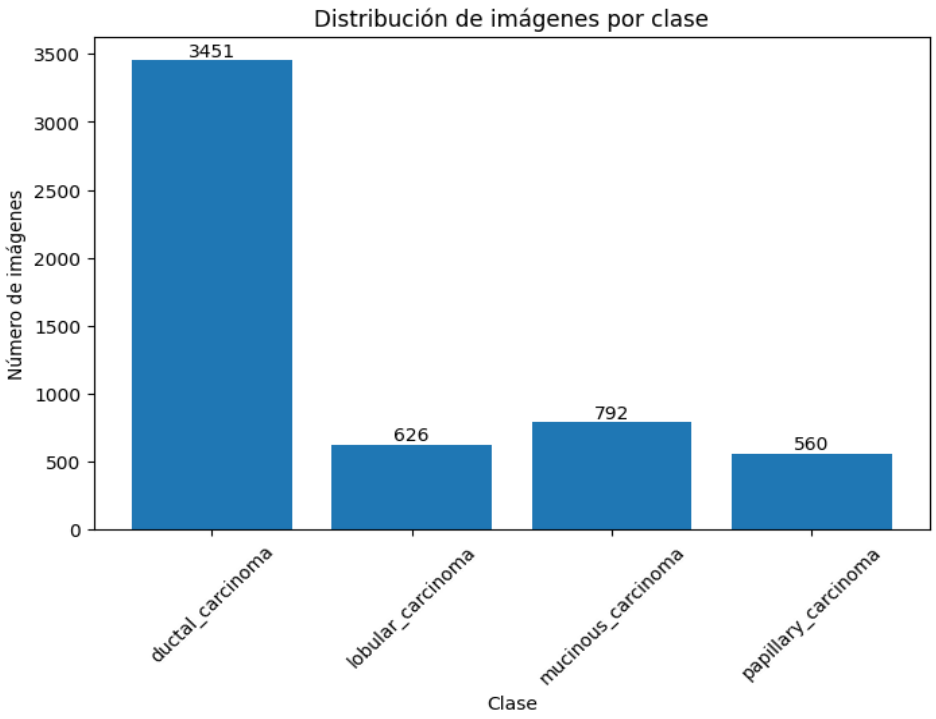

Ilustración 1. Distribución inicial de las imágenes por clase
(Fuente: Elaboración propia con Python)

Como se puede ver en el gráfico, había una gran diferencia entre al carcinoma ductal y el resto de los tipos, algo normal al ser el tipo de cáncer de mama más común. Esto daría lugar a un desbalanceo claro entre la clase ductal_carcinoma y el resto de las

clases, más equilibradas entre ellas. Este desbalanceo se trataría más adelante mediante técnicas de data augmentation.

Análisis de las dimensiones y canales

Posteriormente, se han presentaron las observaciones en forma de dataframe para comprobar las dimensiones, el modo y el número de canales de las imágenes:

Tabla 2. Dimensión, modo y nº de canales de las imágenes

Index	Class	Filename	Width	Height	Mode	Channels
0	ductal_carcinoma	SOB_M_DC-14-2985-100-001.png	700	460	RGB	3
3451	lobular_carcinoma	SOB_M_LC-14-16196-100-010.png	700	460	RGB	3
4093	mucinous_carcinoma	SOB_M_MC-14-19979C-400-011.png	700	460	RGB	3
5424	papillary_carcinoma	SOB_M_PC-14-15687B-40-007.png	700	460	RGB	3

Fuente: Elaboración propia con Python

Como se ve, se confirmó que en general las imágenes presentaban unas dimensiones de 700x460 en modo RGB con 3 canales.

Además, se va a comprobó que todas las imágenes presentaran las mismas dimensiones, mediante el conteo y la distribución (ver Anexo 3) de estas.

Tabla 3. Conteo de dimensiones

width	height	count
700	456	74
700	460	5.355

Fuente: Elaboración propia con Python

Finalmente se observó que la mayoría de las imágenes presentaba una dimensión de 700x460, mientras que 74 tenían una dimensión de 700x456. Pero, al comprobar ejemplos de imágenes con ambas dimensiones (ver Anexo 4), se observó que la diferencia en la dimensión era mínima y, que además al tratarse de un pequeño número de imágenes no tendría un gran efecto en los modelos. También, el efecto de esta diferencia de tamaño sería nula, ya que más adelante se aplicaría un redimensionamiento a todas las imágenes porque los modelos pre entrenados requieren un tamaño de entrada de imagen específico.

También se comprobó que todas imágenes presenten el mismo número de canales y modo, mediante el conteo y la distribución (ver Anexo 5) de estos.

Tabla 4. Conteo de canales

Mode	Channels	Count
RGB	3	5.429

Fuente: Elaboración propia con Python

Se observó que todas las imágenes son iguales en modo, y por tanto en canales, siendo estos RGB y 3, respectivamente.

Identificación de imágenes corruptas

Finalmente, se comprobó si existen imágenes corruptas dentro del dataset:

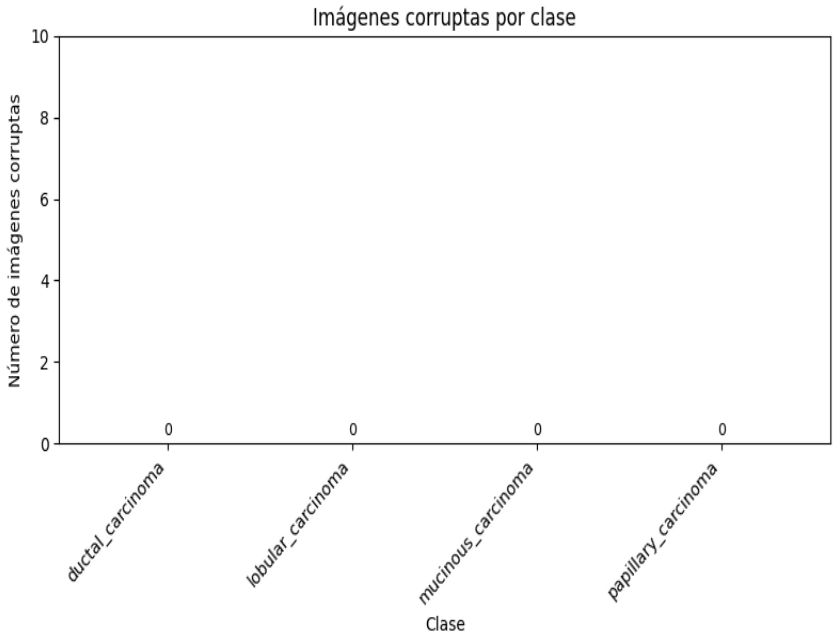

Ilustración 2. Número de imágenes corruptas por clase
(Fuente: Elaboración propia con Python)

Se observó que no existían imágenes corruptas, por lo que todas eran válidas para usarlas en el análisis.

3.4. Preprocesamiento de los datos

Una vez hecho el análisis y la comprobación de la validez de las imágenes del dataset, se preprocesaron para prepararlas para los modelos.

En este proceso de preprocesado se dividieron las imágenes en train, validation y test, para después aplicar las técnicas de data augmentation, arreglando el problema de desbalanceo de clases, y se crearon los generadores, donde se definió el tamaño del batch para cada epoch durante el entrenamiento de los modelos (el número de imágenes que se cargará) y se normalizaron y redimensionaron las imágenes a las medidas requeridas por estos.

3.4.1. División de los datos

Primero se hizo la división los datos para poder entrenar y validar los modelos correctamente. Para ello las imágenes se dividieron en 3 sets:

Train

Este set es el mayoritario con un 70% de los datos, ya que son los que el modelo utiliza para aprender a clasificarlos, con la siguiente distribución:

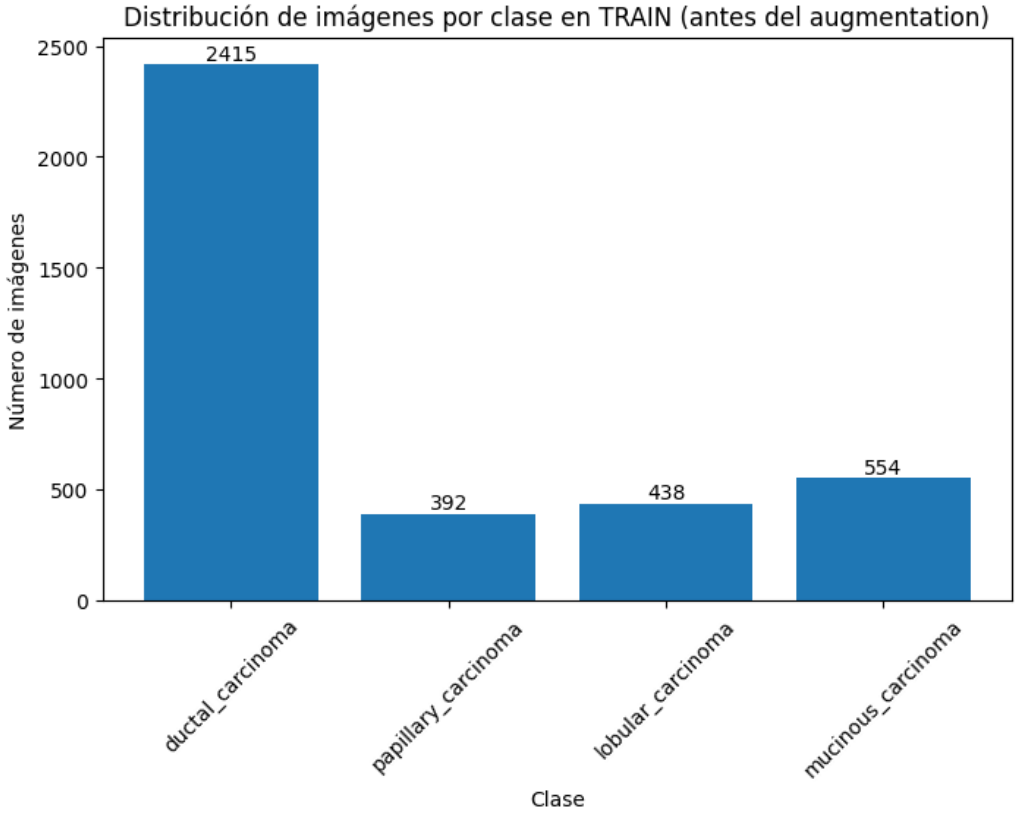

Ilustración 3. Distribución de imágenes por clase en Train antes del augmentation
(Fuente: Elaboración propia con Python)

Validation

Este set cuenta con el 15% de los datos, que son los que el modelo utiliza durante el entrenamiento para validar su aprendizaje en curso, con la siguiente distribución:

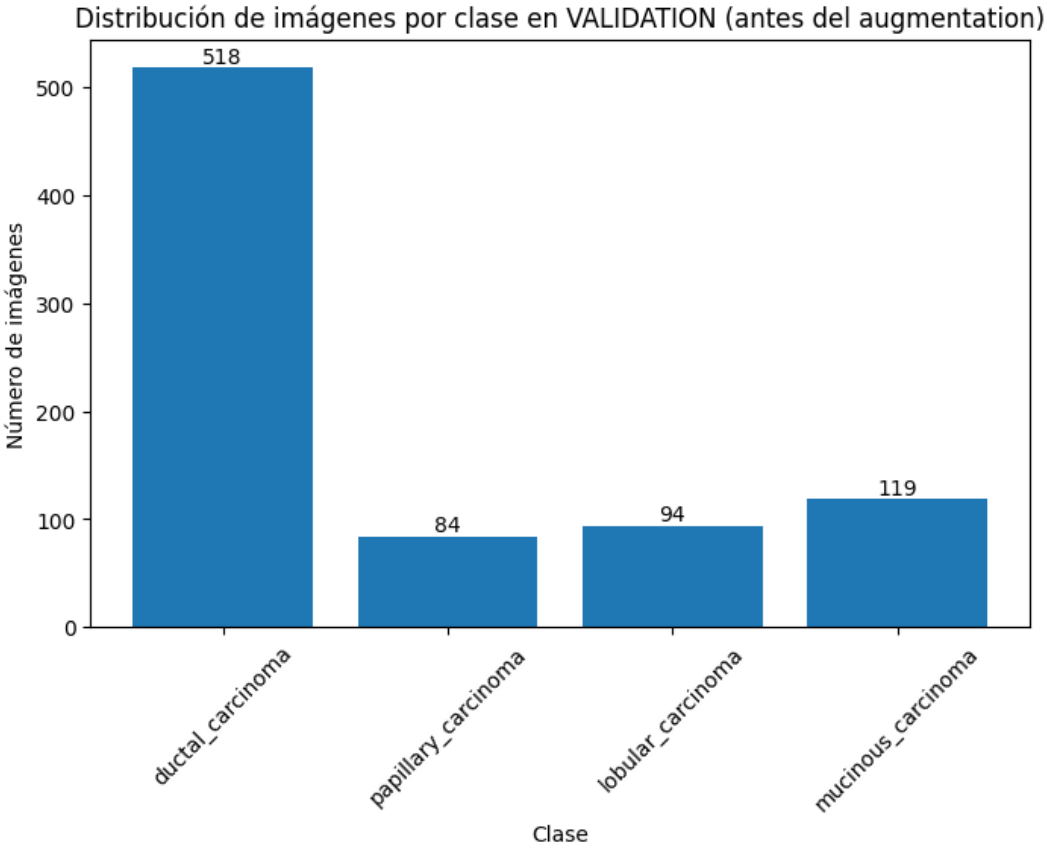

Ilustración 4. Distribución de imágenes por clase en Validation antes del augmentation (Fuente: Elaboración propia con Python)

Test

Este set también cuenta con un 15% de los datos y son imágenes que no se utilizan durante el entrenamiento, sino que se utilizan como datos nuevos en el modelo ya entrenado para evaluar su capacidad de generalización en la clasificación de las clases y, por tanto, su aplicación en casos nuevos. Al ser del mismo tamaño que el set de validación, sigue la misma distribución:

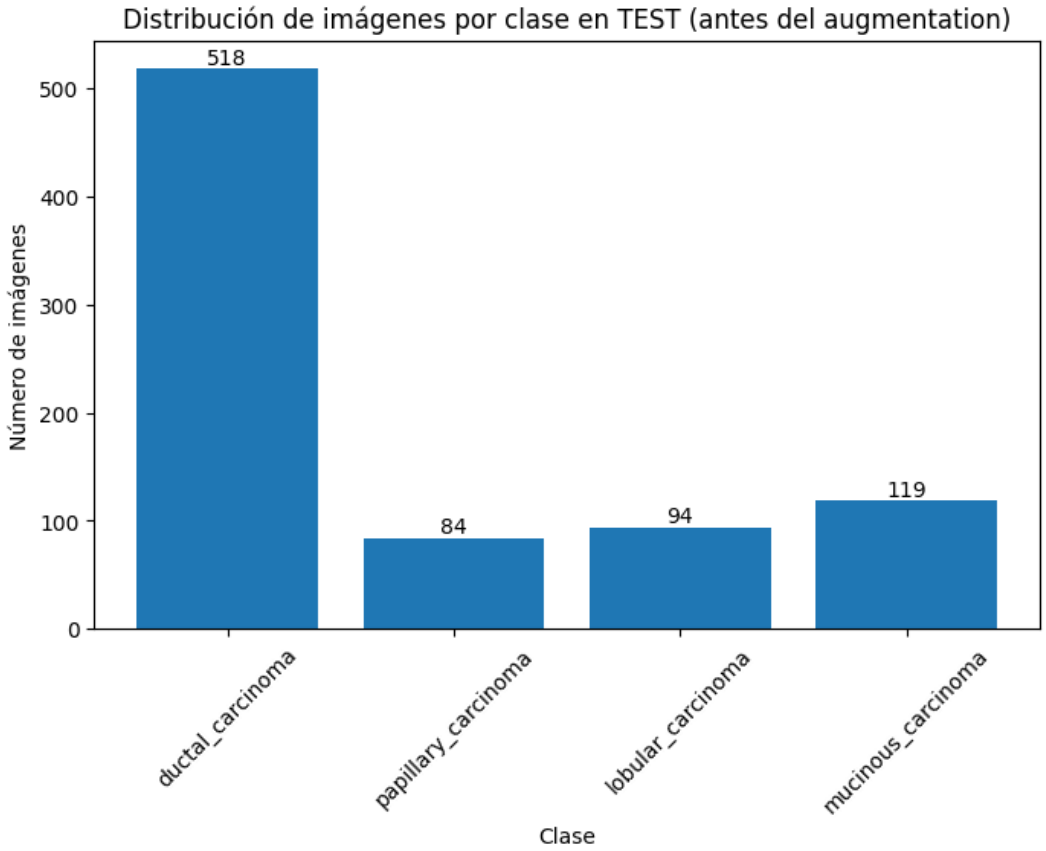

Ilustración 5. Distribución de imágenes en Test antes del augmentation
(Fuente: Elaboración propia con Python)

Para la división de estos sets se ha seguido una metodología que ha permitido mantener los porcentajes descritos con simplicidad. Primero se han divido el total de las imágenes en 70% para train y 30% a un set temporal, que luego se dividió en validation y test con 15% para cada set. Además, se siguió esta metodología, ya que la clase train_test_split de la librería sklearn solo permite dividir el dataset en dos partes por lo que fue necesario hacer dos divisiones.

Este paso es fundamental hacerlo antes de aplicar data augmentation, ya que esta técnica se aplica con el objetivo de regularizar el modelo mediante su aprendizaje, por lo que solo se utiliza en el set de train. En cambio, si se aplicase a los sets de validation y test, alteraría la distribución de la evaluación (Ian Goodfellow, 2016). Esto ocurre, ya que se aportaría una variabilidad innecesaria en esta parte, haciendo que las métricas reflejen el rendimiento del modelo entrenado sobre imágenes modificadas en lugar reales, produciendo una estimación optimista que no es representativa ni real (Connor Shorten, 2019).

3.4.2. Data Augmentation

Data augmentation es una técnica de regularización que consiste en generar nuevas muestras de entrenamiento aplicando transformaciones controladas sobre los datos originales, ampliando de forma artificial el tamaño y la diversidad del dataset sin tener que recopilar nuevos datos reales. Además, lo identifican como una de las técnicas más efectivas para combatir el overfitting en modelos de Deep learning con datasets de tamaño pequeño y mediano. En el caso de datasets de imágenes, las transformaciones aplicadas como las rotaciones, los desplazamientos, los cambios de escala, los flips y las variaciones de brillo generan imágenes que son distintas a nivel de píxel pero que preservan la etiqueta de la clase, ya que el contenido semántico y diagnóstico de la imagen no se altera (Connor Shorten, 2019).

La utilidad de esta técnica es que actúa como un regularizador implícito, ya que como el modelo recibe versiones ligeramente diferentes de cada imagen en cada época de entrenamiento, este no puede limitarse a memorizarlas, lo que le obliga a identificar las características visuales que realmente definen cada clase, como la morfología celular o la arquitectura del tejido. De esta forma, se reduce error de generalización al aumentar el espacio de ejemplos que el modelo ve durante el entrenamiento, lo que da lugar a un modelo más robusto frente a imágenes nuevas (Ian Goodfellow, 2016).

Además, presenta una solución para estudios en el ámbito médico, ya que uno de los principales obstáculos en el desarrollo de modelos de Deep Learning es la escasez de datos etiquetados. Esto ocurre porque la adquisición de imágenes médicas reales implica procedimientos clínicos invasivos, costes elevados y restricciones tanto éticas como de

privacidad de los datos. Sin embargo, al aplicar esta técnica se evita la necesidad de adquirir nuevas imágenes mitigando este problema (Geert Litjens, 2017).

Por otro lado, en el dataset de este proyecto, como se ha visto anteriormente existe un desbalanceo notable en las clases, lo que, incluso ya en el dataset original de BreakHis, supone una gran limitación (Fabio A. Spanhol, 2016). Por ello se ha decidido aplicar la técnica de data augmentation, la cual ha demostrado ser útil para solucionar esta limitación en el dataset original mejorando las métricas de evaluación en todas las arquitecturas utilizadas (Agnieszka Mikołajczyk-Bareła, 2018).

Al haber un desequilibrio de alrededor de 2000 imágenes entre la clase ductal_carcinoma y el resto de las clases, puede haber un sesgo en el aprendizaje del modelo hacia las clases mayoritarias, lo cual reduce la capacidad de clasificar correctamente las clases minoritarias.

Por ello se ha decidido generar nuevas imágenes en las clases minoritarias hasta alcanzar un número total de 2000 imágenes como máximo en cada clase, ya que la clase mayoritaria, ductal_carcinoma, tiene aproximadamente 2400 imágenes en el set de train. De esta manera se garantiza que el modelo recibe una cantidad similar de imágenes de cada una de las cuatro clases durante el entrenamiento, eliminando así el sesgo que se puede producir por el desbalanceo.

Aunque la clase mayoritaria presenta cerca de 2400 imágenes, se ha decidido poner el límite de 2000 en el resto de las clases, ya que, si se trataran de igualar todas exactamente al mismo número de imágenes, las imágenes generadas podrían dominar las originales, provocando que el modelo aprenda más sobre datos sintéticos que sobre datos reales (Connor Shorten, 2019). Además, las nuevas imágenes suponen un aumente de aproximadamente el 85% en las clases minoritarias, lo cual es un ratio elevado, pero justo y necesario por el desequilibrio extremo que se presenta. Así, el desbalanceo disminuye drásticamente presentando una diferencia bastante menor entre la clase mayoritaria y las minoritarias, la cual se terminará de ajustar mediante el uso de pesos en los modelos.

Para aplicar esta técnica, se siguió una metodología común en este tipo de proyectos (Jason Wang, 2017). Primero se estableció que por cada clase que no alcanzaba el límite de 2000 imágenes se seleccione de forma aleatoria una imagen original del conjunto de entrenamiento de esa clase, a la que se le aplicarían las transformaciones configuradas de forma independiente y aleatoria, resultando una imagen que se guarda

como una muestra nueva en la misma carpeta de la clase. Este proceso se repetiría hasta alcanzar aproximadamente 2000 imágenes por clase. De esta manera, las imágenes originales se conservan intactas y las generadas se añaden como muestras adicionales.

Este enfoque corresponde a la augmentation offline, ya que las transformaciones se aplican a los datos antes del entrenamiento, lo que permite tener un control explícito sobre el tamaño final del dataset. Esto supone una ventaja frente a la augmentation online, en la cual las transformaciones definidas se aplican en tiempo real durante el entrenamiento, limitando el control del número de datos con los que el modelo está aprendiendo (Joseph Lemley, 2017).

Dentro de data augmentation existe una gran variedad de técnicas (ver en Anexo 6), que incluyen transformaciones geométricas, manipulaciones del espacio de color, mezcla de imágenes, borrado aleatorio, generación sintética mediante redes generativas adversiales (GANs), etcétera (Bedmar, 2023).

Debido a la gran variedad de transformaciones que existen, la selección de estas tiene que ser adecuada dado el contexto en se está trabajando. Esta decisión es importante, ya que no todas las transformaciones son igual de válidas para todas las tareas y su aplicación inapropiada puede reducir el rendimiento del modelo (Suorong Yang, 2023).

En el caso de las imágenes médicas, como las del dataset de este proyecto, las transformaciones válidas son únicamente aquellas que preservan el contenido de la imagen, es decir, que no alteran la morfología celular, la arquitectura del tejido ni la información cromática relevante para el diagnóstico. Teniendo esto en cuenta, se descartaron transformaciones como el borrado aleatorio o el recorte agresivo ya que eliminarían estructuras médicas relevantes. Además, las transformaciones de color extremas, las cuales alterarían la información de tinción H&E (método para visualizar mejor las diferentes partes de la célula al microscopio mediante tintes de hematoxilina y eosina (NIH, s.f.)), son también descartadas. Por ello, las transformaciones seleccionadas son la rotación moderada, desplazamiento, zoom, flip horizontal, variación de brillo suaves, desplazamiento de canales ligero y relleno de píxeles; las cuales son las más utilizadas para la clasificación de imágenes médicas porque introducen variabilidad suficiente para mejorar la generalización del modelo, sin comprometer la información de diagnóstico (David Tellez, 2019).

Rotation range

Esta transformación consiste en la rotacion de la imagen hacia la izquierda o hacia la derecha entre 1º y 359º. Este tipo de transformación está determinado por el grado de rotación del parámetro, ya que las rotaciones suaves se consideran útiles en tareas de detección de dígitos como MNIST (Modified National Institute of Standards and Technology) (Connor Shorten, 2019). En cambio, respecto a las imágenes médicas, no existen reglas relacionadas con la orientación, ya que un tejido puede aparecer en cualquier ángulo dependiendo de cómo se haya cortado la muestra. En este contexto, se ha demostrado que las rotaciones moderadas entre 10º y 30º mejoran la generalización en la clasificación de tejidos, mientras que rotaciones mayores pueden distorsionar las estructuras morfológicas relevantes para el diagnóstico, afectando de manera negativa a los resultados del modelo (David Tellez, 2019). Además, este tipo de transformación es una de las más naturales y efectivas en imágenes médicas, ya que son rotacionalmente invariantes (Sushovan Chaudhury, 2021).

Por esto, para el dataset de este proyecto, se ha decidido aplicar una rotación de 15º, dentro del rango previamente indicado, ya que aporta variabilidad sin distorsionar las partes importantes de las imágenes.

Width shift range y Hight shift range

Este tipo de transformación consiste en el desplazamiento de la imagen, vertical u horizontalmente, en el porcentaje del ancho especificado en el parámetro. Es especialmente útil para evitar el sesgo posicional de los datos, es decir, que el modelo aprenda a clasificar basándose en la posición de las estructuras en la imagen en lugar de en sus características morfológicas. Además, se recomiendan desplazamientos conservadores de entre el ±5% y el ±10% en imágenes médicas para preservar la integridad del diagnóstico, ya que porcentajes superiores podrían desplazar las estructuras relevantes fuera del encuadre (Connor Shorten, 2019). Por ello se ha decidido aplicar desplazamientos, tanto verticales como horizontales, de un ±8%, dentro del rango recomendado.

Zoom range

Este tipo de transformación consiste en aplicar un porcentaje de magnificación o zoom a las imágenes. Se ha concluido que zooms entre ±5% y ±10% son los más adecuados para imágenes médicas, ya que simulan pequeñas variaciones en la distancia focal del microscopio, que se producen de forma natural entre tomas del mismo tejido. En cambio, valores mayores alterarían la escala de las estructuras celulares y pueden confundir al modelo (Agnieszka Mikołajczyk-Bareła, 2018). Además, se ha comprobado que para la clasificación del dataset BreakHis, el zoom es una de las transformaciones principales de data augmentation, confirmando la efectividad en este ámbito (Musa Adamu Wakili, 2022).

Aunque las imágenes originales del dataset presenten aumentos por microscopio del 40%, 100%, 200% y 400%, y se haya decidido mantenerlos indistintamente, también se ha aplicado la transformación de zoom con un ±8%. Esto se ha hecho porque el porcentaje aplicado en el data augmentation es mucho menor que los aumentos de origen, por lo que no se estaría solapando ningún aumento. Además, como se ha explicado anteriormente, este valor se encuentra dentro del rango recomendado para este tipo de imágenes y se trata de una transformación útil y eficaz en este dataset.

Horizontal flip

Este tipo de transformación consiste en crear imágenes con 'efecto espejo' volteando las imágenes originales sobre su eje central de manera que se inviertan sus píxeles de izquierda a derecha. Se trata de una de las transformaciones más efectivas y sencillas de implementar, pero que dependen del contexto en el que se trabaje. Por ejemplo, si se trabaja con reconocimiento de texto, el flip destruye la etiqueta. A diferencia del ámbito médico, ya que los tejidos representados en imágenes médicas no tienen lateralidad preferente porque las estructuras celulares son morfológicamente simétricas y pueden aparecer con igual probabilidad en cualquier orientación horizontal. Esto supone que sea una transformación útil en este contexto, ya que preserva la clase (Connor Shorten, 2019). Se ha comprobado su utilidad en este ámbito, aplicándola en la clasificación de lesiones con CNN argumentando que la simetría bilateral de los tejidos biológicos justifica siempre su uso (Andre Esteva, 2017). De esta manera, se identifica como la transformación de data augmentation más aplicada en imágenes médicas (Geert Litjens, 2017).

Brightness range

Esta transformación es una de las más sencillas y prácticas de implementar. Consiste en aplicar operaciones matriciales simples sobre los valores RGB para aumentar o disminuir la luminosidad de la imagen (Connor Shorten, 2019). Además, se demostró que la manipulación del brillo y color es especialmente importante en las imágenes médicas debido a la variabilidad del proceso de tinción, y que valores superiores al 15%-20% podrían alterar la cromaticidad de forma poco realista, por lo que el rango conservador de alrededor del 10%, elegido para este proyecto, es el más habitual, ya que simula las diferencias en la intensidad de la tinción entre diferentes preparaciones médicas, que pueden variar entre laboratorios, lotes de reactivos y técnicos (David Tellez, 2019).

Channel shift range

Esta transformación consiste en el esplazamiento de los canales RGB aplicando una variación aleatoria sobre cada uno de estos de forma independiente. A diferencia de brightness range, que afecta a la luminosidad global de forma uniforme, el channel shift actúa canal a canal generando variaciones sutiles de tono que reproducen la variabilidad cromática real. Sin embargo, este tipo de transformación se describe como complementaria al brightness range, ya que cubren un tipo de variabilidad fotométrica diferente (Connor Shorten, 2019). Por esta razón, en el caso de este proyecto se aplica una variación de 10 unidades en los canales, el mismo valor que el aplicado en brightness range, ya que la variabilidad de color entre imágenes médicas no se limita al brillo, sino que también afecta a la distribución cromática entre canales (David Tellez, 2019).

Fill mode

Esta transformación es complementaria a rotaciones y desplazamientos, ya que al aplicar estas los píxeles que quedan fuera del encuadre original dejan huecos en los bordes de la imagen. Fill mode se utiliza para rellenar estos huecos y el modo en el que lo hace viene determinado por el parámetro que se defina. Con el valor 'nearest', cada píxel vacío se rellena copiando el valor del más cercano de la imagen original, lo que produce que el resultado sea visualmente coherente y menos artificial para imágenes de tejido celular, como lo es este caso. Además, se trata del modo de relleno más habitual a la hora de

aplicar data augmentation a imágenes médicas, ya que evita introducir colores o patrones artificiales que no existen en el tejido real (Connor Shorten, 2019).

Así, la aplicación de data augmentation se queda con estas transformaciones y valores respectivos:

Tabla 5. Parámetros de data augmentation

Transformación	Valor
Rotation range	15
Width shift range	0.08
Height shift range	0.08
Zoom range	0.08
Horizontal flip	True
Brightness range	(0.9, 1.1)
Channel shift range	10
Fill mode	nearest

Fuente: Elaboración propia con Python

Tras aplicar todas las transformaciones con los parámetros descritos, se ha solucionado el problema inicial de desbalanceo en el set de train reduciendo la diferencia con la clase mayoritaria drásticamente.

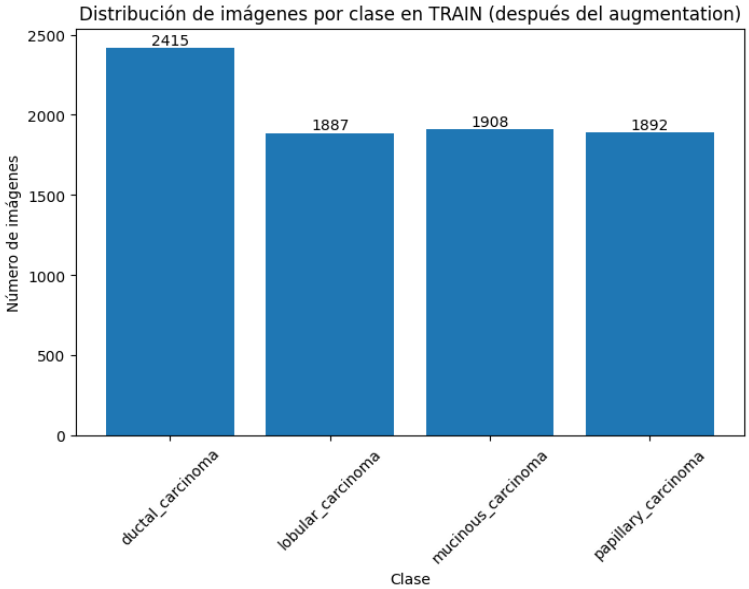

Ilustración 6. Distribución de las imágenes en Train después del augmentation (Fuente: Elaboración propia con Python)

Se observa que aún existe una diferencia mínima entre las clases, aunque se encuentran mucho más equilibradas que antes. Al ser una diferencia pequeña se solucinará mediante el ajuste de pesos en la ejecución de los modelos. Pero, de esta manera, los datos ya se encuentran almacenados en las carpetas correspondientes a su clase de forma balanceada.

3.4.3. Generadores

Los generadores de datos son una solución al problema de cargar grandes volúmenes de imágenes en memoria de forma simultánea. En lugar de cargar todo el dataset de una vez, el generador lee y procesa las imágenes por lotes durante el entrenamiento, lo que reduce bastante el consumo de la memoria RAM (HT, 2019). De esta manera, presentan la forma estándar de cargar datos a un modelo de Keras cuando el dataset es demasiado grande para cargarse en memoria de golpe (Chollet, 2021).

Pero es necesario definir unos parámetros cada set que estandaricen la carga de los datos. Por lo que, para este proyecto, se han definido 3 generadores, uno para cada set de datos (train, validation y test) aplicando, en cada uno, parámetros para el rescaldo de los píxeles y dimensiones, el número de imágenes que se cargan, el modo de las etiquetas y la mezcla de los datos.

Rescale

Las imágenes, al ser RGB con entrada de 8 bits por canal, se almacenan con valores de píxel en rango [0, 255], por lo que antes de introducirlas en la red es necesario normalizarlas al rango [0, 1] dividiendo cada valor de píxel por 255. Esto es importante, ya que se ha demostrado que la normalización de los datos de entrada es fundamental para la convergencia del entrenamiento, ya que evita que los gradientes sean dominados por las diferencias de escala entre características (Ian Goodfellow, 2016). Además, las redes neuronales convergen más rápido y de forma estable cuando los valores de entrada están en rangos pequeños y centrados. Por ello, para este proyecto, esta normalización se aplica a los tres generadores con el objetivo de garantizar que todos los datos se escalan de la misma forma.

Target size

Como ya se ha comentado anteriormente, las imágenes del dataset BreakHis tienen una dimensión general de 700x460, pero las arquitecturas pre entrenadas en Imagenet como ResNet, DenseNet o EfficientNet esperan imágenes de tamaño fijo. Se trata de un tamaño estándar de entrada de 2024x224 píxeles establecido, originalmente, en VGG (Karen Simonyan, 2015) y adoptado, posteriormente, en ResNet (Kaiming He, 2015), DenseNet y EfficientNet (Mingxing Tan, 2020). Por esta razón, al ser estas tres últimas las arquitecturas en este proyecto, este redimensionamiento es un requerimiento fundamental.

Batch size

El batch size determina el número de imágenes que se procesan en cada paso de cada epoch durante el entrenamiento. Se ha demostrado que valores entre 16 y 64 (ver Anexo 7) ofrecen el mejor equilibrio entre velocidad de entrenamiento y capacidad de generalización en los modelos CNN (Ibrahem Kandel, 2020). Además, los tamaños de batch entre 2 y 64 (ver Anexo 7) generalizan mejor que los tamaños grandes, ya que el ruido introducido por lotes pequeños actúa como un regularizador implicito (Luschi, 2018).

Por estas razones se ha aplicado un batch size de 32, ya que representa un equilibrio entre la estabilidad del gradiente y la capacidad de generalización y por eso es uno de los valores más usados en la clasificación de imágenes.

Class mode

Mediante este parámetro se indica al generador el tipo de las clases a clasificar, que en este proyecto son categóricas, por lo que las etiquetas de cada una se codifican como vertores one-hot. Esto es que cada clase se representa como un vector de longitud igual al número total de clases, donde solo la posición correspondiente a la clase correcta vale 1 y el resto valen 0 (Keras, s.f.). Este parámetro es fundamental, ya que la función de activación y la función de perdida de los modelos depende de las clases. Por ejemplo, para softmax y categorícal crossentropy como funciones de activación y perdida, respectivamente, corresponde un class mode categorical (Ian Goodfellow, 2016), que es justo el caso de este proyecto.

Shuffle

Tener shuffle activado permite que las imágenes se carguen de forma aleatoria sin seguir el orden de las etiquetas. Por ello, es importante que se active en los generadores de train y validation para evitar que el modelo se aprenda el orden de las imágenes. En cambio, en el generador de test debe estar desactivado, ya que es fundamental que las etiquetas reales coincidan de forma exacta con el orden de las predicciones para poder calcular métricas como la matriz de confusión o la curva ROC. En caso de que estuviera activado en test, las predicciones y las etiquetas quedarían desalineadas y las métricas, por tanto, serían incorrectas (J, 2018).

Así, los 3 generadores se quedan con estos parámetros y valores respectivos:

Tabla 6. Parámetros de los generadores para cada set

	Train	Validation	Test
Rescale	1./255	1./255	1./255
Target size	(224, 224)	(224, 224)	(224, 224)
Batch size	32	32	32
Class mode	Categorical	Categorical	Categorical
Shuffle	True	True	False

Fuente: Elaboración propia con Python

3.5. Conclusión

Tras aplicar todas estas técnicas, se ha aprendido información sobre los datos con los que se cuenta, lo que ha permitido preprocesarlos de la manera idónea para los modelos que se van a configurar. De esta forma, los datos con los que se va a trabajar finalmente quedan almacenados y etiquetados correctamente, además de estar divididos en los 3 sets correspondientes, estando balanceados en train, que van a utilizar los modelos durante el aprendizaje. De esta manera también quedan preparados los generadores que cargarán los datos en los formatos correctos durante dicho aprendizaje.

BIBLIOGRAFÍA

Aditya Chattopadhyay, A. S. (2018). Grad-CAM++: Improved Visual Explanations for Deep Convolutional Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1710.11063

Agnieszka Mikołajczyk-Bareła, M. G. (2018). Data augmentation for improving deep learning in image classification problem. 2018 International Interdisciplinary PhD Workshop (IIPhDW).

Ali Erdem Ozcelik, N. O. (2025). Optimizing malignancy prediction: A comparative analysis of transfer learning techniques on EBUS images. Clinics.

Ameen, M. (2026). Explainable Mammogram Analysis with EfficientNetV2 and Grad-CAM++ for Robust Cancer Diagnosis. Diagnostics.

Andre Esteva, B. K. (2017). Dermatologist-level classification of skin cancer with deep neural networks. Obtenido de Nature: https://doi.org/10.1038/nature21056

Azzedine El mrabet, M. B. (2025). Explainable AI for Skin Cancer Classification Unlocking Insights with Grad-Cam and Grad-Cam++. 2025 International Conference on Circuit, Systems and Communication (ICCSC). Fez, Morocco.

Balamurali, J. H. (2022). Transfer Learning and Data Augmentation in the Diagnosis of Knee MRI. AI 2021: Advances in Artificial Intelligence. Sydney.

Bedmar, I. S. (2023). Procesamiento del Lenguaje Natural con Aprendizaje Profundo. Obtenido de Universidad Carlos III de Madrid: https://ocw.uc3m.es/pluginfile.php/7195/mod_page/content/5/6-da-ocw2023.pdf

Biblioteca Nacional de Medicina. (2025). Cáncer de Mama. Obtenido de Mediline Plus: https://medlineplus.gov/spanish/ency/article/000913.htm

Chávez, C. E. (2023). Sistema automático para la interpretación inmediata de mamografías para la determinación del riesgo de cáncer. Obtenido de Universidad Autónoma de Aguascalientes: http://hdl.handle.net/11317/2583

Chetan L. Srinidhi, O. C. (2021). Deep neural network models for computational histopathology: A survey. Medical Image Analysis.

Chollet, F. (2021). Deep Learning with Python. MANNING.

Collazo, N. d. (2020). Predicción en el diagnóstico de tumores de cáncer de mama empleando métodos de clasificación. Revista de Investigación en Tecnologías de la Información, 96-104.

Connor Shorten, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. Journal of Big Data.

Criollo, E. G. (2024). Comparativa de redes de aprendizaje profundo empleando transfer learning para detección de cáncer de mama en el corpus CBIS-DDSM. Obtenido de Repositorio Institucional de la Universidad Politécnica Salesiana: http://dspace.ups.edu.ec/handle/123456789/28664

David Tellez, G. L.-M. (2019). Quantifying the effects of data augmentation and stain color normalization in convolutional neural networks for computational pathology. Medical Image Analysis.

Dominic Masters, C. L. (2018). REVISITING SMALL BATCH TRAINING FOR DEEP NEURAL NETWORKS. Obtenido de Arxiv: https://arxiv.org/pdf/1804.07612

Fabio A. Spanhol, L. S. (2016). A Dataset for Breast Cancer Histopathological Image Classification. Obtenido de IEEE TRANSACTIONS ON BIOMEDICAL ENGINEERING: https://www.inf.ufpr.br/lesoliveira/download/TBME-00608-2015-R2-preprint.pdf

Gao Huang, Z. L. (2018). Densely Connected Convolutional Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1608.06993

Geert Litjens, T. K. (2017). A Survey on Deep Learning in Medical Image Analysis. Obtenido de Arxiv: https://arxiv.org/pdf/1702.05747

HT. (2019). ImageDataGenerator. Obtenido de Medium: https://medium.com/@hackares/imagedatagenerator-bbc935a88f7b

Hugo Chanampe, S. A. (2019). Modelo de redes neuronales convolucionales profundas para la clasificación de lesiones en ecografías mamarias. XXI Workshop de Investigadores en Ciencias de la Computación - WICC 2019. San Juan.

Ian Goodfellow, Y. B. (2016). Deep Learning.

Ibrahem Kandel, M. C. (2020). The effect of batch size on the generalizability of the convolutional neural networks on a histopathology dataset. ICT Express.

Institute, A. C. (s.f.). Papillary carcinoma. Obtenido de Advocate Health Care: https://www.advocatehealth.com/health-services/cancer-institute/cancers-we-treat/breast-cancer/papillary-carcinoma-breast

J, V. (2018). Tutorial on Keras flow_from_dataframe. Obtenido de Medium: https://vijayabhaskar96.medium.com/tutorial-on-keras-flow-from-dataframe-1fd4493d237c

J.A. Gómez Ruiz, J. J. (2000). Un Modelo para la Predicción de Recidiva de Pacientes Operados de Cáncer de Mama (CMO) Basado en Redes Neuronales. Revista Iberoamericana de Inteligencia Artificial, 39-45.

Jason Wang, L. P. (2017). The Effectiveness of Data Augmentation in Image Classification using Deep Learning. Obtenido de Arxiv: https://arxiv.org/pdf/1712.04621

Jason Yosinski, J. C. (2014). How transferable are features in deep neural networks? Obtenido de NeurIPS Proceedings: https://proceedings.neurips.cc/paper_files/paper/2014/file/532a2f85b6977104bc93f8580abbb330-Paper.pdf

Jonathan de Matos, S. T. (2021). Machine Learning Methods for Histopathological Image Analysis: A Review. Electronics.

Joseph Lemley, S. B. (2017). Smart Augmentation - Learning an Optimal Data Augmentation Strategy. Obtenido de IEEE: 10.1109/ACCESS.2017.2696121

Kaiming He, X. Z. (2015). Deep Residual Learning for Image Recognition. Obtenido de Arxiv: https://arxiv.org/pdf/1512.03385

Karen Simonyan, A. Z. (2015). VERY DEEP CONVOLUTIONAL NETWORKS FOR LARGE-SCALE IMAGE RECOGNITION. ICLR 2015.

Keras. (s.f.). Image data loading. Obtenido de Keras: https://keras.io/api/data_loading/image/

Luschi, D. M. (2018). REVISITING SMALL BATCH TRAINING FOR DEEP NEURAL NETWORKS. Obtenido de Arxiv: https://arxiv.org/pdf/1804.07612

Marina Álvarez-Benito, E. E.-C.-M. (2025). Inteligencia artificial en el diagnóstico por imagen de patología mamaria. Revista de Senología y Patología Mamaria - Journal of Senology and Breast Disease.

Mingxing Tan, Q. V. (2020). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. Obtenido de Arxiv: https://arxiv.org/pdf/1905.11946

Miriam Hägele, P. S. (2020). Resolving challenges in deep learning-based analyses of histopathological images using explanation methods. Scientific Reports.

Mitko Veta, J. P. (2014). Breast Cancer Histopathology Image Analysis: A Review. Obtenido de IEEE TRANSACTIONS ONBIOMEDICALENGINEERING: https://helios2.mi.parisdescartes.fr/~lomn/Cours/CV/BME/HistoPatho/LongPapers/TBMEHistopathoBreastImageProcessingReview2014.pdf

Musa Adamu Wakili, H. A. (2022). Classification of Breast Cancer Histopathological Images Using DenseNet and Transfer Learning. Computational Intelligence and Neuroscience.

Nadia Harbeck, F. P.-L. (2019). Breast cancer. Nature Reviews Disease Primers.

NIH, I. N. (s.f.). carcinoma ductal. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/carcinoma-ductal

NIH, I. N. (s.f.). carcinoma lobulillar. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/carcinoma-lobulillar

NIH, I. N. (s.f.). carcinoma mucinoso. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/carcinoma-mucinoso

NIH, I. N. (s.f.). Metástasis. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/metastasis

NIH, I. N. (s.f.). tinción H y E. Obtenido de Instituto Nacional del Cáncer NIH: https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/tincion-h-y-e

Nima Tajbakhsh, J. Y. (2017). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning? Obtenido de Arxiv: https://arxiv.org/pdf/1706.00712

Ocariz, J. P. (2025). Análisis Sistemático de Métodos de Explicabilidad Aplicados al Deep Learning en Oncología. Obtenido de Universidad Politécnica de Madrid: https://oa.upm.es/91155/3/TFG_PASTOR_OCARIZ_JAIME.pdf

Puay Hoon Tan, I. E. (2020). The 2019 World Health Organization classification of tumours of the breast. Hystopathology.

Reshma Ahmed Swarna, M. M. (2024). Concrete Crack Detection and Segregation: A Feature Fusion, Crack Isolation, and Explainable AI-Based Approach. Journal of Imaging.

Santora, T. (2025). Información sobre los adenomas de mama: síntomas y tratamientos. Obtenido de BREASTCANCER.ORG: https://www.breastcancer.org/es/afecciones-mamarias-benignas/adenoma

Simón, J. A. (2023). Clasificación y explicabilidad de imágenes tumorales cerebrales con Aprendizaje Profundo (Deep Learning). Obtenido de Universidad de Valladolid: https://uvadoc.uva.es/handle/10324/62839

Society, A. C. (2022). Adenosis del seno. Obtenido de American Cancer Society: https://www.cancer.org/es/cancer/tipos/cancer-de-seno/afecciones-no-cancerosas-de-los-senos/adenosis-del-seno.html

Society, A. C. (2022). Fibroadenomas del seno. Obtenido de American Cancer Society: https://www.cancer.org/es/cancer/tipos/cancer-de-seno/afecciones-no-cancerosas-de-los-senos/fibroadenomas-del-seno.html

Society, A. C. (2022). Tumores filodes del seno. Obtenido de American Cancer Society: https://www.cancer.org/es/cancer/tipos/cancer-de-seno/acerca/tipos-de-cancer-de-seno/tumores-filoides-del-seno.html

Suorong Yang, W. X. (2023). Image Data Augmentation for Deep Learning: A Survey. Obtenido de Arxiv: https://arxiv.org/pdf/2204.08610

Sushovan Chaudhury, N. M. (2021). A Novel Approach to Classifying Breast Cancer Histopathology Biopsy Images Using Bilateral Knowledge Distillation and Label Smoothing Regularization. Computational and Mathematical Methods in Medicine.

UFPR, U. F. (2016). Base de datos histopatológica del cáncer de mama (BreakHis). Obtenido de Laboratorio de Visión, Robótica e Imagen: https://web.inf.ufpr.br/vri/databases/breast-cancer-histopathological-database-breakhis/

Vásquez, D. A. (2025). Desarrollo de un algoritmo basado en transfer learning para el análisis de imágenes médicas de cáncer de mama. Obtenido de Universidad Estatal Península de Santa Elena: https://repositorio.upse.edu.ec/handle/46000/14157

ANEXO 1. DESCARGA DEL DATASET BREAKHIS

Para descargar este dataset hay que usar el link ‘http://www.inf.ufpr.br/vri/databases/BreaKHis_v1.tar.gz’, que se encuentra en la sección ‘How to obtain access to the images’, al final de la web ‘https://web.inf.ufpr.br/vri/databases/breast-cancer-histopathological-database-breakhis/’.

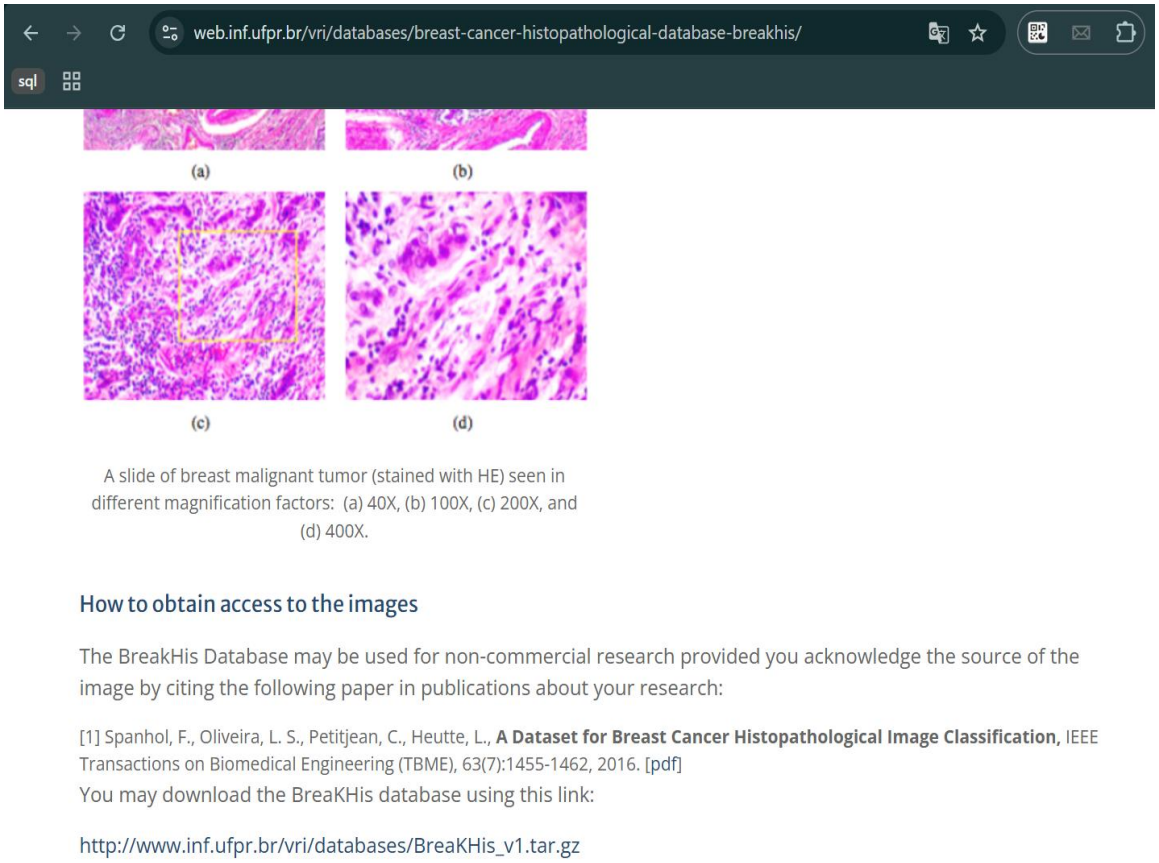

Ilustración 7. Captura de la sección de descarga del dataset BreakHis (Fuente: (UFPR, 2016))

ANEXO 2. COMPROBACIÓN DE LAS CLASES DE LAS IMÁGENES

```
--- ductal_carcinoma ---
SOB_M_DC-14-10926-100-001.png
SOB_M_DC-14-10926-100-002.png
SOB_M_DC-14-10926-100-003.png

--- lobular_carcinoma ---
SOB_M_LC-14-12204-100-015.png
SOB_M_LC-14-12204-100-031.png
SOB_M_LC-14-12204-100-032.png

--- mucinous_carcinoma ---
SOB_M_MC-14-10147-100-001.png
SOB_M_MC-14-10147-100-002.png
SOB_M_MC-14-10147-100-003.png

--- papillary_carcinoma ---
SOB_M_PC-14-12465-100-001.png
SOB_M_PC-14-12465-100-002.png
SOB_M_PC-14-12465-100-003.png
```

Ilustración 8. Comprobación de las clases de las imágenes

(Fuente: Elaboración propia con Python)

ANEXO 3. DISTRIBUCIÓN DE LAS DIMENSIONES

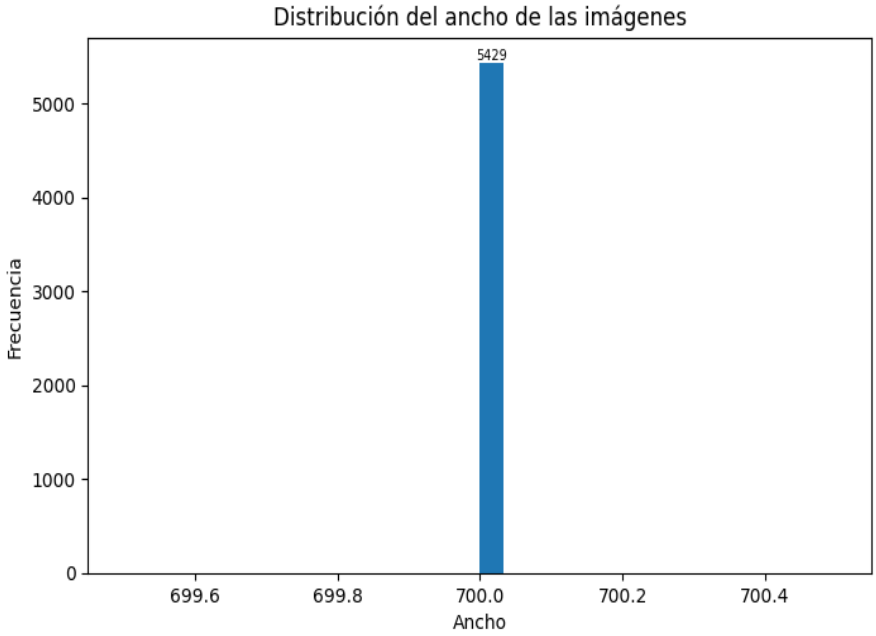

Ilustración 9. Distribución del ancho de las imágenes

(Fuente: Elaboración propia con Python)

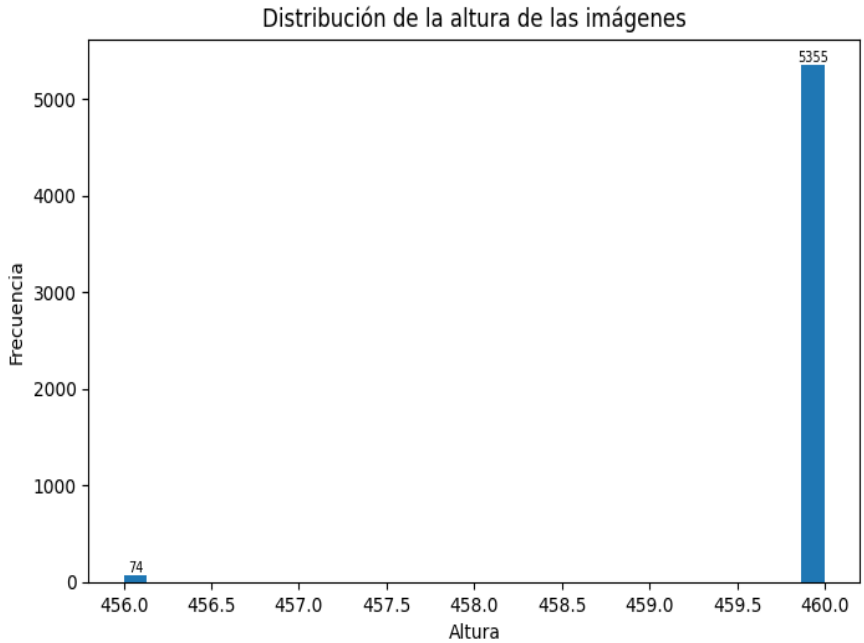

Ilustración 10. Distribución de la altura de las imágenes

(Fuente: Elaboración propia con Python)

ANEXO 4. EJEMPLOS DE IMÁGENES CON DIMENSIONES DISTINTAS

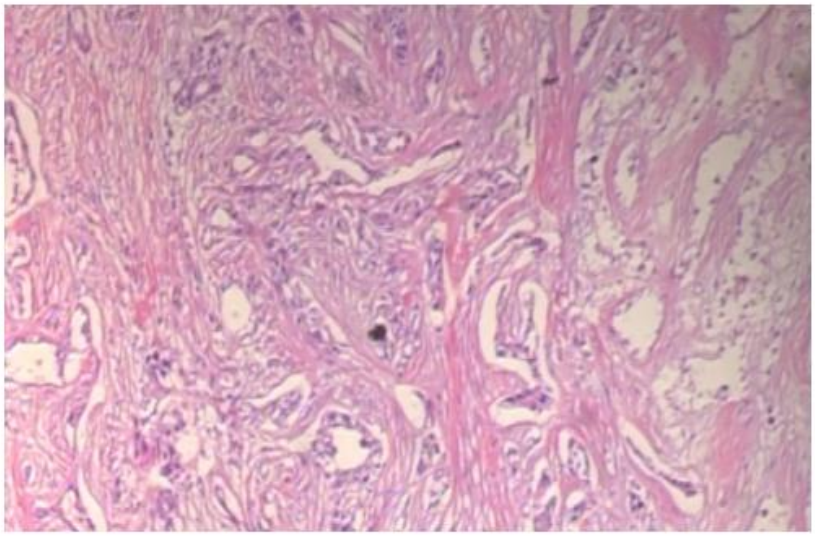

Ilustración 11. Imagen de 700x460
(Fuente: (Fabio A. Spanhol, 2016))

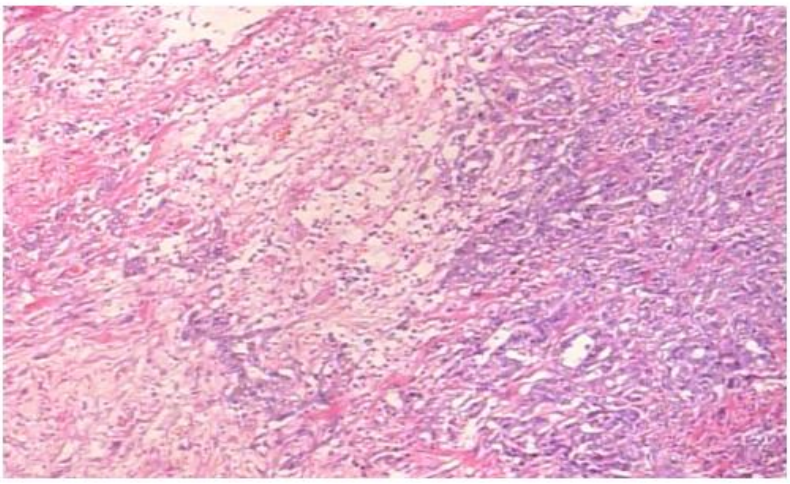

Ilustración 12. Imagen de 700x456
(Fuente: (Fabio A. Spanhol, 2016))

ANEXO 5. DISTRIBUCIÓN DEL MODO Y N.º DE CANALES

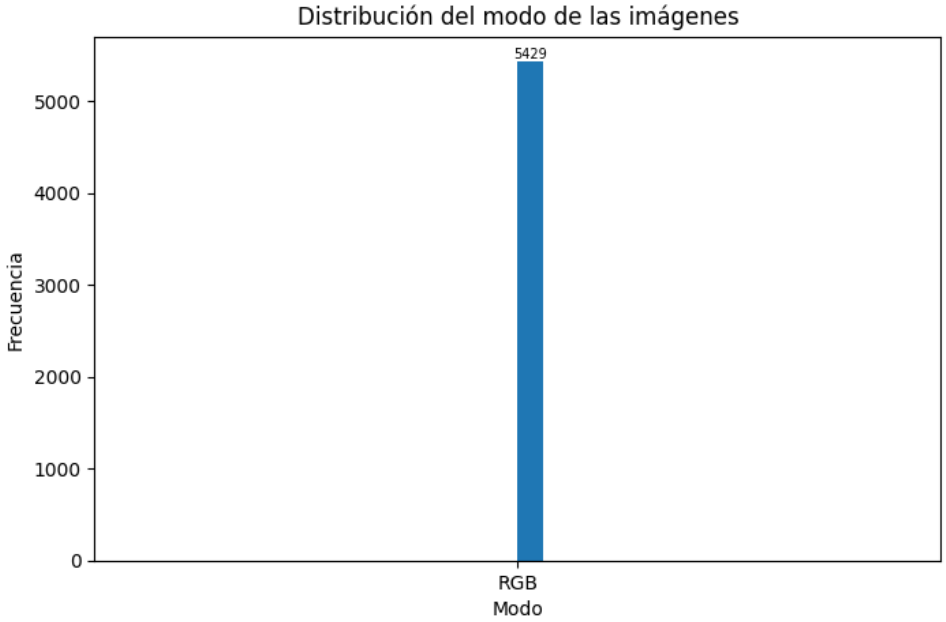

Ilustración 13. Distribución del modo de las imágenes

(Fuente: Elaboración propia con Python)

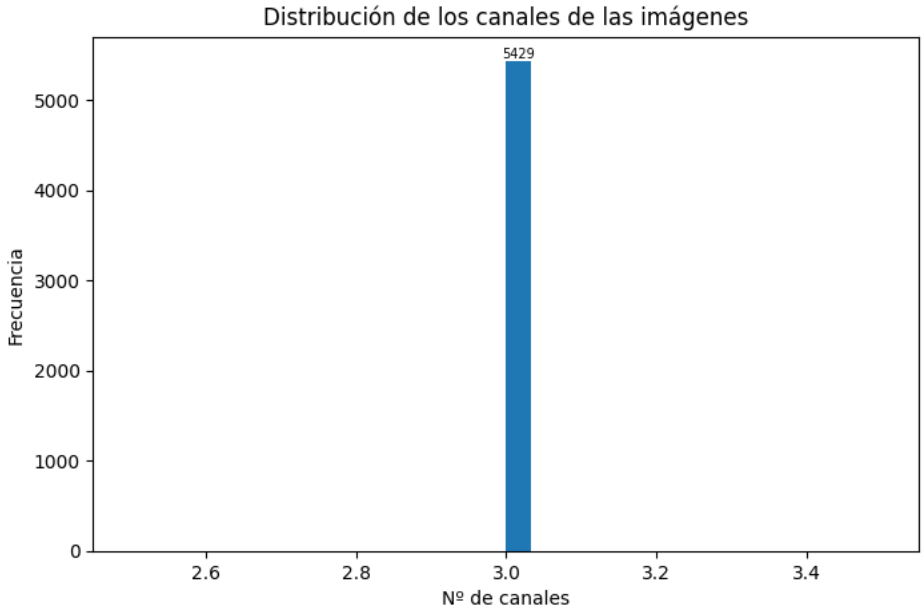

Ilustración 14. Distribución de los canales de las imágenes

(Fuente: Elaboración propia con Python)

ANEXO 6. TRANSFORMACIONES DE DATA AUGMENTATION

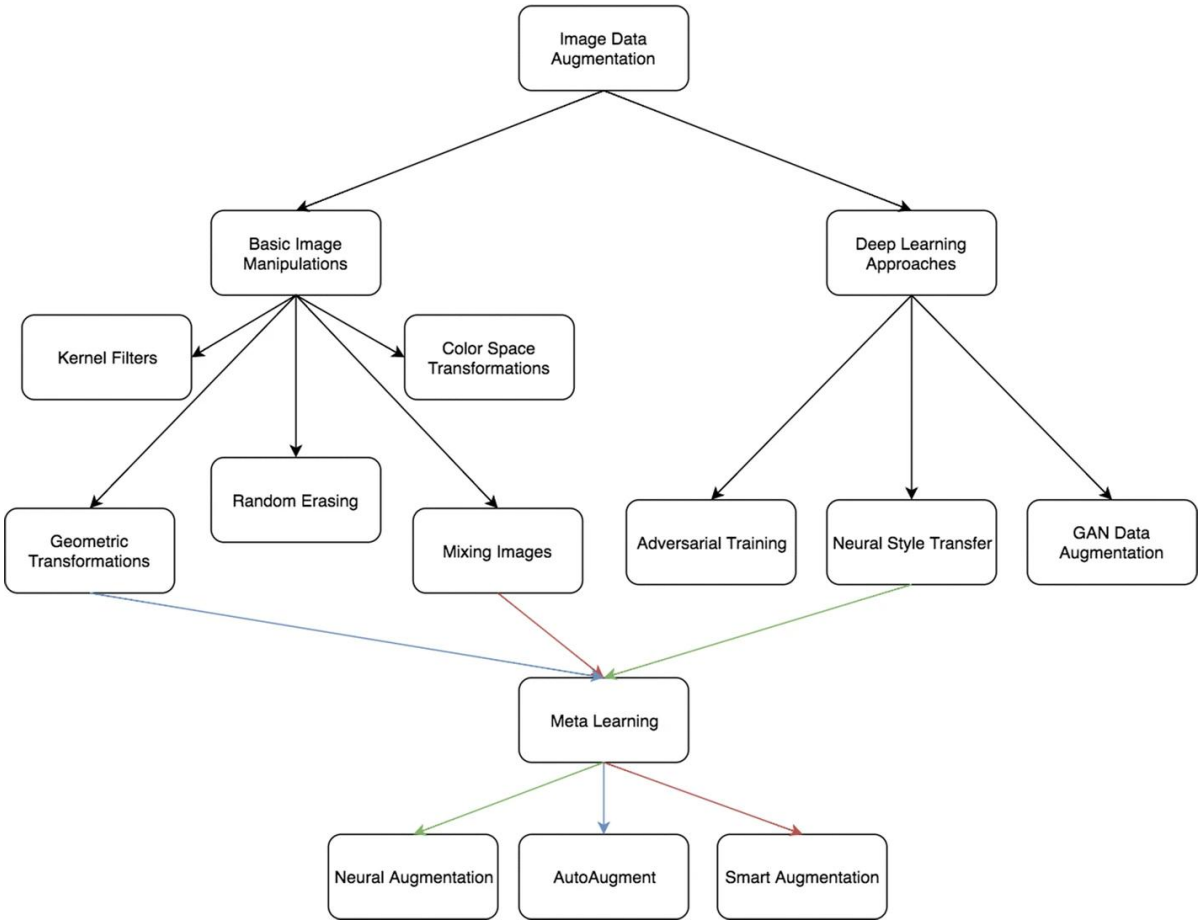

Ilustración 15. Transformaciones de data augmentation

(Fuente: (Connor Shorten, 2019))

ANEXO 7. COMPARACIÓN DE DIFERENTES VALORES DE BATCH SIZE

Table 1. The results of the test AUC of the Adam optimizer.

Test AUC		
Batch size	**Adam LR = 0.0001**	**Adam LR = 0.001**
16	**0.9677**	0.9144
32	0.9636	0.9332
64	0.9616	0.9381
128	0.9567	0.9432
256	0.9585	**0.9652**

Table 2. The results of the test AUC of the SGD optimizer.

Test AUC		
Batch size	**SGD LR = 0.0001**	**SGD LR = 0.001**
16	0.9555	0.9461
32	**0.9570**	0.9521
64	0.9512	0.9545
128	0.9302	0.9567
256	0.9077	**0.9579**

Ilustración 16. Comparación de diferentes valores de batch size (1)

(Fuente: (Ibrahem Kandel, 2020))

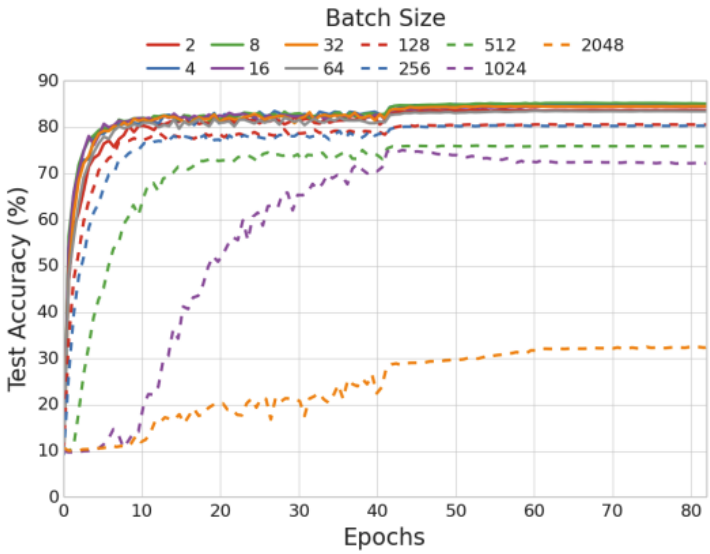

Ilustración 17. Comparación de diferentes valores de batch size (2)

(Fuente: (Dominic Masters, 2018))